Corretor Automático de Provas usando Inteligência Artificial

Trabalho de Conclusão de Curso

Lucas Lorenzo Savino Maycon Mendes Fernandes

Abril de 2026

Instituto Federal de Educação, Ciência e Tecnologia Fluminense

Campus Campos Centro — Bacharelado em Engenharia da Computação

Orientador: Prof. Dr. Luiz Gustavo Lourenço Moura

Sumário

1. Introdução e Problema
2. Objetivos
3. Justificativa
4. Fundamentação Teórica
5. Trabalhos Relacionados
6. Metodologia e Desenvolvimento
7. Resultados
8. Discussão
9. Conclusão e Trabalhos Futuros

Introdução e Problema

O Problema: Correção Manual de Provas Discursivas

Desafios da correção discursiva:

1. **Tempo:** professores dedicam 6–10 h semanais a atividades extraclasse [1] — correção compete com planejamento e acompanhamento
2. **Fadiga do avaliador:** dificuldade de manter o mesmo rigor ao longo de muitas correções
3. **Subjetividade:** diferentes avaliadores atribuem notas distintas à mesma resposta [2]
4. **Escala:** em turmas grandes ou avaliações nacionais, o custo operacional é significativo

Pergunta de pesquisa

Como apoiar o professor com uma avaliação inicial **padronizada e rastreável**, alinhada aos seus critérios pedagógicos, **sem substituir** seu papel decisório?

Objetivos

Objetivo Geral

Desenvolver um **sistema de apoio à decisão docente** na correção de provas discursivas utilizando LLMs, apoiado pela recuperação dinâmica de contexto (RAG), produzindo avaliações preliminares consistentes e alinhadas aos critérios pedagógicos estabelecidos pelos professores — **mantendo a decisão final sob responsabilidade do docente**.

Objetivos Específicos

1. Construir um **banco de dados vetorial** a partir dos materiais didáticos fornecidos pelos professores (RAG)
2. Desenvolver módulo de **configuração inicial** das provas com critérios avaliativos definidos pelo professor
3. Implementar mecanismo de correção baseado em **múltiplos agentes independentes** com arbitragem condicional por divergência
4. Disponibilizar **módulo de revisão docente** que permita revisar, ajustar e confirmar as correções realizadas pelo sistema

Justificativa

Justificativa

Por que esta solução é necessária:

- Automatizar a **avaliação inicial** libera tempo docente para atividades de maior valor pedagógico — planejamento, feedback qualitativo, acompanhamento individualizado
- Critérios explícitos e consistentes **reduzem a variabilidade** entre correções, aumentando a equidade
- A revisão final permanece com o professor — a IA **complementa**, não substitui
- Ferramentas existentes não integram **critérios pedagógicos configuráveis** nem oferecem **rastreabilidade** das decisões automáticas

Contribuição esperada

Um artefato tecnológico que torna possível a correção discursiva mais **eficiente, consistente e auditável**, mantendo o docente no centro do processo avaliativo.

Fundamentação Teórica

Avaliação Educacional e AES

Avaliação discursiva

- Exige análise qualitativa — não se reduz a gabarito
- Subjetividade é inerente, mas pode ser **reduzida** com critérios explícitos e padronizados

AES — *Automated Essay Scoring*

- Campo consolidado para correção automática de redações
- Modelos clássicos (BERT, RoBERTa) treinados em corpus anotados
- Limitação: dependem de dados rotulados em larga escala e língua/domínio específico

Lacuna que motivou este trabalho

AES tradicional não suporta **critérios pedagógicos configuráveis** nem integração ao fluxo de revisão docente — problemas que abordamos com LLMs + RAG.

Conceitos-Chave

LLM — Large Language Models

Modelos baseados na arquitetura *Transformer* (Vaswani et al., 2017), capazes de gerar texto coerente e contextualizado. Usamos **Gemini 2.5 Flash** (Google).

RAG — Recuperação Aumentada por Geração

Estratégia que fornece ao LLM trechos relevantes do material didático recuperados por similaridade vetorial, ancorando a correção ao conteúdo programático da disciplina.

Sistemas Multiagentes (SMA)

Múltiplos agentes independentes colaboram para uma tarefa. Aqui: dois corretores paralelos + árbitro condicional, inspirado no processo do ENEM.

Engenharia de Prompt

Técnicas para instruir o LLM: **Role Prompting** (identidade especializada), **Chain-of-Thought** (raciocínio passo a passo) e **Groundedness** (fidelidade ao contexto RAG).

Trabalhos Relacionados

Revisão Sistemática da Literatura

INSTITUTO FEDERAL Fluminense

Protocolo PICOC

- Bases: ACM, IEEE, Scopus, Google Scholar
- Termos: *automated grading*, *LLM assessment*, *essay scoring*
- Resultado: **7 estudos incluídos** após triagem

Padrão encontrado nos estudos

- Foco em métricas preditivas (QWK, Pearson)
- Domínio inglês/japonês, dados rotulados
- Pouca ênfase em integração institucional

Questões de pesquisa respondidas

QP1: LLMs são viáveis para correção? *Sim, com prompts estruturados.*

QP2: RAG melhora especificidade? *Sim, especialmente em respostas parciais.*

QP3: Há suporte a revisão docente? *Não nos trabalhos analisados — esta é a lacuna.*

Lacuna na Literatura e Oportunidade

O que a literatura já faz bem:

- Métricas de desempenho preditivo em cenários controlados
- Modelos de AES (*Automated Essay Scoring*) para inglês/japonês
- Uso de LLMs para feedback em redações

O que ainda falta:

- Integração ao **fluxo real de correção docente**
- Rastreabilidade das decisões automatizadas
- Critérios pedagógicos explícitos configurados pelo professor
- Auditabilidade para revisão humana

Trabalho mais próximo

SteLLA (Qiu et al., 2025): sistema estruturado com LLMs + RAG para correção, mas sem mecanismo de arbitragem nem revisão docente integrada.

Metodologia e Desenvolvimento

Visão Geral da Arquitetura

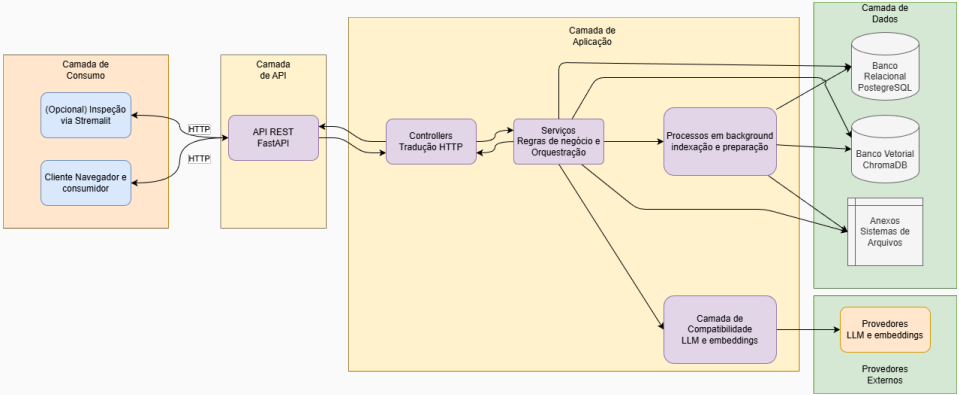

FastAPI (backend) · LangGraph (orquestração) · LangChain (agentes) · ChromaDB (vetorial) · PostgreSQL (relacional)

Subprocesso 1 — Configuração da Prova

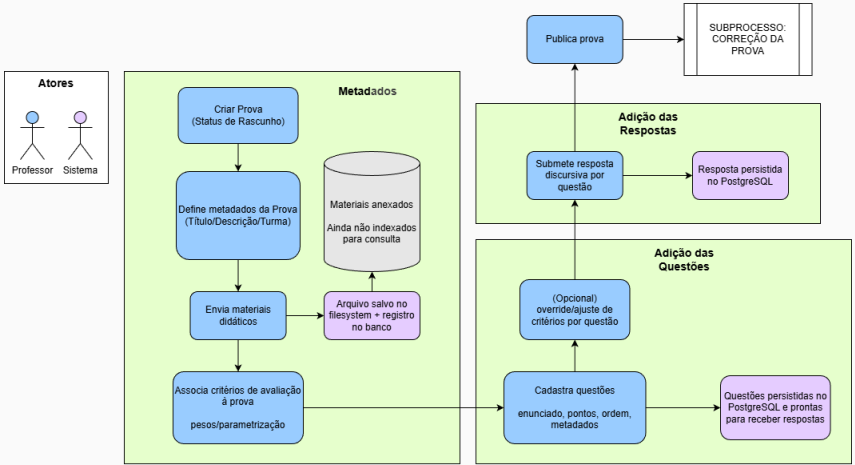

Subprocesso 2 — Fluxo de Correção da Prova

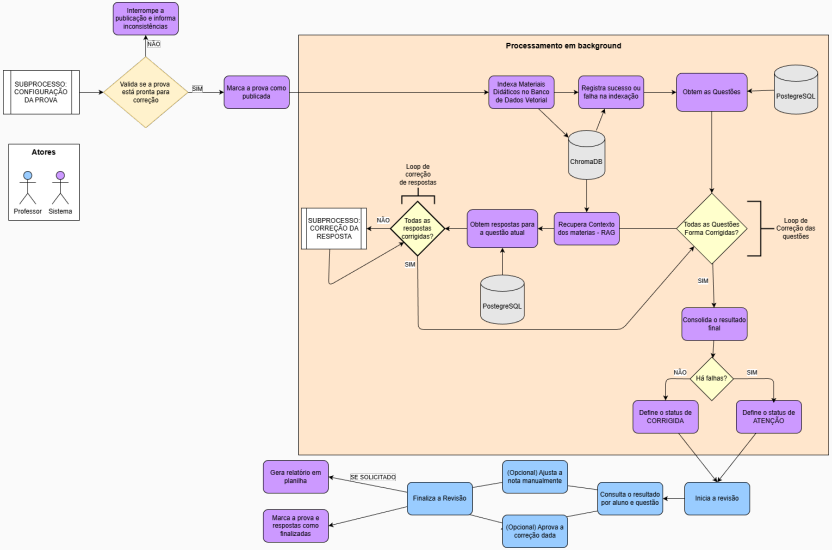

Subprocesso 3 — Fluxo de Correção da Resposta

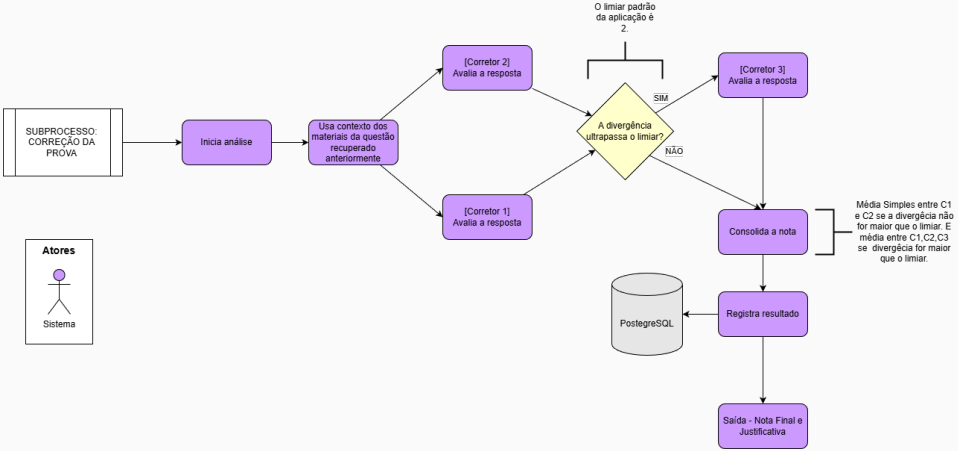

Stack Tecnológica

Backend e Orquestração

- **Python + FastAPI**: API REST assíncrona
- **LangGraph**: grafo de estados para pipeline multiagente
- **LangChain**: integração com LLMs
- **Docker Compose**: containerização

Armazenamento

- **PostgreSQL**: dados relacionais (provas, respostas, notas)
- **ChromaDB**: banco vetorial para RAG
- **Alembic**: versionamento de esquema

IA e Modelo

- **Gemini 2.5 Flash** (Google): LLM principal
- Temperatura = 0,0 (baixa estocasticidade)
- Embeddings para indexação vetorial

Experimentação

- **Jupyter Notebook**: orquestra experimento via API REST
- Resultados exportados em CSV e JSON
- Código disponível publicamente no GitHub

Resultados

Desenho do Estudo

INSTITUTO FEDERAL Fluminense

4 Questões Avaliativas (QAs)

- **QA1:** O sistema executa o fluxo *end-to-end* sem falhas?
- **QA2:** O RAG melhora a especificidade da avaliação?
- **QA3:** O árbitro é acionado somente quando $|C1 - C2| > 2{,}0$?
- **QA4:** O sistema produz notas estáveis em execuções repetidas?

Delineamento

Estudo de caso controlado com **dados pareados**:
Condição A (com RAG) vs. Condição B (sem RAG)

3 questões · 4 níveis de qualidade · 12 respostas/condição

Nota importante

O objetivo é validar o **funcionamento e a rastreabilidade** do sistema como artefato tecnológico de apoio ao trabalho docente — **não** mensurar eficácia educacional ampla nem sustentar superioridade definitiva da IA sobre a correção humana.

Configuração do Experimento

Parâmetro	Valor
Modelo LLM	Gemini 2.5 Flash
Temperatura	0,0
Questões (Q)	3 (Algoritmos e ED)
Respostas por questão	4 níveis de qualidade
Total de respostas	12 por condição
Critérios de avaliação	5 critérios
Limiar de divergência	2,0 pontos
Repetições (QA4)	$R = 3$

Delineamento:

- **Condição A** (com RAG): material indexado no ChromaDB
- **Condição B** (sem RAG): sem material de referência
- **Mesmo conjunto pareado** de respostas nas duas condições

Níveis de qualidade das respostas:
Excelente · Intermediária · Fraca · Fora do tema

QA1 — Execução *End-to-End*

Resultado

24/24 respostas processadas

100% de completude estrutural

Todas as 13 etapas do fluxo concluídas com sucesso:

- Cadastro, indexação vetorial, publicação
- Correção paralela C1 e C2
- Verificação de divergência
- Persistência no PostgreSQL
- Disponibilização via API REST

Cada correção produziu:

- Nota final consensuada
- Notas individuais de C1 e C2
- Pontuação por critério
- Justificativa textual por critério
- Valor de divergência
- Método de consenso aplicado

Viabilidade técnica confirmada

A arquitetura multiagente com LangGraph é funcionalmente coerente e operacionalmente viável.

QA2 — Utilidade do RAG

Nível	Média A (RAG)	Média B (sem RAG)	Δ
Excelente	10,00	10,00	0,00
Intermediária	9,31	8,47	+0,84
Fraca	1,07	0,95	+0,12
Fora do tema	0,00	0,00	0,00

Maior impacto individual:
Q1/Intermediária: $\Delta = +1{,}92$ Q2/Intermediária: $\Delta = +0{,}59$

Interpretação

O RAG funciona como **gabarito contextual**: ancora a avaliação ao conteúdo programático específico da disciplina, melhorando a precisão em respostas parcialmente corretas.

Extremos inalterados: LLM identifica respostas inequívocas sem precisar de referência adicional.

QA3 — Arbitragem por Divergência

Nível	Divergência máx.	Árbitro?
Excelente	0,00	Não
Intermediária	1,18	Não
Fraca	1,22	Não
Fora do tema	0,00	Não

Limiar configurado:
DIVERGENCE_THRESHOLD $= 2{,}0$
Divergência máxima observada: 1,22 pontos

Critério atendido

Árbitro acionado **se e somente se** $|C1 - C2| > 2{,}0$. Mecanismo funcionou corretamente: nenhum acionamento indevido em 24 casos.

Por que baixa divergência?

- Temperatura 0,0 minimiza variabilidade
- Prompts com critérios explícitos

QA4 — Estabilidade Operacional

Nível	R_1	R_2	R_3	Var. máx.
Excelente	10,00	10,00	10,00	0,00
Intermediária	9,88	9,04	9,08	0,84
Fraca	0,51	1,71	1,88	1,37
Fora do tema	0,00	0,00	0,00	0,00

Critério: variação $\leq 1{,}0$ ponto. Questão Q2, $R = 3$ repetições.

Resultado:

- Extremos: variação nula — reprodutibilidade perfeita
- Intermediária: $\leq 0{,}84$ ✓ (atende critério)
- Fraca: 1,37 (parcialmente atende)

Nota

Variabilidade em respostas fracas é inerente: erros parciais coexistem com alguma terminologia adequada, gerando julgamentos ambíguos mesmo com temperatura 0,0.

Síntese dos Resultados

QA	Critério	Resultado	Status
QA1	Completude $\geq 95\%$	24/24 (100%)	**Atendido**
QA2	Efeito do RAG observável	$\Delta = +0{,}84$ (interm.)	**Atendido**
QA3	Árbitro acionado só se $> 2{,}0$	Máx. 1,22; árbitro não acionado	**Atendido**
QA4	Variação $\leq 1{,}0$ ponto	Extremos: 0,00; Interm.: 0,84; Fraca: 1,37	**Parcial**
Tempo de correção (12 respostas, Condição A)			**155 s**

$\approx$ 12,9 s/resposta — tempo substancialmente inferior à correção manual

Discussão

Viabilidade Técnica e Operacional

Viabilidade técnica

- Fluxo *end-to-end* executado sem falhas
- Artefatos **estruturados e rastreáveis**: nota final, notas por critério, justificativas, divergência
- ChromaDB + PostgreSQL integrados conforme especificado
- Pipeline determinístico e reproduzível

Viabilidade operacional

- **Professor mantém autoridade**: aceita, revisa ou rejeita cada correção antes da consolidação
- Acesso via API REST — integrável a sistemas institucionais
- Corretores C1 e C2 em paralelo (LangGraph) reduzem tempo total
- Sistema operou de forma autônoma sem intervenção manual entre etapas

Limitações Observadas

1. **Respostas sintéticas:** conjunto de 12 respostas elaboradas pelos autores em níveis bem definidos — respostas reais têm maior variabilidade e gradações intermediárias
2. **Escala reduzida:** 3 questões de uma única disciplina — generalização limitada
3. **Modelo único:** todos os experimentos com `gemini-2.5-flash` — resultados podem variar com outros LLMs
4. **Sem comparação com correção humana:** impossibilita mensurar acurácia absoluta (*ground truth*)
5. **Árbitro não exercitado empiricamente:** nenhuma divergência ultrapassou o limiar de 2,0 pontos neste experimento

Conclusão e Trabalhos Futuros

Trabalhos Futuros

- **Validação com respostas humanas reais:** concordância IA vs. docente (coeficiente Kappa, correlação de Pearson)
- **Exercitação empírica do árbitro:** respostas mais heterogêneas para provocar divergências acima do limiar
- **Estudo multi-modelo:** OpenAI, Anthropic, modelos locais via Ollama
- **Análise aprofundada do RAG:** mais disciplinas e materiais didáticos
- **Interface docente completa:** ajuste por critério, anotações, relatórios pedagógicos de lacunas de aprendizagem
- **Detecção de plágio e integridade acadêmica:** similaridade entre respostas e detecção de conteúdo gerado por IA

Conclusão

Objetivos atingidos:

- ✓ Banco vetorial (ChromaDB) construído a partir do material didático
- ✓ Módulo de configuração com critérios e pesos definidos pelo professor
- ✓ Correção por múltiplos agentes independentes com arbitragem condicional
- ✓ Módulo de revisão docente integrado ao fluxo via API REST

Resultados principais:

- 100% de completude *end-to-end* (QA1)
- RAG aumentou especificidade avaliativa (QA2)
- Árbitro funcionou corretamente (QA3)
- Estabilidade satisfatória nos extremos (QA4)

Evidência de **viabilidade técnica e operacional** — validação pedagógica com turmas reais é o próximo passo.

Obrigado!

Lucas Lorenzo Savino **Maycon Mendes Fernandes**

Orientador: Prof. Dr. Luiz Gustavo Lourenço Moura

`github.com/savinoo/ai-grading-system`

Perguntas?

Referências i

- BARBOSA, A. et al. Tempo de trabalho e de ensino. *Educação e Pesquisa*, v. 47, 2021.
- BORGES, B. G.; SILVA, S. P. D. Avaliação, exames e poderes. *EDUCAÇÃO E FILOSOFIA*, v. 31, 2017.
- QIU, H. et al. SteLLA: A Structured Grading System Using LLMs with RAG. arXiv, 2025.