

Lucas Lorenzo Savino
Maycon Mendes Fernandes

Corretor automático de provas usando inteligência artificial

Campos dos Goytacazes-RJ

Abril de 2026

Lucas Lorenzo Savino
Maycon Mendes Fernandes

Corretor automático de provas usando inteligência artificial

Trabalho de Conclusão apresentado ao curso Bacharelado em Engenharia da Computação do Instituto Federal de Educação, Ciência e Tecnologia Fluminense, como parte dos requisitos para a obtenção do título de Bacharel em Engenharia da Computação.

Instituto Federal de Educação, Ciência e Tecnologia Fluminense

Orientador: Prof. Dr. Luiz Gustavo Lourenço Moura

Campos dos Goytacazes-RJ

Abril de 2026

Lucas Lorenzo Savino
Maycon Mendes Fernandes

Corretor automático de provas usando inteligência artificial

Trabalho de Conclusão apresentado ao curso Bacharelado em Engenharia da Computação do Instituto Federal de Educação, Ciência e Tecnologia Fluminense, como parte dos requisitos para a obtenção do título de Bacharel em Engenharia da Computação.

Campos dos Goytacazes-RJ, 07 de abril de 2026.

Prof. Dr. Fernando Luiz de Carvalho e Silva
Instituto Federal Fluminense (IFF)

Prof. Me. Márcio de Oliveira Pontes
Instituto Federal Fluminense (IFF)

Orientador: Prof. Dr. Luiz Gustavo Lourenço Moura
Instituto Federal Fluminense (IFF)

Campos dos Goytacazes-RJ
Abril de 2026

AGRADECIMENTOS

Agradeço primeiramente a Deus, por ter estado comigo desde o primeiro dia em que saí da casa dos meus pais. Sua presença foi o meu sustento nos momentos difíceis e em todo o processo de adaptação que um estudante que mora longe de casa enfrenta. Aos meus pais, Marciano Savino e Mailza Savino, que, apesar de todos os problemas do cotidiano, nunca mediram esforços para me ajudar financeiramente e me oferecer suporte emocional. Se hoje cheguei onde estou, é porque pude me apoiar no ombro de gigantes que vocês são para mim. À minha mulher, Thaiz Batista da Cunha, que sempre esteve comigo, fazendo-se presente mesmo nos momentos de distância física. Agradeço por ter mudado minha personalidade para melhor com seu jeito incrível de ser e por me ensinar a encontrar a felicidade nas pequenas coisas. Você fez toda a diferença nesta jornada. Ao meu amigo Maycon Mendes Fernandes, pela parceria constante nas atividades e pela grande amizade que construímos. Maycon, você sempre foi minha primeira opção para os desafios acadêmicos, e sou grato por todo o conhecimento profissional e pessoal que adquiri ao seu lado. Aos meus professores, em especial àqueles que tiveram paciência comigo nos primeiros anos de faculdade. O início foi um mundo totalmente novo, mas hoje me sinto integrado à área da tecnologia e devo grande parte dessa conquista aos ensinamentos e à dedicação de vocês. Por fim, agradeço a mim mesmo, pelo esforço contínuo e pela resiliência que só eu conheço. Pelos dias intensos de estudo, pelas orações, pelas noites regadas a café e pelo desgaste mental superado. Olhando para trás, vejo que cada parte do processo valeu a pena para chegar até aqui.

- Lucas Lorenzo Savino

Agradeço a Deus, por ter me dado a oportunidade de viver esta experiência acadêmica e por me guiar em cada passo do caminho. Sua presença constante foi fundamental para superar os desafios e alcançar este momento tão importante. A minha mãe, Maria Cristina Mendes, que sempre me apoiou incondicionalmente, mesmo quando as circunstâncias eram difíceis. Sua força e amor foram essenciais para que eu pudesse seguir em frente, mesmo nos momentos mais desafiadores. A minha namorada, Anna Carolina F. Sartori, que esteve ao meu lado durante toda a jornada, oferecendo apoio emocional e compreensão a todo momento. Sua presença foi um porto seguro nos momentos de estresse e uma fonte de motivação para continuar avançando com leveza. Ao meu amigo Lucas Lorenzo Savino, com quem compartilhei muitos momentos de estudo e aprendizado. A parceria e a amizade que construímos foram fundamentais para o meu desenvolvimento acadêmico e pessoal. Lucas, agradeço por todo o conhecimento que adquiri com você em nossas discussões. Aos meus amigos e colegas de curso, que tornaram a experiência universitária mais leve e

divertida. Em especial, a Rodrigo P. Almeida, Lucas R. Rangel, Pedro M. Menezes e Ester P. Nunes, vocês foram uma parte importante da minha jornada, e sou grato por cada momento compartilhado. Por fim, aos meus professores, que me ensinaram não apenas o conteúdo acadêmico, mas também lições de vida e ética profissional. Agradeço por todo o conhecimento transmitido e pela dedicação em nos preparar para o futuro.

- Maycon Mendes Fernandes

RESUMO

A correção de provas discursivas é uma das tarefas mais onerosas da prática docente, sujeita a alto custo de tempo e subjetividade do avaliador. Este trabalho apresenta o desenvolvimento e a avaliação de um sistema de correção automatizada baseado em múltiplos agentes de Inteligência Artificial, com suporte à Recuperação Aumentada por Geração (RAG) e arbitragem condicional por divergência. Dois agentes corretores independentes avaliam cada resposta em paralelo com base em uma rubrica e no material didático da disciplina; quando a divergência entre as notas ultrapassa um limiar configurável, um terceiro agente árbitro é acionado, em desenho inspirado no processo de correção do ENEM. A arquitetura emprega FastAPI, LangGraph, LangChain, ChromaDB e PostgreSQL. A avaliação foi conduzida por meio de um estudo de caso controlado com dados pareados entre as condições com e sem RAG, três questões discursivas de Algoritmos e Estrutura de Dados e quatro níveis de qualidade de resposta. O sistema completou o fluxo *end-to-end* sem falhas, com 100% de completude estrutural. O mecanismo de divergência funcionou conforme especificado: nenhuma das 24 correções ultrapassou o limiar de 2,0 pontos (máximo: 1,22), de modo que o árbitro não foi acionado. O RAG aumentou a especificidade avaliativa, alterando as notas de forma não uniforme: efeito positivo no nível intermediário ($\Delta = +0,84$) e modesto no nível fraco ($\Delta = +0,12$), com casos de maior rigor quando o material expôs lacunas mais claramente; os extremos permaneceram inalterados ($\Delta = 0,00$). No teste de estabilidade com $R = 3$ repetições, os níveis extremos apresentaram variação nula e o nível intermediário atendeu ao critério ($\leq 1,0$ ponto), enquanto o nível fraco ultrapassou o limiar (variação máxima de 1,37). Os resultados evidenciam a viabilidade técnica e operacional do protótipo como ferramenta de apoio à correção docente.

Palavras-chave: Correção Automatizada. Inteligência Artificial. Modelos de Linguagem (LLM). Recuperação Aumentada por Geração (RAG). Sistemas Multiagentes. Avaliação Educacional.

ABSTRACT

The grading of open-ended exam questions is one of the most time-consuming tasks in teaching practice, subject to high time costs and evaluator subjectivity. This work presents the development and evaluation of an automated grading system based on multiple Artificial Intelligence agents, with support for Retrieval-Augmented Generation (RAG) and conditional divergence-based arbitration. Two independent grading agents evaluate each response in parallel using a rubric and course reference materials; when divergence exceeds a configurable threshold, a third arbiter agent is invoked, following a design inspired by Brazil’s official ENEM essay grading process. The architecture uses FastAPI, LangGraph, LangChain, ChromaDB, and PostgreSQL. The evaluation was conducted through a controlled case study with paired data between conditions with and without RAG, three open-ended questions on Algorithms and Data Structures, and four response quality levels. The system completed the end-to-end flow without failures, achieving 100% structural completeness. The divergence mechanism functioned as specified: none of the 24 corrections exceeded the 2.0-point threshold (maximum: 1.22), so the arbiter was not triggered. RAG increased evaluative specificity, altering scores in a non-uniform way: positive effect on intermediate-quality responses ($\Delta = +0.84$) and modest on weak responses ($\Delta = +0.12$), with cases of increased strictness when the reference material exposed gaps more clearly; extreme levels were unaffected ($\Delta = 0.00$). In the stability test with $R = 3$ repetitions, extreme levels showed zero variation and the intermediate level met the criterion (≤ 1.0 point), while the weak level exceeded the threshold (maximum variation of 1.37). The results demonstrate the technical and operational feasibility of the prototype as a tool to support teacher grading.

Keywords: Automated Grading. Artificial Intelligence. Large Language Models (LLM). Retrieval-Augmented Generation (RAG). Multi-Agent Systems. Educational Assessment.

LISTA DE FIGURAS

Figura 1 – Fluxograma do subprocesso de configuração da prova	39
Figura 2 – Fluxograma do subprocesso de correção da prova, incluindo revisão docente antes da consolidação das notas finais	40
Figura 3 – Fluxograma do subprocesso de correção da resposta, com acionamento condicional do Corretor 3 por limiar de divergência	41
Figura 4 – Visão geral da arquitetura do sistema	52
Figura 5 – Fluxo de requisição e resposta entre camadas do backend	54
Figura 6 – Pipeline de correção com Retrieval-Augmented Generation (RAG) e arbitragem por divergência	57
Figura 7 – Modelo entidade-relacionamento simplificado do domínio	63
Figura 8 – Esquema completo do banco de dados relacional	91

LISTA DE QUADROS

Quadro 1 – Elementos PICOOC e suas palavras-chave	25
Quadro 2 – Características dos estudos incluídos	28
Quadro 3 – Parâmetros experimentais utilizados no estudo	48
Quadro 4 – Exemplos de endpoints do fluxo principal do sistema	54
Quadro 5 – Parâmetros efetivos do experimento	68
Quadro 6 – Caracterização dos níveis de qualidade das respostas sintéticas	69
Quadro 7 – Verificação de execução <i>end-to-end</i> do sistema	70
Quadro 8 – Síntese do atendimento aos critérios de sucesso	78

LISTA DE TABELAS

Tabela 1	–	Compleitude estrutural dos artefatos gerados — Condição A (com RAG)	70
Tabela 2	–	Compleitude estrutural dos artefatos gerados — Condição B (sem RAG)	71
Tabela 3	–	Comparação de notas finais — Condição A (com RAG) vs. Condição B (sem RAG)	72
Tabela 4	–	Comparação de notas médias por nível de qualidade	72
Tabela 5	–	Verificação de divergência — Condição A (com RAG)	74
Tabela 6	–	Verificação de divergência — Condição B (sem RAG)	75
Tabela 7	–	Estabilidade das notas em execuções repetidas ($R = 3$) — Questão Q2	76
Tabela 8	–	Tempos de execução do <i>pipeline</i> de correção	77

LISTA DE CODIGOS

Codigo 1 – Definição do grafo de correção com LangGraph	58
---	----

LISTA DE SIGLAS

IA	Inteligência Artificial
LLM	Large Language Model
PLN	Processamento de Linguagem Natural
RAG	Retrieval-Augmented Generation
RNN	Redes Neurais Recorrentes
LSTM	Long Short-Term Memory
RNA	Redes Neurais Artificiais
SMA	Sistemas Multiagentes
CoT	Chain-of-Thought
AES	Automated Essay Scoring
ENEM	Exame Nacional do Ensino Médio
API	Application Programming Interface
JSON	JavaScript Object Notation
PDF	Portable Document Format
PICOC	População, Intervenção, Comparação, Outcome e Contexto
DSPy	Declarative Self-improving Python (framework de programação para modelos de linguagem)

SUMÁRIO

1	INTRODUÇÃO	1
1.1	Objetivos	2
1.1.1	Objetivo Geral	3
1.1.2	Objetivos Específicos	3
1.2	Justificativa	3
2	FUNDAMENTAÇÃO TEÓRICA	5
2.1	Avaliação Educacional	5
2.1.1	Conceitos e Importância da Avaliação no Processo Educacional	5
2.1.2	Desafios da Avaliação Discursiva	6
2.1.3	Subjetividade na Avaliação de Questões Dissertativas	7
2.2	Correção Manual de Provas Discursivas	8
2.2.1	Processo Tradicional de Correção	8
2.2.2	Limitações e Desafios da Correção Manual	9
2.2.3	Impacto da Subjetividade na Avaliação	10
2.2.4	Necessidade de Automação no Processo de Correção	11
2.3	Inteligência Artificial e Processamento de Linguagem Natural	12
2.3.1	Fundamentos de Inteligência Artificial	12
2.3.2	Processamento de Linguagem Natural (PLN)	13
2.3.3	Modelos de Linguagem e Transformers	14
2.3.4	Large Language Model (LLM)s e suas Aplicações	15
2.4	Arquiteturas de Agentes de IA e Estratégias de Coordenação	17
2.4.1	Agentes de IA	17
2.4.2	Sistema de Multi Agentes	18
2.4.3	Engenharia de Prompt	19
2.4.4	RAG	21
3	TRABALHOS RELACIONADOS	23
3.1	Protocolo de Pesquisa	23
3.1.1	Questões de pesquisa	23
3.1.2	Estratégia de pesquisa e instrumentos	24
3.1.3	Procedimentos da Revisão Sistemática da Literatura	26

3.2	Caracterização da Pesquisa	27
3.3	Resultados e Discussões	29
3.3.1	LLMs e Avaliação Automatizada de Redações	29
3.3.2	Inteligência Artificial (IA) na Geração e Avaliação de Feedback Educacional	31
3.3.3	Desafios e Considerações Éticas	32
3.4	Respostas às Questões de Pesquisa	34
3.5	Considerações	36
4	METODOLOGIA	38
4.1	Tipo de Pesquisa	38
4.2	Processo de Correção de Prova	38
4.2.1	Subprocesso de Configuração da Prova	42
4.2.2	Subprocesso de Correção da Prova	42
4.2.3	Subprocesso de Correção da Resposta	43
4.3	Ferramentas e Tecnologias Utilizadas	43
4.3.1	Python	43
4.3.2	FastAPI	43
4.3.3	Orquestração do fluxo com LangGraph	44
4.3.4	Agentes corretores com LangChain	44
4.3.5	Integração com LLMs e provedores de <i>embeddings</i>	44
4.3.6	Recuperação de contexto e armazenamento vetorial	44
4.3.7	Persistência relacional e migrações	45
4.3.8	Containerização	45
4.3.9	Ollama e Streamlit	45
4.3.10	JavaScript Object Notation (JSON)	45
4.4	Métodos de Avaliação	45
4.4.1	Objetivo da avaliação	46
4.4.2	Questões avaliativas	46
4.4.3	Desenho do estudo	46
4.4.4	Parâmetros experimentais	47
4.4.5	Procedimento experimental	48
4.4.6	Evidências coletadas	49
4.4.7	Métricas simples	49
4.4.8	Critérios de sucesso	50
4.4.9	Ameaças à validade	50
4.4.10	Reprodutibilidade	51
5	DESENVOLVIMENTO	52
5.1	Arquitetura do sistema	52
5.2	Backend	53

5.2.1	Processamento assíncrono e <i>status</i> de rastreabilidade	55
5.3	Pipeline de IA (RAG, correção e arbitragem)	55
5.3.1	Recuperação de contexto	58
5.3.2	Vantagens do desenho multiagente frente a uma correção monolítica	59
5.3.3	Correção por agentes e saídas estruturadas	60
5.3.4	Engenharia de <i>prompts</i> dos agentes corretores	60
5.4	Modelagem do banco de dados	62
5.4.1	Justificativa das entidades e relações	64
5.5	Integrações e decisões técnicas	65
5.5.1	Integrações principais	65
5.5.2	Infraestrutura de experimentação	66
5.5.3	Disponibilização do código-fonte	66
5.5.4	Decisões e <i>trade-offs</i>	66
6	RESULTADOS E DISCUSSÕES	68
6.1	Configuração do experimento	68
6.1.1	Respostas sintéticas	69
6.2	QA1 — Execução <i>end-to-end</i>	69
6.2.1	Resultados	70
6.2.2	Análise	71
6.3	QA2 — Utilidade do RAG	72
6.3.1	Comparação de notas	72
6.3.2	Efeito do RAG sobre a precisão avaliativa	73
6.3.3	Análise	73
6.4	QA3 — Arbitragem por divergência	74
6.4.1	Resultados	74
6.4.2	Padrões de divergência	75
6.4.3	Análise	75
6.5	QA4 — Estabilidade operacional	76
6.5.1	Resultados	76
6.5.2	Análise	76
6.6	Desempenho temporal	77
6.6.1	Análise	77
6.7	Discussão integrada	78
6.7.1	Síntese dos critérios de sucesso	78
6.7.2	Viabilidade técnica	78
6.7.3	Viabilidade operacional	79
6.7.4	Contribuição do RAG	79
6.7.5	Limitações observadas	80

7	CONCLUSÃO	81
7.1	Trabalhos Futuros	82
	REFERÊNCIAS	84
	Apêndices	90
	APÊNDICE A – ESQUEMA COMPLETO DO BANCO DE DADOS	91
	APÊNDICE B – PROMPTS COMPLETOS	92

1 INTRODUÇÃO

A Inteligência Artificial (IA) alcançou avanços expressivos nos últimos anos, impulsionada principalmente pelo aprendizado profundo (*deep learning*) e técnicas baseadas em redes neurais artificiais (Young et al., 2018; Otter; Medina; Kalita, 2021). Esses métodos têm superado abordagens tradicionais em diversas aplicações, especialmente em tarefas complexas relacionadas à decisão, classificação e extração de informações.

Particularmente no Processamento de Linguagem Natural (PLN), esses avanços transformaram profundamente o cenário tecnológico (Torfi et al., 2021). Modelos neurais profundos, como as Redes Neurais Recorrentes (RNN), redes Long Short-Term Memory (LSTM) e mecanismos de atenção, mostraram-se altamente eficazes em tarefas como tradução automática, análise de sentimentos e reconhecimento de entidades (Young et al., 2018; Otter; Medina; Kalita, 2021).

Um marco decisivo nessa evolução foi a introdução da arquitetura *Transformer*, proposta por Vaswani et al. (2017), que eliminou a necessidade de recorrências ao utilizar mecanismos de autoatenção. Com isso, foi possível o treinamento de modelos maiores e mais eficientes, conhecidos como Large Language Model (LLM). Esses modelos são capazes de gerar textos coerentes e contextualizados, demonstrando versatilidade inédita em múltiplas tarefas linguísticas (Chen et al., 2021).

Os avanços proporcionados por LLMs e PLN vêm sendo amplamente aplicados para melhorar processos em diversas áreas. Na saúde, essas tecnologias têm auxiliado diagnósticos e agilizado a análise de dados clínicos (Paixão et al., 2022). No setor jurídico, LLMs ajudam na pesquisa legal e previsão de resultados judiciais, tornando o trabalho mais eficiente (Lai et al., 2024). Atendimento ao cliente, administração pública e setor empresarial também têm integrado esses modelos para automatizar tarefas e aprimorar a tomada de decisão (Pessanha; Vieira; Brandão, 2024). Esse cenário abre possibilidades promissoras também para o campo educacional (Shahzad et al., 2025).

O sistema educacional brasileiro enfrenta desafios multidimensionais, abrangendo questões estruturais, pedagógicas, avaliativas e administrativas. Estruturalmente, persistem deficiências em infraestrutura e recursos limitados, especialmente na rede pública, problemas agravados por desigualdades socioeconômicas e regionais (Carnaval, 2021). Pedagogicamente, destaca-se a formação insuficiente de professores e práticas de ensino ultrapassadas, que afetam diretamente a qualidade do ensino (Gatti, 2017). No contexto administrativo, políticas públicas descontínuas, baixa valorização docente e deficiências no planejamento institucional impedem avanços consistentes (Silva, 2020).

Em relação às avaliações, prevalecem exames tradicionais centrados na memorização, negligenciando abordagens formativas e críticas. Essa realidade, aliada à gestão escolar deficiente, compromete a equidade e a qualidade das avaliações (Santos, 2016).

Um desafio central nesse cenário educacional refere-se especificamente à correção de provas discursivas. Essa atividade exige alto empenho docente, análise minuciosa e critérios definidos para justiça na atribuição das notas. Estudos apontam que correções discursivas sofrem frequentemente de subjetividade e variação significativa entre avaliadores, impactando negativamente a equidade e a confiabilidade da avaliação educacional (Borges; Silva, 2017).

Embora o uso de IA em avaliação educacional tenha avançado consideravelmente nos últimos anos, ainda se observa uma lacuna entre os resultados experimentais reportados e a aplicação institucional contínua dessas ferramentas no fluxo de trabalho docente. Trabalhos recentes em correção automática no contexto brasileiro concentram-se predominantemente em maximizar métricas de acurácia preditiva em cenários controlados, recorrendo a abordagens como classificadores baseados em BERT (Lima; Freitas; Macario, 2024), redes neurais para classificação de fuga ao tema (Pinho; Gaspar; Sassi, 2024) e medidas de similaridade textual com técnicas tradicionais de PLN (Dias et al., 2023). Estudos com LLMs atuando como avaliadores reportam variabilidade de consistência entre modelos e prompts (Seo et al., 2025), e revisões críticas alertam para riscos de vieses algorítmicos quando os critérios pedagógicos não são explicitados ou auditáveis (Heggler; Szmoski; Miquelin, 2025). Persistem, portanto, três aspectos pouco endereçados de forma articulada nessas propostas: (i) a integração ao fluxo real de correção docente, preservando a decisão final do professor; (ii) a explicitação dos critérios pedagógicos sob os quais a avaliação automatizada é produzida; e (iii) a rastreabilidade e auditabilidade das decisões automatizadas (Borges; Silva, 2017; Shahzad et al., 2025). Adicionalmente, a articulação entre Retrieval-Augmented Generation (RAG) para fundamentação por material didático específico e arquiteturas multiagente que reduzam a dependência de uma única decisão automatizada permanece pouco explorada na literatura nacional, configurando o espaço investigado neste trabalho.

1.1 OBJETIVOS

Esta seção apresenta o objetivo geral e os objetivos específicos que orientam o desenvolvimento do trabalho, delimitando o escopo do sistema proposto e as funcionalidades a serem implementadas.

1.1.1 Objetivo Geral

Desenvolver um sistema de apoio à decisão docente na correção de provas discursivas utilizando LLMs, apoiado pela recuperação dinâmica de contexto, de modo a produzir avaliações preliminares consistentes e alinhadas aos critérios pedagógicos estabelecidos pelos professores, mantendo a revisão, o ajuste e a decisão final sob responsabilidade do docente.

1.1.2 Objetivos Específicos

1. Construir um banco de dados vetorial a partir dos materiais didáticos fornecidos pelos professores, permitindo ao sistema recuperar automaticamente conteúdos relevantes durante o processo de avaliação das respostas discursivas.
2. Desenvolver um módulo para configuração inicial das provas, em que os professores possam selecionar critérios avaliativos pré-existentes e definir, para cada critério, a pontuação máxima.
3. Implementar um mecanismo de correção baseado em múltiplos agentes virtuais independentes, capazes de analisar as respostas individualmente, tratando automaticamente eventuais divergências entre suas avaliações.
4. Disponibilizar um módulo de revisão docente que permita ao professor revisar, ajustar e confirmar as correções realizadas pelo sistema, favorecendo que as avaliações finais permaneçam alinhadas aos objetivos acadêmicos e critérios pedagógicos estabelecidos previamente.

1.2 JUSTIFICATIVA

A correção de provas discursivas impõe uma demanda considerável sobre o tempo dos docentes, uma tarefa essencial que, no entanto, compete com outras atividades pedagógicas cruciais como o planejamento de aulas e o acompanhamento individualizado dos estudantes. Pesquisas sobre a jornada de trabalho docente indicam que uma parcela significativa de professores dedica entre 6 a 10 horas semanais a atividades extraclasse, que incluem a elaboração e correção de avaliações (Barbosa et al., 2021). Este cenário de sobrecarga não apenas afeta o bem-estar docente, mas possui o potencial de impactar a qualidade geral do ensino.

A principal contribuição neste trabalho reside em oferecer ao professor uma ferramenta de suporte tecnológico capaz de agilizar a correção, liberando tempo para que o docente se dedique a aspectos mais estratégicos e humanizados da prática pedagógica.

É crucial enfatizar que a solução proposta visa complementar, e não substituir, o papel central do professor, atuando como um assistente na análise inicial das respostas, sempre com base nos critérios definidos pelo educador.

Adicionalmente, a correção manual está inerentemente sujeita à subjetividade, o que pode gerar inconsistências avaliativas (Borges; Silva, 2017). O sistema proposto busca oferecer uma avaliação inicial mais padronizada, embora a revisão final e os ajustes permaneçam sob a responsabilidade do professor, assegurando a conformidade com os objetivos acadêmicos e a experiência docente. Esta colaboração visa aumentar a equidade do processo avaliativo.

Em suma, a implementação desta solução busca contribuir para a melhoria da qualidade do ensino ao reduzir a carga operacional dos professores, permitindo que se concentrem em atividades que promovem a aprendizagem significativa. A ferramenta pode ainda auxiliar na identificação de padrões de dificuldades dos alunos, informando intervenções pedagógicas mais eficazes (Santos, 2016). Estudos recentes no contexto brasileiro evidenciam o potencial dessa abordagem em escala: a análise automática de 1.320 redações distribuídas em 119 temas distintos para classificação de fuga ao tema, no contexto do Exame Nacional do Ensino Médio (ENEM), alcançou resultados significativos com redes neurais convolucionais (Pinho; Gaspar; Sassi, 2024), indicando que padrões recorrentes podem ser identificados sistematicamente em volumes inviáveis para análise manual exaustiva. A proposta deste trabalho alinha-se a uma visão de que a tecnologia pode aprimorar os processos educativos, valorizando sempre o papel central do educador.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta as bases teóricas que sustentam o desenvolvimento de um sistema de correção automática de provas por meio de agentes de IA. Inicialmente, revisaremos os fundamentos de avaliação educacional, seus desafios e a subjetividade inerente à correção de questões dissertativas (seção 2.1). Em seguida, examinaremos o processo tradicional de correção manual, suas limitações e a necessidade de automação (seção 2.2). Na seção 2.3, abordaremos os princípios de IA e PLN, incluindo técnicas de deep learning e modelos transformer aplicáveis à compreensão de respostas escritas. Finalmente, na seção 2.4, discutiremos arquiteturas de agentes de IA, sistemas multi-agentes e estratégias avançadas como engenharia de prompt e RAG, que permitirão orquestrar componentes especializados para análise, pontuação e feedback automático.

2.1 AVALIAÇÃO EDUCACIONAL

Esta seção aborda a avaliação educacional como elemento central do processo de ensino-aprendizagem. Parte-se dos conceitos fundamentais e da importância da avaliação no contexto pedagógico, avançando para os desafios específicos da avaliação discursiva e para a discussão sobre a subjetividade inerente à correção de questões abertas.

2.1.1 Conceitos e Importância da Avaliação no Processo Educacional

A avaliação educacional constitui um elemento fundamental no processo de ensino-aprendizagem, representando não apenas um dispositivo de verificação do conhecimento adquirido, mas também um mecanismo essencial para o direcionamento das práticas pedagógicas. Segundo Carregari e Romão (2024), a avaliação transcende a mera atribuição de notas, configurando-se como um processo contínuo que permite diagnosticar dificuldades, reorientar o ensino e promover a evolução da aprendizagem.

Embora os princípios gerais de avaliação enfatizem seu caráter formativo e diagnóstico em qualquer sistema de ensino, no Brasil esses usos ganham contornos particulares devido ao nosso histórico de desigualdades educacionais. É nesse cenário que a avaliação não só verifica aprendizados, mas também sinaliza onde as políticas públicas e as práticas escolares precisam intervir.

No contexto educacional brasileiro, marcado por desafios estruturais e pedagógicos, a avaliação assume papel ainda mais relevante como ferramenta para identificação de lacunas e potencialidades do sistema. O processo avaliativo, quando bem conduzido,

possibilita a coleta de informações valiosas sobre o desempenho dos estudantes, permitindo intervenções pedagógicas mais precisas e eficazes.

A importância da avaliação educacional manifesta-se em múltiplas dimensões. No âmbito individual, proporciona ao estudante feedback sobre seu progresso, estimulando a metacognição e a autorregulação da aprendizagem. Para o professor, constitui instrumento diagnóstico que orienta o planejamento e a execução de estratégias didáticas. Na perspectiva institucional, fornece indicadores para políticas educacionais e reformulações curriculares.

2.1.2 Desafios da Avaliação Discursiva

A avaliação discursiva, caracterizada pela proposição de questões abertas que demandam respostas elaboradas pelos estudantes, apresenta particularidades e desafios significativos. Diferentemente das avaliações objetivas, as questões dissertativas permitem avaliar habilidades cognitivas complexas, como capacidade de análise, síntese, argumentação e pensamento crítico.

Conforme apontado por [Lima et al. \(2023\)](#), a correção de questões dissertativas constitui tarefa não trivial, exigindo do avaliador competências específicas e tempo considerável para a análise das respostas. O processo envolve a interpretação do conteúdo produzido pelo estudante, a identificação de elementos conceituais relevantes e o julgamento sobre a qualidade da argumentação desenvolvida.

Entre os principais desafios da avaliação discursiva, destacam-se aqueles relacionados ao desenho e à aplicação do instrumento avaliativo:

1. **Estabelecimento de critérios claros:** A definição de parâmetros objetivos para avaliação de respostas abertas representa desafio considerável, especialmente em áreas que envolvem interpretação e argumentação.
2. **Escala de aplicação:** Para instituições como escolas de ensino básico e fundamental, universidades e o ENEM, a atividade de correção demanda tempo e custo significativos para a avaliação dos textos produzidos ([Pinho; Gaspar; Sassi, 2024](#)).
3. **Feedback adequado:** A elaboração de devolutivas qualitativas que orientem o processo de aprendizagem representa outro desafio importante, especialmente em contextos com grande número de estudantes.

Os desafios operacionais decorrentes da execução da correção — tempo demandado, variabilidade entre avaliadores e fadiga — são abordados de forma específica na [seção 2.2](#), dedicada à correção manual de provas discursivas. Os desafios listados acima, por sua vez, tornam-se ainda mais evidentes em avaliações de larga escala, como vestibulares e

exames nacionais, onde a padronização dos critérios e a equidade no processo avaliativo são requisitos fundamentais.

2.1.3 Subjetividade na Avaliação de Questões Dissertativas

A subjetividade constitui elemento inerente ao processo de avaliação de questões dissertativas, representando simultaneamente riqueza e desafio. Conforme apontado por [Barroso, Reis e Amorim \(2021\)](#), a subjetividade está presente não apenas no processo de avaliação da aprendizagem, mas em todo o ambiente educacional, por ser parte intrínseca dos indivíduos que o compõem.

O estudo conduzido por [Barroso, Reis e Amorim \(2021\)](#) verificou que a subjetividade pode influenciar a avaliação da aprendizagem, inclusive interferindo na progressão do estudante para séries posteriores. Os autores observaram que, com o professor, não seria diferente, sendo necessária a consciência sobre a subjetividade durante as correções das atividades desenvolvidas pelos alunos, a fim de tentar minimizá-la para não prejudicar os estudantes.

[Borges e Silva \(2017\)](#), em seu trabalho sobre avaliação da aprendizagem, subjetividade e docimologia, aprofundam a discussão sobre os fatores que influenciam o julgamento avaliativo. A docimologia, ciência que estuda os exames e suas implicações, revela que diversos elementos subjetivos podem afetar a atribuição de notas, entre eles:

1. **Efeito de halo:** Tendência a generalizar uma característica positiva ou negativa do estudante para toda sua produção.
2. **Efeito de contraste:** Influência da qualidade das respostas anteriormente corrigidas sobre a avaliação da resposta atual.
3. **Efeito de estereotipia:** Influência de preconceitos ou expectativas prévias sobre determinados grupos de estudantes.
4. **Efeito de ordem:** Variação na avaliação conforme a posição da resposta no conjunto de provas.
5. **Fadiga do avaliador:** Alteração nos critérios de correção em função do cansaço acumulado durante o processo.

A consciência sobre estes fatores torna-se fundamental para o desenvolvimento de estratégias que minimizem seus impactos. Conforme destacado por [Barroso, Reis e Amorim \(2021\)](#), é necessário que o avaliador esteja ciente da subjetividade durante as correções, buscando estratégias para minimizar seus efeitos potencialmente prejudiciais.

Neste contexto, o desenvolvimento de sistemas automatizados de correção, baseados em critérios objetivos e consistentes, apresenta-se como alternativa promissora para mitigar os efeitos da subjetividade, especialmente em avaliações de larga escala. Contudo, como será discutido em seções posteriores, tais sistemas também enfrentam desafios significativos na captura da complexidade e riqueza do pensamento humano expressos em respostas dissertativas.

2.2 CORREÇÃO MANUAL DE PROVAS DISCURSIVAS

Esta seção examina o processo de correção manual de provas discursivas em suas diferentes dimensões. Descreve-se o fluxo tradicional de correção e suas etapas constitutivas, analisam-se as principais limitações e desafios operacionais enfrentados pelos docentes e discute-se o impacto da subjetividade sobre a validade e a confiabilidade das avaliações. Por fim, apresenta-se a necessidade de automação como resposta a esses desafios.

2.2.1 Processo Tradicional de Correção

O processo tradicional de correção de provas discursivas caracteriza-se por uma abordagem essencialmente manual, na qual o avaliador analisa individualmente cada resposta, comparando-a com parâmetros predefinidos ou gabaritos de referência. Este método, amplamente utilizado em instituições educacionais de diversos níveis, envolve uma série de etapas que demandam tempo e atenção consideráveis do professor ou avaliador.

Conforme observado por (Lima et al., 2023), o processo de correção manual de questões dissertativas constitui tarefa não trivial, exigindo do avaliador competências específicas e disponibilidade de tempo. Tipicamente, o avaliador precisa ler atentamente cada resposta, identificar os elementos conceituais presentes, verificar a coerência argumentativa, analisar a adequação da linguagem e, finalmente, atribuir uma pontuação que reflita a qualidade da resposta em relação aos objetivos de aprendizagem estabelecidos.

O processo tradicional de correção geralmente segue um fluxo que inclui:

1. **Elaboração de critérios de avaliação:** Definição prévia dos elementos que serão considerados na análise das respostas, incluindo conteúdo conceitual, estrutura argumentativa, uso da linguagem, entre outros.
2. **Leitura e análise individual:** Exame detalhado de cada resposta, identificando pontos fortes e fracos em relação aos critérios estabelecidos.
3. **Atribuição de pontuação:** Conversão do julgamento qualitativo em valor quantitativo, geralmente seguindo escalas predefinidas.

4. **Registro e feedback:** Documentação das avaliações e, idealmente, elaboração de comentários que orientem o processo de aprendizagem do estudante.

Este modelo, embora permita análise aprofundada e contextualizada das respostas, apresenta limitações significativas, especialmente em contextos de avaliação em larga escala ou com grande número de estudantes.

2.2.2 Limitações e Desafios da Correção Manual

A correção manual de provas discursivas, apesar de sua tradição e potencial para análise qualitativa aprofundada, enfrenta desafios consideráveis que impactam sua eficácia e viabilidade em diversos contextos educacionais. [Lima et al. \(2023\)](#) destacam que o Brasil experimentou, na última década, grande aumento na demanda por Educação a Distância, tendência acentuada com o advento da pandemia, o que intensificou a necessidade de ferramentas tecnológicas que possam auxiliar nas atividades pedagógicas e de avaliação.

Entre as principais limitações e desafios da correção manual, destacam-se:

1. **Tempo demandado:** Conforme apontado por [Barbosa et al. \(2021\)](#), o tempo gasto para corrigir uma avaliação é extenso, representando parcela significativa da carga de trabalho docente. Em contextos com grande número de estudantes, este fator pode comprometer a qualidade e a tempestividade do feedback fornecido.
2. **Consistência avaliativa:** Manter o mesmo padrão de rigor e critérios ao longo de todo o processo de correção constitui desafio considerável. [Barbosa et al. \(2021\)](#) observam que frequentemente o educador não consegue manter o mesmo nível de correção para todos os eventos, o que pode comprometer a equidade do processo avaliativo.
3. **Fadiga do avaliador:** O cansaço acumulado durante longas sessões de correção pode afetar o julgamento e a precisão da avaliação, introduzindo variabilidade indesejada nos resultados.
4. **Custo operacional:** Para instituições educacionais, especialmente em avaliações de larga escala, o processo de correção manual implica custos significativos com recursos humanos e logística. [Pinho, Gaspar e Sassi \(2024\)](#) destacam que, para instituições como escolas de ensino básico e fundamental, universidades e o ENEM, tal atividade demanda tempo e custo para a avaliação dos textos produzidos.
5. **Demora no feedback:** O tempo necessário para a correção manual frequentemente resulta em atraso no retorno aos estudantes, o que pode comprometer o valor pedagógico da avaliação como instrumento de aprendizagem.

6. **Limitações em análises comparativas:** A natureza individualizada da correção manual dificulta análises comparativas amplas e identificação de padrões coletivos de desempenho, elementos valiosos para o planejamento pedagógico.

Estes desafios tornam-se particularmente evidentes em contextos educacionais contemporâneos, caracterizados por turmas numerosas, diversidade de perfis de estudantes e crescente demanda por feedback imediato e personalizado. Conforme observado por [Lima et al. \(2023\)](#), a adaptação forçada pela realidade pandêmica aos professores, embora difícil inicialmente, contribuiu para uma visão clara de como ferramentas tecnológicas podem fornecer maior assistência na prática de suas atividades pedagógicas e de ensino aos alunos.

2.2.3 Impacto da Subjetividade na Avaliação

A subjetividade inerente ao processo de avaliação manual de provas discursivas constitui elemento de particular relevância, com impactos significativos sobre a validade e a confiabilidade dos resultados obtidos. [Barroso, Reis e Amorim \(2021\)](#) investigaram especificamente se a subjetividade pode influenciar a avaliação da aprendizagem, inclusive interferindo na progressão do estudante para séries posteriores, confirmando esta hipótese através de estudos bibliográficos.

Os efeitos de halo, contraste, estereotipia, ordem e fadiga, descritos sob a perspectiva docimológica na [seção 2.1](#), manifestam-se de modo concreto durante a execução da correção manual. Sobre esses efeitos individuais, no contexto específico da prática avaliativa, agregam-se duas dimensões adicionais que envolvem diretamente o instrumento e o ambiente de trabalho:

1. **Interpretação de critérios:** Mesmo quando existem rubricas ou critérios formalizados, sua interpretação pode variar entre avaliadores, resultando em diferenças significativas na atribuição de notas.
2. **Efeitos contextuais:** Fatores como ambiente de correção, pressão de tempo e estado emocional do avaliador podem afetar o processo de julgamento, introduzindo variabilidade adicional nos resultados.

Um estudo recente conduzido por [Heggler, Szmoski e Miquelin \(2025\)](#) sobre as dualidades entre o uso da inteligência artificial na educação e os riscos de vieses algorítmicos destaca que, embora a subjetividade humana seja um desafio reconhecido, é importante considerar que sistemas automatizados também podem incorporar vieses, ainda que de natureza distinta. O autor argumenta que a consciência sobre esses fatores é fundamental

para o desenvolvimento de abordagens avaliativas mais equitativas, sejam elas humanas ou assistidas por tecnologia.

2.2.4 Necessidade de Automação no Processo de Correção

Diante dos desafios e limitações da correção manual de provas discursivas, a automação deste processo emerge como alternativa promissora, especialmente em contextos educacionais contemporâneos. A crescente disponibilidade de tecnologias avançadas de processamento de linguagem natural e inteligência artificial tem viabilizado o desenvolvimento de sistemas capazes de analisar respostas dissertativas com níveis cada vez mais sofisticados de compreensão semântica.

Diversos fatores convergem para justificar a necessidade de automação no processo de correção:

1. **Escala e eficiência:** Em contextos de avaliação em larga escala, como exames nacionais, vestibulares ou cursos com grande número de estudantes, a automação pode proporcionar ganhos significativos de eficiência, reduzindo o tempo necessário para o processamento das respostas e a disponibilização dos resultados.
2. **Padronização de critérios:** Sistemas automatizados tendem a aplicar os mesmos critérios a todas as respostas, reduzindo variações decorrentes de fadiga, ordem de correção ou outros fatores subjetivos que afetam avaliadores humanos.
3. **Feedback imediato:** A automação possibilita a geração de feedback instantâneo aos estudantes, potencializando o valor formativo da avaliação e permitindo intervenções pedagógicas mais tempestivas.
4. **Análise de dados educacionais:** Sistemas automatizados podem gerar dados estruturados sobre o desempenho dos estudantes, facilitando análises comparativas, identificação de padrões e diagnóstico de dificuldades recorrentes, informações valiosas para o planejamento pedagógico.
5. **Complementaridade ao trabalho docente:** A automação não visa substituir o papel do professor, mas oferecer suporte que permita ao educador concentrar-se em aspectos mais qualitativos e personalizados do processo avaliativo.

Conforme destacado por [Lima et al. \(2023\)](#), o aumento na demanda por Educação a Distância e as transformações aceleradas pela pandemia intensificaram a necessidade de ferramentas tecnológicas que possam auxiliar nas atividades pedagógicas e de avaliação. Neste contexto, sistemas automatizados de correção representam não apenas uma resposta

a desafios operacionais, mas também uma oportunidade de repensar e aprimorar os processos avaliativos.

Contudo, é importante ressaltar que a automação da correção de provas discursivas apresenta seus próprios desafios e limitações, relacionados principalmente à capacidade dos sistemas em capturar nuances semânticas, contextualizar adequadamente as respostas e avaliar aspectos qualitativos da argumentação. Estas questões serão abordadas em seções subsequentes, dedicadas às tecnologias de inteligência artificial e processamento de linguagem natural aplicadas à correção automática.

2.3 INTELIGÊNCIA ARTIFICIAL E PROCESSAMENTO DE LINGUAGEM NATURAL

Esta seção apresenta os fundamentos técnicos que sustentam o sistema desenvolvido. Inicialmente, são descritos os conceitos centrais de Inteligência Artificial e seus domínios de aplicação ([subseção 2.3.1](#)). Em seguida, aborda-se o Processamento de Linguagem Natural como subcampo aplicado à compreensão de textos ([subseção 2.3.2](#)). Por fim, discutem-se a arquitetura Transformer e os Modelos de Linguagem de Grande Porte (LLMs), que constituem a base dos agentes corretores implementados neste trabalho ([subseção 2.3.3](#) e [subseção 2.3.4](#)).

2.3.1 Fundamentos de Inteligência Artificial

A IA representa um campo multidisciplinar da ciência da computação dedicado ao desenvolvimento de sistemas capazes de realizar tarefas que, tradicionalmente, demandariam inteligência humana. Estas tarefas incluem reconhecimento de padrões, aprendizado, raciocínio, resolução de problemas, compreensão de linguagem natural e percepção visual, entre outras.

Historicamente, o campo da IA evoluiu através de diferentes paradigmas e abordagens. Desde os primeiros sistemas baseados em regras e lógica simbólica, desenvolvidos nas décadas de 1950 e 1960 ([Russell; Norvig, 2021](#)), até os atuais modelos de aprendizado profundo (*deep learning*), observa-se uma trajetória marcada por avanços significativos, intercalados por períodos de expectativas moderadas, conhecidos como “invernos da IA” ([Torfi et al., 2021](#)).

Os fundamentos conceituais da IA abrangem diversas áreas do conhecimento, incluindo:

1. **Representação do conhecimento:** Métodos para codificar informações de forma

que possam ser processadas por sistemas computacionais.

2. **Algoritmos de busca e otimização:** Técnicas para encontrar soluções eficientes em espaços de possibilidades complexos.
3. **Aprendizado de máquina:** Abordagens que permitem aos sistemas melhorar seu desempenho com base em experiência, sem programação explícita para cada situação.
4. **Raciocínio probabilístico:** Métodos para lidar com incerteza e informações incompletas.
5. **Processamento de linguagem natural:** Técnicas para compreensão, interpretação e geração de linguagem humana.

Nas últimas décadas, o campo da IA experimentou avanços expressivos, impulsionados principalmente pelo aprendizado profundo e técnicas baseadas em Redes Neurais Artificiais (RNA). Conforme destacado por [Young et al. \(2018\)](#), [Otter, Medina e Kalita \(2021\)](#), esses métodos têm superado abordagens tradicionais em diversas aplicações, especialmente em tarefas complexas relacionadas à decisão, classificação e extração de informações.

No contexto educacional, a IA tem encontrado aplicações diversas, desde sistemas tutoriais inteligentes até ferramentas de avaliação automatizada. [Wang et al. \(2024\)](#) destacam que a IA educacional pode ser categorizada com base em seu papel no processo educativo, abrangendo assistência a estudantes e professores, aprendizagem adaptativa e ferramentas comerciais específicas para o ambiente educacional.

2.3.2 PLN

O PLN constitui um subcampo da IA dedicado ao desenvolvimento de métodos e sistemas capazes de compreender, interpretar e gerar linguagem humana em suas diversas formas. Esta área interdisciplinar combina conhecimentos de linguística, ciência da computação, estatística e aprendizado de máquina para abordar a complexidade inerente à comunicação humana.

Conforme observado por [Torfi et al. \(2021\)](#), os avanços em PLN transformaram profundamente o cenário tecnológico nas últimas décadas. Tarefas que anteriormente representavam desafios significativos para sistemas computacionais, como tradução automática, análise de sentimentos, reconhecimento de entidades nomeadas e resposta a perguntas, hoje são realizadas com níveis crescentes de precisão e sofisticação.

O PLN enfrenta diversos desafios fundamentais, decorrentes da natureza complexa e ambígua da linguagem humana:

1. **Ambiguidade lexical e sintática:** Palavras e estruturas frasais podem ter múltiplos significados, dependendo do contexto.
2. **Variações linguísticas:** Diferenças dialetais, gírias, expressões idiomáticas e evolução constante da linguagem.
3. **Inferência pragmática:** Compreensão de significados implícitos, ironia, sarcasmo e outras nuances comunicativas.
4. **Conhecimento de mundo:** Necessidade de informações contextuais e conhecimento geral para interpretação adequada de textos.
5. **Multimodalidade:** Integração entre linguagem e outros modos de comunicação, como gestos, expressões faciais e elementos visuais.

Para abordar estes desafios, o PLN desenvolveu diversas técnicas e abordagens, que evoluíram significativamente ao longo do tempo. Inicialmente baseadas em regras linguísticas explícitas e análise estatística simples, as abordagens contemporâneas de PLN fundamentam-se predominantemente em métodos de aprendizado de máquina, especialmente aprendizado profundo.

No contexto educacional, e particularmente na avaliação de respostas discursivas, o PLN oferece ferramentas valiosas para análise semântica, identificação de conceitos-chave, verificação de coerência argumentativa e avaliação da qualidade textual. Conforme destacado por [Lima et al. \(2023\)](#) em sua revisão sistemática sobre avaliação automática de redação, técnicas avançadas de PLN têm viabilizado sistemas cada vez mais sofisticados de correção automática, capazes de analisar aspectos tanto formais quanto substantivos das produções textuais dos estudantes.

2.3.3 Modelos de Linguagem e Transformers

Um marco decisivo na evolução do PLN foi a introdução da arquitetura Transformer, proposta por [Vaswani et al. \(2017\)](#). Antes dos Transformers, os modelos de linguagem dependiam de arquiteturas recorrentes para processar sequências de texto, o que limitava a paralelização e dificultava a captura de dependências de longo alcance. O avanço central dos Transformers foi substituir a recorrência por mecanismos de *autoatenção* (*self-attention*), que permitem ao modelo ponderar dinamicamente a relevância de cada token da sequência em relação aos demais, independentemente de sua posição. Esse mecanismo viabilizou o processamento paralelo e tornou a arquitetura escalável para modelos com bilhões de parâmetros.

Os Transformers apresentam várias vantagens decorrentes dessa escolha arquitetural:

1. **Paralelização:** Por não depender de processamento sequencial, os Transformers processam todos os tokens simultaneamente, resultando em treinamento mais rápido e escalável.
2. **Atenção multi-cabeça:** Permite ao modelo focar em diferentes aspectos do texto simultaneamente, capturando relações complexas entre palavras e frases em múltiplas representações.
3. **Modelagem bidirecional:** Capacidade de considerar tanto o contexto anterior quanto o posterior de cada palavra, resultando em representações mais ricas e contextualizadas.
4. **Escalabilidade:** A arquitetura pode ser expandida para modelos com bilhões de parâmetros, aproveitando o poder computacional disponível para melhorar o desempenho.

A partir da arquitetura Transformer, surgiram diversos modelos de linguagem de grande porte que transformaram o estado da arte em PLN. Esses modelos são pré-treinados em vastos conjuntos textuais e demonstram capacidades impressionantes em diversas tarefas linguísticas, incluindo compreensão de leitura, inferência textual, resposta a perguntas e geração de texto (Chen et al., 2021). No contexto educacional, os Transformers têm sido aplicados com sucesso em sistemas de tutoria inteligente, avaliação automatizada e geração de feedback personalizado.

Wang et al. (2024), em sua revisão abrangente sobre modelos de linguagem para educação, observam que os Transformers proporcionaram avanços significativos na capacidade dos sistemas em compreender respostas discursivas dos estudantes, avaliar sua qualidade e fornecer feedback contextualizado. Os autores destacam que estas arquiteturas permitem análises mais nuançadas e sensíveis ao contexto, superando limitações de abordagens anteriores baseadas em correspondência de palavras-chave ou estatísticas superficiais.

2.3.4 LLMs e suas Aplicações

Os LLMs representam a culminação dos avanços em arquiteturas Transformer, caracterizando-se por sua escala sem precedentes em termos de parâmetros e dados de treinamento. Modelos como GPT-4o, Claude, Llama 2 e DeepSeek contêm dezenas ou centenas de bilhões de parâmetros e são treinados em vastos conjuntos textuais, abrangendo livros, artigos, websites e outras fontes de conhecimento humano.

Esta escala confere aos LLMs capacidades emergentes notáveis:

1. **Compreensão contextual sofisticada:** Capacidade de interpretar nuances, ambiguidades e referências implícitas em textos complexos.
2. **Versatilidade em múltiplas tarefas:** Habilidade para realizar diversas tarefas linguísticas sem treinamento específico, apenas com instruções em linguagem natural (prompting).
3. **Geração de texto coerente e contextualizado:** Produção de conteúdo textual que mantém consistência temática, estilística e factual ao longo de extensões consideráveis.
4. **Raciocínio em múltiplos passos:** Capacidade de decompor problemas complexos, seguir cadeias de raciocínio e explicar conclusões.

No contexto educacional, os LLMs têm encontrado aplicações diversas e promissoras. Wang et al. (2024) categorizam estas aplicações em três áreas principais: assistência a estudantes, assistência a professores e ferramentas comerciais específicas para a educação.

Na assistência a estudantes, os LLMs podem atuar como tutores personalizados, respondendo a dúvidas, explicando conceitos complexos, fornecendo exemplos ilustrativos e adaptando-se ao nível de conhecimento do aprendiz. Conforme destacado por Seo et al. (2025), em seu estudo sobre LLMs como avaliadores na educação, estes modelos podem fornecer feedback detalhado e construtivo sobre produções textuais dos estudantes, identificando pontos fortes e áreas para melhoria.

Na assistência a professores, os LLMs podem auxiliar na preparação de materiais didáticos, geração de questões para avaliação, correção automatizada de atividades e análise de padrões de desempenho dos estudantes. Beckford (2024) destaca o potencial destes modelos para reduzir a carga administrativa dos educadores, permitindo que dediquem mais tempo a interações pedagógicas significativas.

Especificamente na correção automática de provas discursivas, os LLMs oferecem vantagens significativas em relação a abordagens anteriores:

1. **Compreensão semântica profunda:** Capacidade de entender o significado das respostas além de correspondências lexicais superficiais.
2. **Avaliação holística:** Habilidade para considerar simultaneamente múltiplos aspectos da resposta, como precisão factual, coerência argumentativa, estrutura textual e adequação linguística.
3. **Feedback contextualizado:** Possibilidade de gerar comentários específicos e construtivos, identificando pontos fortes e sugerindo melhorias.

4. **Adaptabilidade a diferentes disciplinas:** Versatilidade para avaliar respostas em diversos domínios do conhecimento, desde ciências exatas até humanidades.

Contudo, como observado por [Hegglar, Szmoski e Miquelin \(2025\)](#) os LLMs também apresentam desafios e limitações importantes, incluindo potenciais vieses incorporados durante o treinamento, tendência a "alucinações" (geração de informações incorretas com aparência de confiabilidade) e questões de privacidade e segurança. Estas considerações serão abordadas em seções subsequentes, dedicadas aos desafios e limitações dos sistemas atuais.

2.4 ARQUITETURAS DE AGENTES DE IA E ESTRATÉGIAS DE COORDENAÇÃO

Esta seção descreve as arquiteturas e estratégias que organizam o comportamento dos agentes de IA no sistema desenvolvido. Parte-se do conceito de agente baseado em LLM e seus componentes fundamentais, avançando para a coordenação entre múltiplos agentes em sistemas multiagentes. Em seguida, são apresentadas as técnicas de engenharia de prompt aplicadas aos agentes corretores e a estratégia de RAG, que fundamenta o uso de materiais didáticos como contexto para a avaliação.

2.4.1 Agentes de IA

A concepção tradicional de agentes inteligentes, caracterizados por autonomia, reatividade, pró-atividade e sociabilidade em um ambiente ([Wooldridge, 2012](#)), ganhou uma nova dimensão com a implantação de LLMs. Os LLMs, como o GPT-4o, DeepSeek e outros, com suas vastas capacidades de compreensão e geração de linguagem natural, raciocínio e até mesmo planejamento rudimentar, tornaram-se a espinha dorsal de uma nova geração de agentes autônomos ([Wang et al., 2025](#); [Xi et al., 2023](#)).

Agentes baseados em LLMs (*LLM-based agents*) são sistemas que utilizam um LLM como seu componente central de processamento ou "cérebro" para realizar tarefas complexas que exigem planejamento, tomada de decisão e interação com o ambiente, que pode incluir software, ferramentas digitais ou até o mundo físico ([Wang et al., 2025](#)). Diferentemente de agentes simbólicos clássicos, cujo comportamento é explicitamente programado, os agentes baseados em LLMs aproveitam o conhecimento implícito e as capacidades de raciocínio do modelo pré-treinado, guiados por prompts cuidadosamente elaborados (engenharia de prompt) para definir seus objetivos, capacidades e restrições.

[Wang et al. \(2025\)](#) propõem um *framework* conceitual para a construção desses agentes, destacando quatro componentes principais:

1. **Perfil (*Profile*):** Define o papel e as características essenciais do agente (ex: "Você é um assistente de correção de provas..."). Isso molda a identidade e o comportamento esperado do agente.
2. **Memória (*Memory*):** Armazena informações passadas (interações, observações, resultados de ações) para permitir aprendizado contextual e consistência ao longo do tempo. A memória pode ser de curto prazo (contexto da janela do prompt) ou de longo prazo (armazenada e recuperada de bancos de dados externos).
3. **Planejamento (*Planning*):** Envolve a decomposição de tarefas complexas em subtarefas menores e gerenciáveis. O agente pode refletir sobre suas ações passadas e planejar os próximos passos para atingir seu objetivo final.
4. **Ação (*Action*):** Executa as subtarefas planejadas, interagindo com o ambiente. Isso pode envolver o uso de ferramentas externas (APIs, motores de busca, calculadoras), a geração de código ou a produção de texto.

A interação entre esses componentes permite que o agente perceba seu ambiente (através de prompts ou ferramentas), raciocine sobre o estado atual e seus objetivos (usando o LLM), planeje uma sequência de ações e execute essas ações, aprendendo e adaptando-se com base nos resultados. No contexto da correção automática de provas discursivas, um agente baseado em LLM poderia receber a resposta do aluno, acessar critérios de avaliação (memória/ferramenta), planejar os passos da correção (verificar conceitos, avaliar argumentação, etc.), executar a avaliação (ação, usando o LLM para análise e geração de feedback) e registrar o resultado (memória).

2.4.2 Sistema de Multi Agentes

A colaboração entre múltiplos agentes para resolver problemas complexos é o foco dos Sistemas Multiagentes (SMA). Tradicionalmente, a coordenação em SMAs dependia de protocolos de comunicação e mecanismos de negociação predefinidos. No entanto, a integração de LLMs como componentes centrais dos agentes abriu novas possibilidades e desafios para a construção e operação de SMAs (Chen et al., 2025; Yan et al., 2025).

SMAs baseados em LLMs (*LLM-based MAS*) utilizam LLMs não apenas para as capacidades individuais de cada agente (raciocínio, planejamento, ação), mas também para facilitar a interação e a colaboração entre eles. A capacidade dos LLMs de compreender e gerar linguagem natural permite formas de comunicação mais flexíveis e sofisticadas entre os agentes, potencialmente superando a rigidez dos protocolos de comunicação tradicionais (Chen et al., 2025).

As principais abordagens e características dos SMAs baseados em LLMs incluem:

1. **Comunicação Aprimorada por LLM:** Os agentes podem usar linguagem natural para se comunicar, negociar tarefas, compartilhar informações e coordenar ações. O LLM pode interpretar mensagens recebidas e gerar respostas apropriadas no contexto da interação (Yan et al., 2025).
2. **Atribuição Dinâmica de Papéis e Tarefas:** Um LLM central ou os próprios agentes podem analisar um problema complexo e atribuir dinamicamente papéis e subtarefas a diferentes agentes com base em seus perfis e capacidades (Wang et al., 2025).
3. **Colaboração em Resolução de Problemas:** Múltiplos agentes podem trabalhar juntos em tarefas como escrita colaborativa, debate, brainstorming ou desenvolvimento de software. Cada agente contribui com sua perspectiva ou habilidade específica, e o LLM pode ajudar a sintetizar as contribuições ou a mediar discussões (Qian et al., 2024).

A arquitetura desses sistemas pode variar. Alguns utilizam um LLM centralizado que orquestra a comunicação e a colaboração, enquanto outros adotam abordagens mais descentralizadas, onde cada agente possui seu próprio LLM ou acessa um modelo compartilhado (Chen et al., 2025). A engenharia de prompt desempenha um papel crucial na definição dos papéis dos agentes, das regras de interação e dos objetivos coletivos.

No contexto da correção automática de provas, um SMA baseado em LLMs pode envolver múltiplos agentes especializados (ex: agente de análise de conteúdo, agente de verificação gramatical, agente de avaliação de argumentação) que se comunicam (possivelmente via linguagem natural interpretada por LLMs) para chegar a uma avaliação consensual e gerar um feedback abrangente, simulando um processo de revisão por pares ou uma banca avaliadora.

No protótipo desenvolvido neste trabalho, essa ideia é aplicada por meio de uma estratégia de consenso 2→1: dois corretores independentes (C1 e C2) avaliam inicialmente a mesma resposta e, apenas quando há divergência acima de um limiar definido, um terceiro corretor (Corretor 3) atua condicionalmente para resolver a discordância. Assim, o sistema combina paralelismo na avaliação inicial com arbitragem condicional, reduzindo custo computacional em casos de convergência e aumentando a robustez quando há discordância.

2.4.3 Engenharia de Prompt

A Engenharia de Prompt emergiu como uma disciplina fundamental para interagir eficazmente com LLMs. Em vez de re-treinar ou ajustar finamente os modelos para cada tarefa específica, a engenharia de prompt foca na formulação cuidadosa das instruções (prompts) fornecidas ao LLM para eliciar o comportamento desejado (Sahoo et al., 2025).

Um prompt, no contexto de LLMs, é mais do que uma simples pergunta; é uma instrução que pode incluir contexto, exemplos (few-shot learning), e especificações sobre o formato ou estilo da saída desejada. A qualidade do prompt influencia diretamente a qualidade da resposta gerada pelo LLM (Liu et al., 2023 apud Sahoo et al., 2025).

No contexto do presente trabalho, quatro técnicas de engenharia de prompt foram empregadas de forma complementar nos agentes corretores (Sahoo et al., 2025):

1. **Prompting Zero-Shot e Few-Shot:** No *zero-shot*, o prompt contém apenas a instrução, sem exemplos; no *few-shot*, demonstrações ilustrativas são incluídas para orientar o comportamento do modelo (Sahoo et al., 2025). Uma limitação do *few-shot* manual é a sensibilidade à escolha e à ordem dos exemplos, o que pode introduzir variabilidade no desempenho. Para mitigar esse problema, o módulo `BootstrapFewShot` do DSPy adota uma abordagem de otimização automática: executa o pipeline sobre um conjunto de dados de treinamento, coleta as execuções bem-sucedidas e as incorpora automaticamente ao prompt como demonstrações, refinando iterativamente as instruções para maximizar uma métrica de desempenho definida pelo desenvolvedor (DSPy Contributors, 2026). No presente trabalho, o DSPy com `BootstrapFewShot` foi empregado como ferramenta auxiliar de otimização *offline* dos prompts dos agentes corretores, separado do fluxo de inferência em produção.
2. **Chain-of-Thought (Chain-of-Thought (CoT)):** Instrui o modelo a desenvolver um raciocínio passo a passo antes de produzir a resposta final, tornando o processo de decisão explícito e auditável (Wei et al., 2023). No sistema desenvolvido, os agentes corretores são orientados a analisar cada critério da rubrica individualmente, registrando a pontuação parcial ao final de cada etapa; esse raciocínio é armazenado no campo `reasoning_chain` da saída estruturada, permitindo rastreabilidade completa da avaliação.
3. **Role Prompting:** Consiste em atribuir ao modelo uma identidade ou especialização por meio do prompt de sistema, delimitando o escopo de atuação esperado e direcionando o tom, o vocabulário e os critérios de julgamento da resposta gerada (Sahoo et al., 2025). No protótipo, os Corretores 1 e 2 recebem o papel de especialista em avaliação educacional, enquanto o Árbitro é instruído como revisor sênior, o que orienta cada agente a adotar postura e critérios condizentes com sua função no pipeline.
4. **Groundedness (fidelidade ao contexto recuperado):** Orienta o modelo a ancorar suas avaliações nas informações fornecidas pelo contexto RAG, priorizando terminologia e conceitos presentes no material didático recuperado como referência

para validar a resposta do aluno (Gao et al., 2024). No sistema, os agentes são instruídos a utilizar os trechos recuperados como base principal de verificação conceitual, admitindo, contudo, flexibilidade pedagógica: respostas tecnicamente corretas que empreguem terminologia distinta do material, mas demonstrem compreensão conceitual genuína, são consideradas válidas.

A combinação dessas técnicas visa tornar o processo de correção automatizada mais estruturado, rastreável e alinhado aos critérios pedagógicos definidos pelo professor, sem abrir mão da flexibilidade necessária para reconhecer respostas conceitualmente corretas mesmo quando formuladas de maneira diversa do material de referência.

2.4.4 RAG

Os LLMs, apesar de suas notáveis capacidades generativas, enfrentam desafios intrínsecos, como a propensão a gerar informações factualmente incorretas ("alucinações") e a limitação de seu conhecimento ao corpus de treinamento, que rapidamente se torna desatualizado (Gao et al., 2024). A RAG surge como uma arquitetura robusta para mitigar essas limitações, integrando dinamicamente conhecimento de fontes externas e atualizadas ao processo de geração do LLM (Lewis et al., 2021; Gao et al., 2024).

A RAG aprimora os LLMs ao fundamentar suas respostas em informações relevantes recuperadas de uma base de conhecimento externa (documentos, artigos, bases de dados). O processo central da RAG, conforme descrito por Gao et al. (2024), pode ser dividido em etapas fundamentais, com a fase de recuperação sendo crucial e dependente de representações semânticas conhecidas como *embeddings*.

1. **Indexação (*Indexing*):** A base de conhecimento externa (ex: material didático, artigos científicos, gabaritos) é primeiramente processada. Os documentos são segmentados em trechos menores (*chunks*). Em seguida, um modelo de *embedding* (como Sentence-BERT, SimCSE, ou modelos via APIs como os da OpenAI) é utilizado para converter cada trecho de texto em um vetor numérico de alta dimensionalidade (*embedding*). Esses *embeddings* capturam a essência semântica do texto, de modo que trechos com significados similares possuam vetores próximos no espaço vetorial. Esses vetores, juntamente com os textos originais, são armazenados e indexados em um banco de dados vetorial (ex: FAISS, Milvus, Pinecone), otimizado para buscas rápidas de similaridade (Gao et al., 2024; Khattab; Zaharia, 2020).
2. **Recuperação (*Retrieval*):** Quando o usuário envia uma consulta (prompt), ela também é convertida em um *embedding* vetorial usando o mesmo modelo de *embedding*. Este vetor da consulta é então usado para pesquisar no banco de dados

vetorial os *embeddings* dos trechos de texto que são semanticamente mais similares à consulta. A similaridade de cosseno é uma métrica comum para medir a proximidade entre os vetores. Os ‘k’ trechos mais relevantes (*top-k retrieval*) são selecionados (Gao et al., 2024; Gao et al., 2022).

3. **Geração (*Generation*):** Os trechos de texto recuperados, que contêm informações relevantes e potencialmente atualizadas, são então combinados com o prompt original do usuário. Este prompt aumentado é fornecido ao LLM. O LLM utiliza tanto seu conhecimento interno quanto o contexto adicional fornecido pelos trechos recuperados para gerar uma resposta final mais precisa, factual, detalhada e rastreável, pois pode (e idealmente deve) citar as fontes recuperadas (Gao et al., 2024; Ram et al., 2023).

No contexto da correção automática de provas discursivas, a RAG permite que o agente de IA “consulte” materiais específicos do curso, critérios de avaliação detalhados ou exemplos de respostas modelo (previamente indexados como *embeddings*) antes de avaliar a resposta do aluno. Essa estratégia pode ajudar a fundamentar a correção no contexto específico da disciplina e nos critérios do professor, tendendo a aumentar a consistência e a explicabilidade da avaliação gerada pelo LLM.

Com os fundamentos teóricos apresentados neste capítulo — avaliação educacional, técnicas de PLN, arquitetura Transformer, modelos de linguagem de grande porte, sistemas multiagentes, engenharia de *prompts* e RAG — estabelece-se a base conceitual necessária para compreender as decisões de projeto e implementação detalhadas nos capítulos seguintes.

3 TRABALHOS RELACIONADOS

Este capítulo apresenta uma revisão da literatura existente relacionada ao uso de IA, especialmente LLMs e RAG, para a correção automática de provas discursivas. O objetivo é identificar padrões, métodos, desafios e lacunas em pesquisas que envolvem a aplicação dessas técnicas avançadas de IA na avaliação educacional automatizada, com foco na análise e feedback de respostas discursivas. Além disso, busca-se compreender como esses modelos estão sendo desenvolvidos e aplicados em diversos contextos educacionais para aprimorar a eficiência e a qualidade do processo avaliativo.

3.1 PROTOCOLO DE PESQUISA

Esta seção descreve o protocolo metodológico adotado no mapeamento sistemático da literatura, detalhando os objetivos e questões de pesquisa que orientaram a busca, a estratégia de recuperação dos estudos, os critérios de inclusão e exclusão aplicados e os procedimentos seguidos para seleção e análise dos trabalhos.

3.1.1 Questões de pesquisa

A partir do objetivo apresentado na abertura deste capítulo, foram formuladas as seguintes questões de pesquisa, que orientaram a estratégia de busca e os critérios de seleção aplicados ao mapeamento:

1. **QP1:** Quais são as abordagens e técnicas de IA (especialmente LLMs e PLN) mais utilizadas para a correção automática de provas discursivas no contexto educacional?
2. **QP1.1** - Quais são os principais desafios, limitações e vantagens da utilização de sistemas de correção automática de provas discursivas em comparação com a correção manual, especialmente em relação à consistência, subjetividade e feedback ao aluno?
3. **QP1.2** - Como a integração de mecanismos como RAG e bancos de dados vetoriais tem sido explorada para melhorar a precisão e a contextualização na correção automática de provas?
4. **QP1.3** - Quais são as arquiteturas de sistemas (incluindo sistemas multiagentes) propostas para a correção automática de provas e como elas lidam com a configuração de critérios de avaliação e a intervenção do professor?

5. **QP1.4** - Quais são os resultados (*outcomes*) reportados na literatura sobre a eficácia, eficiência e aceitação de ferramentas de correção automática de provas por educadores e alunos?

3.1.2 Estratégia de pesquisa e instrumentos

A principal fonte de dados definida para a busca foi a base Scopus, reconhecida por sua ampla cobertura de literatura científica revisada por pares. Reconhece-se como limitação metodológica a utilização de uma base única; o emprego complementar de bases como Web of Science, IEEE Xplore ou ACM Digital Library poderia ampliar a cobertura. A escolha pela Scopus deveu-se à sua abrangência multidisciplinar e à disponibilidade de acesso institucional, e o número reduzido de estudos resultantes (7 de 12 iniciais) reflete a recência do tema — a aplicação de LLMs à avaliação discursiva é uma área de pesquisa emergente.

O *framework* População, Intervenção, Comparação, Outcome e Contexto (PICOC) é uma metodologia amplamente utilizada em revisões sistemáticas para estruturar e guiar a formulação da questão de pesquisa (Kitchenham; Charters, 2007). O acrônimo representa cinco componentes essenciais: População/Problema, Intervenção, Comparação, *Outcome* (resultado) e Contexto, garantindo que a busca por literatura seja ao mesmo tempo abrangente e focada nos aspectos mais relevantes do estudo.

A string de busca foi construída utilizando o *framework* PICOC (Kitchenham; Charters, 2007) (População/Problema, Intervenção, Comparação, *Outcome*, Contexto) para garantir a abrangência e especificidade na recuperação dos artigos. As palavras-chave em inglês foram priorizadas para maximizar o alcance em bases de dados internacionais, apesar de manter as palavras em português.

O [Quadro 1](#) abaixo mostra as principais palavras-chave selecionadas para cada um dos elementos do modelo PICOC adotado neste trabalho.

Quadro 1 – Elementos PICOC e suas palavras-chave

Elemento	Palavras-chave
P	"correção de provas discursivas", "automated essay scoring", "automatic essay grading", "avaliação educacional automatizada", "automated educational assessment", "feedback automatizado", "automated feedback", "correção de testes discursivos", "discursive tests correction", "avaliação de questões abertas", "open-ended question assessment"
I	"Inteligência Artificial", "Artificial Intelligence", "Modelos de Linguagem de Grande Escala", "Large Language Models", "LLMs", "Processamento de Linguagem Natural", "PLN", "NLP", "Recuperação Aumentada por Geração", "Retrieval-Augmented Generation", "RAG", "bancos de dados vetoriais", "vector databases", "agentes de IA", "AI agents", "sistemas multiagentes", "multi-agent systems"
C (<i>comparação</i>)	Correção manual por docentes; abordagens tradicionais de AES sem LLM
O	"precisão da correção", "grading accuracy", "acurácia da avaliação", "assessment accuracy", "eficiência", "efficiency", "consistência da avaliação", "assessment consistency", "qualidade do feedback", "feedback quality", "métricas de avaliação", "evaluation metrics", "aceitação por usuários", "user acceptance", "desempenho do sistema", "system performance"
C (<i>contexto</i>)	Ensino superior e educação profissional; avaliação de respostas discursivas

Fonte: Elaborado pelos autores.

Os artigos retornados pelas máquinas de busca foram filtrados e analisados considerando os seguintes critérios de inclusão (CI) e exclusão (CE), definidos com base nas diretrizes de [Kitchenham e Charters \(2007\)](#).

- **CI1 - Relevância Temática:** Estudos que abordem diretamente a aplicação de IA, Modelos de LLMs, PLN, RAG, bancos de dados vetoriais, agentes de IA ou sistemas multiagentes para a correção automática, avaliação ou feedback de provas discursivas, questões abertas ou textos dissertativos em contextos educacionais.
- **CI2 - Tipo de Publicação:** Artigos científicos publicados em periódicos revisados por pares, anais de conferências de relevância (com revisão por pares), dissertações e teses.
- **CI3 - Idioma:** Trabalhos publicados em inglês ou português.
- **CI4 - Período de Publicação:** Trabalhos publicados a partir de 2020, inclusive. Este marco temporal foi escolhido devido ao crescimento exponencial e aos avanços significativos na capacidade e disponibilidade de LLMs a partir deste período, o que impactou diretamente as pesquisas na área de correção automática.

- **CI5 - Acesso ao Texto Completo:** Estudos cujo texto completo esteja diretamente acessível para análise.
- **CE1 - Irrelevância Temática:** Estudos que não se concentrem primariamente na correção/avaliação automática de textos discursivos utilizando as tecnologias de IA especificadas (por exemplo, estudos focados apenas em questões de múltipla escolha, avaliação de código de programação sem foco discursivo, ou uso de IA em educação para outros fins que não a avaliação de textos).
- **CE2 - Tipo de Publicação:** Resumos, editoriais, cartas ao editor, livros (como um todo, embora capítulos específicos possam ser considerados se atenderem aos outros critérios como estudos originais), patentes, relatórios técnicos não revisados por pares, artigos de opinião, ou publicações em blogs e websites não acadêmicos.
- **CE3 - Idioma:** Trabalhos publicados em idiomas diferentes de inglês ou português.
- **CE4 - Período de Publicação:** Trabalhos publicados antes de 2020.
- **CE5 - Acesso ao Texto Completo:** Estudos cujo texto completo não pôde ser obtido por acesso direto.
- **CE6 - Duplicatas:** Estudos que sejam publicações duplicadas do mesmo trabalho (será mantida a versão mais completa ou a publicada na fonte de maior impacto/relevância).

3.1.3 Procedimentos da Revisão Sistemática da Literatura

O processo de revisão sistemática da literatura adotado neste trabalho seguiu as etapas metodológicas descritas abaixo, visando assegurar um levantamento abrangente, transparente e replicável dos trabalhos relevantes para responder às questões de pesquisa formuladas.

1. **Definição das Questões de Pesquisa:** Conforme detalhado na [subseção 3.1.1](#), foram estabelecidas questões de pesquisa claras e específicas. Estas questões nortearam toda a estratégia de busca e seleção de estudos, focando em identificar as abordagens de IA, especialmente LLMs e RAG, aplicadas à correção automática de provas discursivas, bem como os desafios, métricas e oportunidades na área.
2. **Elaboração da Estratégia de Busca:** Utilizando o *framework* PICOC ([Kitcheham; Charters, 2007](#)) (População/Problema, Intervenção, Comparação, Resultados e Contexto) como guia, foi desenvolvida uma estratégia de busca detalhada. Foram selecionadas palavras-chave e termos de busca em inglês e português, cobrindo os principais conceitos relacionados à correção automática de provas, IA, LLMs,

RAG, avaliação educacional e contextos de aplicação. A string de busca foi refinada iterativamente para otimizar a sensibilidade e especificidade dos resultados.

3. **Seleção das Bases de Dados e Execução da Busca:** Busca nas bases de dados selecionadas, aplicando os filtros de idioma e período de publicação.
4. **Seleção Inicial dos Estudos:** Os resultados das buscas foram avaliados inicialmente pelos títulos e resumos para excluir estudos claramente irrelevantes ou que não atendessem aos critérios básicos de inclusão (tipo de publicação, idioma).
5. **Análise dos Textos Completos e Extração de Dados:** Os estudos pré-selecionados tiveram seus textos completos lidos para confirmar sua elegibilidade, aplicando-se rigorosamente todos os critérios de inclusão e exclusão. Dos estudos elegíveis, foram extraídas informações sistematicamente utilizando uma planilha eletrônica, contemplando dados bibliográficos, objetivos, metodologia, contexto da aplicação, tecnologias de IA (LLMs, RAG, agentes), tipos de avaliação, métricas de desempenho, principais resultados, desafios, contribuições e sugestões para pesquisas futuras.
6. **Síntese e Análise Qualitativa dos Resultados:** Os dados extraídos foram compilados e organizados para identificar padrões e tendências. Realizou-se uma análise qualitativa, agrupando estudos por temas emergentes e sintetizando narrativamente os achados para responder a cada questão de pesquisa, destacando contribuições, lacunas e limitações, com uso de tabelas/figuras quando apropriado.

3.2 CARACTERIZAÇÃO DA PESQUISA

Aplicando o protocolo descrito na seção anterior, realizou-se uma busca na base Scopus por trabalhos publicados a partir de 2020, em inglês ou português, relacionados ao uso de IA para correção ou avaliação de textos discursivos em contextos educacionais. Foram considerados estudos revisados por pares (artigos de periódicos, anais de conferências) e literatura acadêmica (dissertações e teses). Da busca inicial, identificaram-se 12 publicações; após triagem por título e resumo com aplicação dos critérios de inclusão e exclusão, 7 estudos foram selecionados para leitura completa e extração de dados.

O [Quadro 2](#) apresenta os 7 estudos analisados, com objetivos, metodologia, tecnologias de IA, tipo de avaliação, principais resultados e desafios.

Quadro 2 – Características dos estudos incluídos

E	Autores	Objetivos e Contexto	Metodologia	Tecnologias de IA	Tipo de Avaliação e Métricas	Principais Resultados e Desafios
E1	Janumpally	Mapear aplicações de PLN/LLM na formação médica de residentes	Revisão de escopo (PRISMA); 20 estudos (2018–2024)	Técnicas de PLN e LLMs diversas	Avaliação de desempenho; análise de sentimento; métricas de acurácia	Redução de carga, melhora de consistência; riscos de viés e privacidade
E2	Li; Liu	Avaliar LLMs em correção de redações de japonês L2	Experimento comparativo com 1 400 textos; 5 abordagens	GPT-4, BERT, ferramentas tradicionais	Notas e proficiência; acurácia de anotação	GPT-4 superior; dependência de engenharia de prompt
E3	Xiao et al.	Sistema colaborativo Humano-IA para pontuação de ensaios em inglês L2	Experimentos com GPT-4/GPT-3.5 afinado; co-avaliação com professores	GPT-4, GPT-3.5 <i>fine-tuned</i>	Notas e <i>feedback</i> ; consistência e interpretabilidade	Melhora de avaliadores; necessidade de ampliar amostra
E4	Hutt et al.	IA para avaliar qualidade de <i>feedback</i> entre pares	Comparativo: modelo clássico versus LLM generativo	Modelo ML clássico; LLM generativo	Classificação da qualidade do <i>feedback</i> ; acurácia	ML tradicional um pouco melhor; LLM gera explicações ricas
E5	Avcu	Revisão de modelos hierárquicos de avaliadores (HRMs) em Automated Essay Scoring (AES)	Revisão de escopo sobre HRMs e PLN	HRMs integrados com PLN/IA	Consistência interavaliador; viés de correção	Mitigação de vieses; alta complexidade computacional
E6	Fiki Setiawan; Annas Alkhowarizmi	Ferramentas de IA no <i>feedback</i> de escrita em inglês EFL	Estudo descritivo: Grammarly, QuillBot, Ginger	Ferramentas de PLN (Grammarly, QuillBot, Ginger)	Detecção de erros; qualidade das sugestões	Eficácia e dependência; uso como complemento

Quadro 2 – (continuação)

E	Autores	Objetivos e Contexto	Metodologia	Tecnologias de IA	Tipo de Avaliação e Métricas	Principais Resultados e Desafios
E7	Kitzie et al.	Painel sobre IA para apoiar doutorandos	Relato de painel com experientes e novatos	ChatGPT, Otter.ai, tradutores, etc.	Assistência em pesquisa e redação; produtividade	Maior eficiência; desafios de integridade acadêmica

Fonte: Elaborado pelos autores.

3.3 RESULTADOS E DISCUSSÕES

A análise dos estudos selecionados revela tendências convergentes, que agrupamos em três eixos principais:

1. Aplicação de LLMs e outras IA para avaliação automatizada de textos discursivos (especialmente redações);
2. Uso de IA para geração e avaliação de feedback em contexto educacional;
3. Principais desafios e considerações na implementação dessas tecnologias em ambientes de aprendizagem.

As seções [subseção 3.3.1](#), [subseção 3.3.2](#) e [subseção 3.3.3](#) a seguir, sintetizam os achados de acordo com esses temas.

Para evitar sobreposição entre estado da arte e implementação, as discussões desta seção descrevem capacidades reportadas na literatura e não devem ser interpretadas, automaticamente, como funcionalidades já presentes no protótipo desenvolvido neste trabalho.

3.3.1 LLMs e Avaliação Automatizada de Redações

Vários trabalhos exploram como modelos de LLMs e outras abordagens de IA estão sendo empregados para atribuir notas automáticas a textos escritos por alunos. No estudo experimental de [Li e Liu \(2024\)](#) (E2), por exemplo, a aplicação de LLMs no AES mostrou-se promissora: o GPT-4 ultrapassou métodos tradicionais na correção de redações em japonês como L2. Esse LLM obteve maior exatidão na anotação das redações e melhor capacidade de estimar o nível de proficiência do aluno, evidenciando o potencial

dos modelos generativos de última geração em avaliações escritas. Por outro lado, os autores ressaltam que a eficácia dos LLMs depende fortemente de *prompts* bem elaborados, visto que estratégias de *prompting* diferentes resultaram em qualidade variável da avaliação automática. Assim, otimizar as instruções dadas ao modelo (*prompt engineering*) desponta como fator crítico para obter avaliações confiáveis, alinhado à recomendação dos autores de explorar técnicas de *prompt* mais avançadas e testar LLMs em outras modalidades de linguagem (como avaliação de fala).

No trabalho de [Xiao et al. \(2025\)](#) (E3), que foca em redações de inglês L2, os LLMs (GPT-4 e GPT-3.5) foram incorporados em um sistema colaborativo de correção. Embora versões anteriores do estudo tenham indicado que LLMs puros não superavam todos os modelos tradicionais em métricas de desempenho, na versão final percebeu-se que um GPT-3.5 ajustado conseguiu igualar ou exceder a acurácia de modelos clássicos especializados. Mais notável, porém, foi o ganho em consistência e capacidade de explicação: as notas atribuídas pelos LLMs apresentaram menor variabilidade indesejada e vieram acompanhadas de feedback textual interpretável, algo que métodos tradicionais geralmente não fornecem. Além disso, os experimentos do autor demonstraram que LLMs podem aumentar a eficiência de avaliadores humanos, servindo como apoio (*augmented grading*), os professores menos experientes conseguiram avaliar textos com qualidade próxima à de especialistas ao utilizar sugestões e justificativas geradas pela IA. Esses achados reforçam a ideia de que, para avaliação de redações, a sinergia entre IA e humanos pode produzir melhores resultados do que cada um isoladamente: a IA confere rapidez, padronização e abrangência, enquanto o humano aporta julgamento pedagógico e senso crítico.

Um aspecto transversal aos estudos de AES é a preocupação com equidade e robustez das notas automatizadas. A revisão de [Avcu \(2025\)](#) (E5) contribui aqui ao discutir HRMs integrados à IA. Esses modelos matemáticos visam replicar o processo de um avaliador humano, capturando vieses e variâncias, e incorporá-los no sistema automático para minimizar injustiças. A revisão aponta que combinar técnicas de PLN com HRMs mitiga vieses de correção e melhora a confiabilidade das pontuações. Em outras palavras, algoritmos de correção de redações podem se tornar mais justos ao ajustar automaticamente as notas considerando, por exemplo, a tendência de um professor ser “mão dura” ou “leniente” demais, equilibrando assim a avaliação. Este enfoque complementa o uso de LLMs: enquanto estes trazem poder de compreensão semântica em larga escala, HRMs trazem o arcabouço estatístico para tratar consistência e fairness. A revisão de [Janumpally \(2025\)](#) (E1), embora focada em educação médica, também identificou sistemas automatizados de avaliação de desempenho como uma das principais aplicações do PLN/IA na educação, ressaltando ganhos de acurácia e redução de carga dos instrutores. Em suma, o conjunto dos estudos sugere que, em determinados contextos, modelos de IA podem produzir avaliações que se aproximam das avaliações humanas, desde que bem

configurados, e oferecem oportunidades de tratar aspectos problemáticos (como viés e inconsistência) por meio de abordagens híbridas (IA + modelos estatísticos + supervisão humana).

3.3.2 IA na Geração e Avaliação de Feedback Educacional

Outro tema recorrente é o emprego da IA para fornecer feedback automatizado aos alunos, bem como para avaliar a qualidade do feedback que alunos produzem. Essa linha aparece tanto em estudos experimentais quanto em contextos de uso real de ferramentas.

No feedback ao estudante sobre sua escrita, o estudo de [Fiki Setiawan e Annas Alkhowarizmi \(2025\)](#) (E6) avaliou três ferramentas amplamente disponíveis. Os resultados mostram que essas IA conseguem identificar e sugerir correções para uma variedade de problemas em textos estudantis, de erros gramaticais a construções confusas. O Grammarly, em particular, destacou-se por sua precisão gramatical, cobrindo grande parte dos erros de forma confiável. Já o QuillBot demonstrou uma função valiosa de reformulações (paráfrases), ajudando os alunos a melhorarem a clareza e variedade de vocabulário. A ferramenta Ginger, por outro lado, ficou aquém das demais, oferecendo feedback mais superficial. Um achado importante foi que os alunos aprimoraram aspectos de sua escrita (especialmente gramática) e se sentiram mais motivados ao utilizar essas ferramentas, mas simultaneamente desenvolveram certa dependência, confiando nas sugestões a ponto de não as revisar criticamente ou não se arriscarem em construções próprias. Os autores propõem, então, uma integração equilibrada: utilizar o feedback automatizado como complemento ao feedback humano. Por exemplo, o aluno pode primeiro passar o texto no Grammarly para corrigir erros básicos e, em seguida, submeter a versão revisada ao professor ou colegas para comentários mais aprofundados. Essa abordagem combinada tira proveito do feedback imediato e personalizado que a IA oferece, sem abrir mão da orientação pedagógica humana e do estímulo ao pensamento crítico do aluno.

Quanto ao feedback que o próprio aluno fornece em atividades de *peer review* (avaliação por pares), o estudo de [Hutt et al. \(2024\)](#) (E4) introduz a IA como “avaliadora de avaliadores”. A ideia é usar modelos para examinar se um comentário de aluno para seu colega é útil, específico, construtivo, etc.. Nesse cenário, comparou-se um algoritmo tradicional de classificação de texto com um LLM. Os resultados indicaram que o método tradicional foi ligeiramente mais preciso em julgar a qualidade do feedback, possivelmente por ter sido treinado diretamente nos critérios de qualidade desejados. Entretanto, o LLM pôde produzir análises mais detalhadas em linguagem natural, por exemplo explicando quais aspectos do feedback do aluno estão bons ou precisam melhorar. Essa capacidade de gerar explicações sugere um valor pedagógico: a ferramenta de IA não apenas atribuiria uma nota ou categoria ao feedback do aluno, mas também daria um retorno a ele sobre seu comentário, fechando um ciclo de meta-feedback (“feedback sobre o feedback”). Na

prática, isso poderia ajudar estudantes a se tornarem revisores melhores ao longo do tempo. A ressalva observada foi que os LLMs, se não devidamente alinhados, podem às vezes se desviar das diretrizes (instruções) ao produzir essas avaliações textuais, por exemplo, podendo elogiar excessivamente ou criticar de forma não estruturada, fugindo dos critérios específicos da tarefa. Apesar disso, o estudo sinaliza que unir a acurácia das técnicas tradicionais com a riqueza das explicações geradas por IA tende a ser uma solução muito eficaz. Uma possibilidade mencionada seria usar o modelo clássico para decidir a classificação do feedback (p.ex. “ótimo, bom, razoável, fraco”) e o LLM para gerar uma justificativa comentada para o aluno.

De forma geral, os estudos concordam que a IA expandiu as possibilidades de feedback educacional em termos de escala e imediatez. Ferramentas como chatbots ou LLMs podem dar retorno instantâneo a um grande número de alunos, algo difícil apenas com pessoal humano. Além disso, conseguem adaptar o feedback ao conteúdo específico de cada texto (diferente de correções fixas), atuando quase como “tutores virtuais” disponíveis 24 horas. Entretanto, a qualidade pedagógica desse feedback automatizado ainda exige validação e acompanhamento. A orientação comum é: IA no feedback deve ser usada de forma assistiva, e não substitutiva, ou seja, para potencializar o aprendizado fornecendo insumos rápidos e detalhados, enquanto o professor reorienta e valida esse processo.

3.3.3 Desafios e Considerações Éticas

Apesar dos avanços demonstrados, os estudos levantam diversos desafios na implementação de IA para avaliação educacional. Um tema recorrente é o risco de viés e injustiça. [Janumpally \(2025\)](#) (E1) e [Avcu \(2025\)](#) (E5) enfatizam preocupação com viés algorítmico: modelos podem perpetuar preconceitos presentes nos dados (por exemplo, avaliar sistematicamente pior redações de certos grupos). Assim, há um apelo forte por *frameworks* éticos e de auditoria das IAs educacionais, garantindo que sejam transparentes, responsáveis e não discriminatórias. Ainda sobre justiça, [Avcu \(2025\)](#) discute que as notas automatizadas precisam ganhar confiança dos educadores e alunos, o que requer tanto rigor técnico (p.ex. uso de HRMs para equilíbrio de notas) quanto clareza nas justificativas. Fornecer explicações compreensíveis junto com a nota (como LLMs fazem) ajuda nesse sentido, tornando o processo menos “caixa-preta”.

Outro desafio destacado é a dependência excessiva de alunos e professores nas ferramentas de IA. [Fiki Setiawan e Annas Alkhowarizmi \(2025\)](#) (E6) observaram que alguns estudantes passaram a aceitar todas as sugestões do Grammarly cegamente, sem reflexão. De modo similar, [Kitzie et al. \(2024\)](#) (E7) alertam que doutorandos podem confiar demais em traduções automáticas ou na geração de conteúdo via IA, em detrimento de desenvolver suas próprias habilidades de escrita e análise. Essa comodidade traz o perigo de uma diminuição do pensamento crítico. Como resposta, os autores sugerem

intervenções educacionais: é crucial treinar os usuários (sejam alunos de graduação, sejam doutorandos) para utilizar as ferramentas de forma estratégica e consciente. Isso inclui discutir casos de erro da IA, incentivar revisão humana do *output* da máquina e enfatizar que a IA é uma assistente, útil para tarefas mecânicas ou como consulta, mas não substitui o aprendizado fundamental nem o julgamento humano.

Questões de integridade acadêmica e plágio também emergem. No contexto de doutorado (E7), mencionou-se preocupação de que o uso de IA para escrever partes de textos ou resumir artigos pode diluir a originalidade e até configurar má conduta se não houver transparência (Kitzie et al., 2024). Instituições educacionais começam a elaborar políticas sobre o uso aceitável de IA pelos alunos. Uma abordagem sugerida é tratar a IA como mais uma fonte de auxílio, similar a um livro ou ferramenta, devendo ser citada ou declarada quando utilizada para produzir conteúdo avaliado. Em avaliações escritas, isso implica que professores talvez precisem repensar formatos de tarefa e critérios, valorizando processos (esboços, rascunhos manuais, discussões em classe) para garantir que a aprendizagem genuína ocorra mesmo com a IA disponível.

No aspecto técnico, a calibragem e manutenção desses sistemas é um ponto complexo. Modelos de IA, especialmente LLMs de ponta, demandam recursos computacionais elevados e atualizações constantes. A robustez fora do ambiente de laboratório é incerta – por exemplo, um GPT-4 pode se comportar de forma inesperada com entradas muito diferentes das do treino. Os estudos que implementaram sistemas (E2, E3, E4, E6) frequentemente limitam seu escopo a conjuntos de dados específicos; quando expandidos para outros domínios ou faixas etárias, o desempenho pode variar. Logo, há a recomendação de testes piloto e refinamento contínuo antes de adoção ampla. Hutt et al. (2024) (E4) mencionaram a necessidade de alinhar melhor o LLM às instruções específicas da tarefa de *feedback*, possivelmente através de *fine-tuning* ou *prompting* mais detalhado, o que ilustra a importância de customizar a IA ao contexto educacional alvo, em vez de usar “modelo pronto” genericamente.

Por fim, todos os autores convergem na visão de que a IA não vem para substituir o professor, mas para empoderá-lo (assim como aos estudantes). A integração bem-sucedida demanda um delineamento claro de papéis: deixar para as máquinas o que elas fazem de melhor (processar rapidamente grande volume de textos, garantir padronização inicial, sugerir melhorias triviais) e deixar para os humanos o que eles fazem de melhor (analisar nuances subjetivas, entender o aluno como indivíduo, inspirar e motivar, ajustar intervenções pedagógicas). Com base nos achados, pode-se dizer que a IA, usada com critério, tem potencial de tornar a avaliação mais ágil, frequente e formativa, desde que os desafios de viés, dependência e integridade sejam continuamente monitorados e mitigados.

3.4 RESPOSTAS ÀS QUESTÕES DE PESQUISA

Com base na análise dos estudos selecionados, esta seção sintetiza as respostas às questões de pesquisa formuladas no protocolo, organizadas conforme a numeração original. Cada resposta consolida os principais achados observados na literatura e é fundamentada nas evidências extraídas dos trabalhos incluídos.

QP1 As abordagens de IA mais empregadas para correção automática de respostas discursivas evoluíram de técnicas clássicas de PLN para modelos de linguagem de última geração. Sistemas de AES tradicionais baseavam-se em *features* linguísticas pré-definidas e algoritmos de aprendizado de máquina supervisionados. Exemplos incluem motores como o *Intelligent Essay Assessor*, *e-rater* e similares. Essas abordagens utilizam métricas como riqueza lexical, complexidade sintática, coerência textual e outros indicadores manuais para emular a avaliação humana. Sua principal contribuição é viabilizar *feedback* rápido e consistente, reduzindo a carga de trabalho dos docentes, embora com flexibilidade limitada. Nos últimos anos, o foco migrou para modelos de *Deep Learning*, especialmente os LLMs, como o BERT, GPT-3.5 e GPT-4. Estudos comparativos indicam que métodos baseados em LLMs podem superar abordagens convencionais em termos de acurácia e capacidade preditiva, dependendo do conjunto de dados e do desenho experimental. Em alguns recortes, modelos como o GPT-4 apresentaram alta correspondência com notas de referência, por vezes próxima à concordância observada entre avaliadores humanos. Além disso, LLMs oferecem a possibilidade de gerar *feedback* textual detalhado ao estudante, como demonstrado por [Xiao et al. \(2025\)](#), que propuseram um sistema inspirado na teoria de processamento dual. [Hutt et al. \(2024\)](#) também constataram que LLMs podem avaliar a qualidade de *feedback* entre pares com desempenho próximo ao de classificadores tradicionais.

QP1.1 No contraste entre correção automática e manual, destacam-se vantagens como consistência, eficiência e *feedback* personalizado. A IA tende a aplicar os mesmos critérios de forma uniforme, reduzindo variabilidades e parte das subjetividades entre corretores humanos. Estudos apontam que a concordância entre modelos como o GPT-4 e notas humanas pode ser alta em certos conjuntos e tarefas ([Li; Liu, 2024](#)). A correção automática oferece retorno rápido e escalável, viabilizando *feedback* formativo em larga escala. Porém, há limitações. A subjetividade de respostas criativas nem sempre é capturada adequadamente. LLMs podem apresentar *alucinações*, ou inferências indevidas, além de reproduzir vieses presentes nos dados de treinamento ([Xiao et al., 2025](#)). Estudos alertam para a necessidade de *frameworks* éticos e mecanismos de monitoramento. Outro desafio é a dependência excessiva de estudantes em ferramentas de correção, prejudicando o pensamento crítico ([Fiki Setiawan; Annas Alkhowarizmi, 2025](#)). Portanto, é essencial equilibrar os benefícios da automação com orientações pedagógicas claras.

QP1.2 A integração de mecanismos de RAG e bancos de dados vetoriais visa melhorar a contextualização na avaliação de respostas discursivas. Esses mecanismos permitem que modelos de linguagem acessem informações relevantes durante a avaliação, alinhando suas respostas aos critérios e conteúdos esperados da tarefa. Um exemplo notável dessa abordagem é o sistema *SteLLA*, desenvolvido por [Qiu et al. \(2025\)](#), que utiliza RAG para recuperar rubricas e respostas modelos e, em seguida, emprega o GPT-4 para gerar perguntas de avaliação e analisar a resposta do aluno item a item. Os resultados preliminares reportam alta concordância com avaliadores humanos e detalhamento do *feedback* por subcritérios. Contudo, trata-se de um estudo em formato de *preprint*, não submetido a revisão por pares, e por isso foi excluído da amostra principal desta revisão. Ainda assim, ele ilustra o potencial das arquiteturas baseadas em RAG para ancorar a correção automatizada em critérios pedagógicos explícitos. Além disso, outros estudos reforçam que a engenharia de *prompts*, quando inclui instruções claras e rubricas na entrada do modelo, também pode contribuir para melhorar a aderência e a contextualização das respostas geradas pelos LLMs, funcionando como uma forma simplificada de simular o fornecimento de contexto adicional ([Hutt et al., 2024](#)).

QP1.3 As arquiteturas propostas para correção automática de provas discursivas variam entre *pipelines* modulares e sistemas colaborativos humano-IA. [Xiao et al. \(2025\)](#) apresentam um modelo em que o LLM realiza uma primeira rodada de avaliação, atribuindo nota e gerando *feedback*, enquanto o professor atua como agente supervisor nos casos em que o sistema identifica baixa confiança na própria resposta, garantindo assim maior confiabilidade. Já os HRMs, discutidos por [Avcu \(2025\)](#), oferecem uma abordagem estatística hierárquica que considera múltiplas camadas, como comportamento dos avaliadores, dificuldade das tarefas e interações entre esses fatores. Esse tipo de modelagem permite calibrar pontuações, mitigar vieses e promover maior consistência entre avaliações. Em comum, essas arquiteturas buscam integrar a atuação do docente ao processo automatizado, permitindo configuração de critérios, personalização pedagógica e intervenção humana quando necessário.

QP1.4 A literatura revisada reporta resultados promissores de ferramentas automáticas, com qualidade de avaliação por vezes comparável à humana em contextos específicos. Modelos como o GPT-3.5 e o GPT-4 foram descritos com desempenho comparável e, em alguns cenários, superior a métodos tradicionais. A correção automatizada tende a reduzir tempo e carga de trabalho dos professores, sugerindo viabilidade para aplicação em maior escala quando há supervisão adequada ([Xiao et al., 2025](#)). Quanto à aceitação, estudantes relataram melhorias na escrita e motivação com o uso de ferramentas como Grammarly e QuillBot, desde que orientados a revisar criticamente as sugestões ([Fiki Setiawan; Annas Alkhowarizmi, 2025](#)). Educadores demonstraram aprovação quando a IA é usada como apoio, permitindo foco em tarefas pedagógicas mais estratégicas. A

confiança na ferramenta cresce com a transparência dos algoritmos e a possibilidade de intervenção docente, tornando a IA uma aliada potencial na avaliação educacional.

3.5 CONSIDERAÇÕES

A presente revisão sistemática da literatura permitiu identificar e analisar, de forma abrangente, os avanços, desafios e tendências no uso de técnicas de IA, com destaque para os LLMs e mecanismos de RAG, aplicados à correção automática de respostas discursivas no contexto educacional.

Os estudos revisados sugerem que os LLMs representam uma evolução expressiva em relação às abordagens tradicionais de correção automática baseadas em features linguísticas e algoritmos clássicos de aprendizado de máquina. Em diferentes trabalhos, modelos como o GPT-4 e o GPT-3.5 *fine-tuned* foram reportados com bom desempenho em acurácia e consistência, além de oferecerem a capacidade de gerar *feedback* textual interpretável e detalhado. Esse tipo de retorno, aliado à velocidade e escalabilidade da correção automatizada, revela um potencial significativo para o uso pedagógico desses modelos em avaliações formativas e somativas.

O uso de mecanismos como RAG e engenharia de *prompts* avançada tem se mostrado promissor para fornecer contexto pedagógico aos modelos, alinhando suas respostas aos critérios avaliativos previamente estabelecidos. Embora ainda escassos, os estudos que integram bases vetoriais, rubricas e exemplos modelo apontam para possíveis melhorias na transparência do processo de avaliação automatizada e na ancoragem do *feedback* ao contexto. Mesmo trabalhos que não atenderam aos critérios formais de inclusão, como preprints, oferecem sinais claros de um movimento em direção a sistemas de avaliação mais contextualizados e explicáveis.

Paralelamente, o uso de IA na geração e avaliação de *feedback* ao estudante, tanto individual quanto em atividades de avaliação por pares, amplia o escopo de aplicação dessas tecnologias, especialmente ao fomentar a autonomia do aprendiz e a personalização do processo de escrita. Contudo, a literatura adverte sobre os riscos da dependência excessiva dos usuários nas ferramentas automatizadas, o que pode comprometer o desenvolvimento de habilidades críticas e criativas.

Em termos de arquitetura, os estudos destacam soluções que variam desde sistemas colaborativos humano-IA, em que o professor supervisiona e ajusta a atuação do modelo, até modelos estatísticos hierárquicos, como os HRMs, que buscam corrigir vieses e inconsistências históricas da avaliação humana. Essa diversidade de propostas revela um consenso: a IA deve atuar como ferramenta complementar e assistiva, e não substitutiva, do julgamento pedagógico humano.

Apesar dos benefícios, persistem desafios técnicos, éticos e pedagógicos. A possibilidade de viés algorítmico, as dificuldades de adaptação dos modelos a diferentes contextos culturais e linguísticos, e as exigências de infraestrutura computacional são obstáculos que requerem atenção. Além disso, a aceitação plena dessas tecnologias por educadores e instituições depende de fatores como transparência, auditabilidade, capacidade de personalização e possibilidade de intervenção docente.

Conclui-se, portanto, que a integração de IA na correção automatizada de respostas discursivas possui alto potencial transformador para a avaliação educacional — desde que conduzida com responsabilidade ética, supervisão qualificada e foco na aprendizagem. Futuras pesquisas devem investir em abordagens híbridas, que combinem IA, modelagem estatística e participação docente, e expandir a análise para outros contextos, níveis educacionais e áreas do conhecimento. O uso crítico e pedagógico da IA, aliado a políticas institucionais claras, será determinante para garantir que essa tecnologia se torne uma aliada efetiva na promoção de avaliações mais justas, ágeis e formativas.

No contexto específico do protótipo deste trabalho, os achados da literatura devem ser lidos como referência para evolução, não como representação integral do que já foi implementado. O fluxo atual mantém revisão humana das correções como etapa necessária de validação pedagógica e concentra-se na correção de respostas discursivas textuais com o conjunto de funcionalidades atualmente disponível.

Entre as limitações práticas do protótipo, destacam-se: (i) dependência da validação docente para consolidação da avaliação final; (ii) cobertura funcional restrita ao escopo implementado, sem contemplar todas as variações arquiteturais e estratégias descritas na literatura; e (iii) necessidade de expansão e validação contínua em diferentes contextos disciplinares para aumentar generalização e robustez.

A partir dessas lacunas e oportunidades identificadas, o próximo capítulo descreve a metodologia adotada para o desenvolvimento e a avaliação do protótipo.

4 METODOLOGIA

O presente trabalho desenvolveu um sistema para a correção automatizada de provas discursivas. Esse sistema utiliza técnicas de inteligência artificial, como LLM e RAG, para apoiar uma correção inicial estruturada e rastreável, mantendo a revisão docente como etapa necessária para confirmação e ajustes. Assim, busca-se reduzir esforço operacional na correção e ampliar a consistência dos artefatos produzidos (notas, justificativas e detalhamento por critério), sem substituir a decisão final do professor.

A organização deste capítulo segue uma progressão metodológica. Inicialmente, delimita-se o **tipo de pesquisa** adotado. Em seguida, descrevem-se os **subprocessos** do sistema e seus fluxos de execução, detalham-se as **ferramentas e tecnologias** empregadas e, por fim, apresenta-se o **método de avaliação** adotado.


4.1 TIPO DE PESQUISA

Este trabalho caracteriza-se como uma pesquisa aplicada, pois desenvolveu um sistema para correção automatizada de provas, visando solucionar um problema prático no contexto educacional. Quanto aos objetivos, classifica-se como uma pesquisa exploratória, já que analisou a viabilidade de implementação de técnicas de inteligência artificial, como LLM e RAG, no processo de correção de avaliações.

4.2 PROCESSO DE CORREÇÃO DE PROVA


Esta seção descreve o funcionamento do sistema conforme implementado, organizado em três subprocessos principais: a configuração da prova, a correção geral da prova e a correção específica das respostas que exigem intervenção adicional. Cada subprocesso é explicado detalhadamente, utilizando fluxogramas para ilustrar os passos realizados ([Figura 1](#), [Figura 2](#) e [Figura 3](#)).

Figura 1 – Fluxograma do subprocesso de configuração da prova




Fonte: Elaborado pelos autores.

Figura 2 – Fluxograma do subprocesso de correção da prova, incluindo revisão docente antes da consolidação das notas finais



Fonte: Elaborado pelos autores.

Figura 3 – Fluxograma do subprocesso de correção da resposta, com acionamento condicional do Corretor 3 por limiar de divergência



Fonte: Elaborado pelos autores.

No fluxo da [Figura 2](#), a revisão do professor ocorre após a correção automatizada e a persistência dos resultados no banco de dados, e antes da consolidação/finalização das notas. Já no fluxo da [Figura 3](#), o Corretor 3 atua apenas quando a divergência entre o Corretor 1 e o Corretor 2 ultrapassa o limiar configurado, mantendo o caminho condicional de arbitragem alinhado à implementação.

4.2.1 Subprocesso de Configuração da Prova

O subprocesso de configuração corresponde às etapas realizadas pelo professor antes da publicação da prova (*status* de rascunho). Inicialmente, são definidos metadados gerais (por exemplo, título, descrição e turma), e os materiais didáticos são anexados (arquivos Portable Document Format (PDF)). Esses anexos são armazenados pela aplicação e registrados no banco de dados relacional, permanecendo indisponíveis para busca semântica até o momento de publicação.

Em seguida, o professor associa critérios de avaliação à prova, definindo pesos e parâmetros de pontuação. Quando necessário, podem ser realizados ajustes específicos por questão, de modo que diferentes questões utilizem variações de rubrica dentro de uma mesma prova. Após essa configuração, as questões são cadastradas com seus enunciados, pontuação e ordem.

Por fim, as respostas discursivas dos alunos são inseridas e persistidas, vinculadas às respectivas questões. Ao publicar a prova, o sistema valida se ela está apta a iniciar o processamento (por exemplo, se permanece em rascunho e se possui questões e respostas registradas). Caso a validação falhe, a publicação é interrompida e as inconsistências são informadas.

4.2.2 Subprocesso de Correção da Prova

Uma vez publicada, a prova dispara um processamento assíncrono em *background*. Esse processamento possui duas responsabilidades principais.

Primeiro, o sistema prepara os materiais didáticos anexados para consulta por similaridade semântica, o que inclui carregar os PDFs, segmentar seu conteúdo em trechos (*chunks*) e indexá-los em uma base vetorial. O resultado desse preparo é registrado como sucesso ou falha, o que subsidia a atribuição de um *status* de atenção quando o processamento não se conclui adequadamente.

Segundo, o sistema percorre as questões da prova e executa a correção das respostas discursivas. Para cada questão, o sistema recupera, uma única vez, trechos relevantes dos materiais didáticos utilizando o enunciado como consulta. O contexto recuperado é então reutilizado na correção de todas as respostas associadas àquela questão, reduzindo repetição de consultas e mantendo consistência de referência por questão.

Ao término do processamento, os resultados são consolidados e persistidos, e a prova é marcada com um *status* compatível com o sucesso do fluxo (por exemplo, corrigida quando não há falhas relevantes, ou atenção quando há falhas que exigem intervenção). Em seguida, o professor pode revisar os resultados por aluno e por questão, aprovar respostas e,

quando necessário, ajustar manualmente a nota. Ao finalizar a revisão, o sistema registra a finalização da prova e, opcionalmente, disponibiliza um relatório em planilha com a consolidação das notas.

4.2.3 Subprocesso de Correção da Resposta

O subprocesso de correção da resposta ([Figura 3](#)) utiliza (i) o texto da resposta do aluno, (ii) a rubrica definida para a questão (critérios, pesos e limites de pontuação) e (iii) o contexto dos materiais didáticos recuperado previamente para a questão.

Inicialmente, dois agentes corretores independentes (Corretor 1 e Corretor 2) avaliam a resposta, produzindo notas e justificativas sem comunicação entre si. Em seguida, o sistema verifica se a divergência entre as avaliações ultrapassa um limiar configurado. Quando a divergência é baixa, a nota final é consolidada diretamente a partir das duas avaliações. Quando a divergência ultrapassa o limiar, um terceiro agente (árbitro) é acionado para uma avaliação adicional.

Ao final, a nota é consolidada por uma regra de consenso e o resultado é persistido, incluindo a nota final e as justificativas associadas. Esse registro alimenta tanto a etapa de consolidação da prova quanto a etapa posterior de revisão docente.

4.3 FERRAMENTAS E TECNOLOGIAS UTILIZADAS

Para o desenvolvimento e a implementação do sistema proposto, foram empregadas ferramentas e tecnologias que atendem aos requisitos de integração com modelos de linguagem, persistência de dados, recuperação de contexto por similaridade semântica e disponibilização do sistema por meio de uma Application Programming Interface (API). A seguir, apresentam-se as principais tecnologias utilizadas e suas respectivas finalidades no contexto do projeto.

4.3.1 Python

O sistema foi implementado em Python, em função da maturidade do ecossistema para desenvolvimento de aplicações web, integração com bibliotecas de inteligência artificial e suporte a ferramentas de persistência e processamento de dados ([Python Software Foundation, 2026](#)).

4.3.2 FastAPI

O backend foi desenvolvido com o *framework* FastAPI, utilizado para a implementação de uma API REST, organização de rotas e tratamento de requisições relacionadas

às etapas de configuração, correção e revisão docente. Para execução em ambiente de produção, a aplicação é servida com *workers* assíncronos (Gunicorn/Uvicorn), favorecendo concorrência e escalabilidade (FastAPI, 2026; Gunicorn Contributors, 2026; Uvicorn Contributors, 2026).

4.3.3 Orquestração do fluxo com LangGraph

O fluxo de correção foi estruturado como um grafo de estados, empregando LangGraph para definir nós de execução (recuperação de contexto, correção independente, verificação de divergência, acionamento condicional do terceiro corretor e consolidação do resultado). Essa abordagem permite controlar o encadeamento das etapas e tornar o processo reprodutível e rastreável (LangChain, Inc., 2026b).

4.3.4 Agentes corretores com LangChain

Os agentes de correção utilizam o método `with_structured_output` do ecossistema LangChain para realizar a inferência em tempo de execução (LangChain, Inc., 2026a). Cada avaliação é resolvida em uma única chamada ao modelo de linguagem, cujo retorno é automaticamente validado e convertido em um objeto Pydantic (`AgentCorrection`), eliminando etapas intermediárias de *parsing* e garantindo aderência ao *schema* esperado.

Essa abordagem substitui o uso anterior de DSPy no caminho de inferência. O DSPy é um *framework* voltado à **otimização offline** de *prompts*, e não à execução de inferência em produção (DSPy Contributors, 2026). No projeto, o módulo `BootstrapFewShot` do DSPy permanece disponível como ferramenta auxiliar para otimização de *prompts* com exemplos reais, porém não participa do fluxo de correção em tempo de execução. A separação entre otimização offline (DSPy) e inferência runtime (LangChain) reduz o número de chamadas ao modelo por correção e simplifica o rastreamento do pipeline.

4.3.5 Integração com LLMs e provedores de *embeddings*

Para padronizar integrações com provedores de modelos e de *embeddings*, foram utilizadas bibliotecas do ecossistema LangChain. No sistema, essa camada é empregada tanto para instanciar modelos de chat (conforme o provedor configurado) quanto para gerar *embeddings* utilizados no processo de recuperação de contexto (LangChain, Inc., 2026a).

4.3.6 Recuperação de contexto e armazenamento vetorial

O armazenamento vetorial e a recuperação por similaridade foram realizados com ChromaDB, utilizado como *vector store* persistente. O banco vetorial armazena

representações vetoriais dos materiais didáticos e permite consultas para obtenção de trechos relevantes, compondo o contexto adicional necessário à estratégia de RAG ([Chroma Contributors, 2026](#)).

4.3.7 Persistência relacional e migrações

Os dados estruturados do sistema (usuários, turmas, provas, questões, respostas, critérios e resultados) são persistidos em banco de dados relacional PostgreSQL. Para a camada de acesso a dados, utiliza-se SQLAlchemy, enquanto Alembic é empregado para versionamento e execução de migrações, assegurando reprodutibilidade do esquema entre ambientes ([PostgreSQL Global Development Group, 2026](#); [SQLAlchemy Authors, 2026b](#); [SQLAlchemy Authors, 2026a](#)).

4.3.8 Containerização

O ambiente de execução foi padronizado por meio de Docker e Docker Compose, viabilizando a composição de serviços (API, banco de dados relacional e serviços auxiliares) e reduzindo diferenças de configuração entre execução local e implantação ([Docker, Inc., 2026b](#); [Docker, Inc., 2026a](#)).

4.3.9 Ollama e Streamlit

Quando configurado, o Ollama é utilizado como provedor local para modelos e/ou *embeddings*, favorecendo experimentação sem dependência exclusiva de serviços externos. Além disso, uma aplicação auxiliar em Streamlit é utilizada para fins de observabilidade e inspeção do pipeline de correção durante o desenvolvimento ([Ollama, 2026](#); [Streamlit Inc., 2026](#)).

4.3.10 JavaScript Object Notation (JSON)

O formato JSON é empregado na padronização e transmissão de informações entre componentes do sistema, como questões, respostas e identificadores. Essa escolha favorece interoperabilidade e validação de dados, enquanto o armazenamento persistente e principal das informações acadêmicas e de correção permanece sob responsabilidade do banco relacional da aplicação ([Bray, 2017](#)).

4.4 MÉTODOS DE AVALIAÇÃO

Esta seção descreve o método adotado para avaliar o sistema desenvolvido, com foco em evidências observáveis do próprio fluxo de correção e revisão docente. Em vez de executar um *benchmark* multi-modelo, a avaliação busca demonstrar a **viabilidade**

técnica e a **viabilidade operacional** do protótipo end-to-end (configurar → publicar → indexar → corrigir → persistir → revisar → consolidar), bem como observar efeitos do RAG e do mecanismo de arbitragem por divergência.

Ressalta-se que o escopo desta avaliação é validar o funcionamento e a rastreabilidade do sistema como artefato tecnológico de apoio ao trabalho docente, e não mensurar, de forma ampla, eficácia educacional (por exemplo, ganhos de aprendizagem) nem sustentar superioridade definitiva da IA em relação à correção humana.

4.4.1 Objetivo da avaliação

O objetivo da avaliação é verificar se o sistema é capaz de executar o fluxo completo de correção automatizada de respostas discursivas, produzindo **artefatos estruturados e revisáveis** (nota final, notas por critério e justificativas), e mantendo o professor como responsável pela decisão final por meio de uma etapa explícita de revisão. Dessa forma, a avaliação está orientada à verificação de **viabilidade técnica e operacional** do protótipo, não a uma comparação conclusiva de desempenho pedagógico com a correção manual.

4.4.2 Questões avaliativas

A avaliação é organizada nas seguintes questões avaliativas (QAs):

- **QA1 — Execução end-to-end:** o sistema completa o fluxo de configuração, publicação, processamento em *background*, correção, persistência e disponibilização para revisão docente?
- **QA2 — Utilidade do RAG:** ao ativar o RAG (materiais anexados), as justificativas e pontuações tendem a ficar mais ancoradas ao conteúdo recuperado do que em um cenário sem RAG?
- **QA3 — Arbitragem por divergência:** o mecanismo de divergência e acionamento condicional do terceiro corretor (árbitro) é acionado quando esperado e contribui para estabilizar a nota final?
- **QA4 — Estabilidade operacional:** com configuração de baixa estocasticidade (temperatura = 0,0), o sistema produz saídas com baixa variabilidade em execuções repetidas do mesmo caso?

4.4.3 Desenho do estudo

Adota-se um **estudo de caso controlado**, com uma prova pequena (de 2 a 4 questões discursivas) e materiais didáticos anexados em PDF. A prova é configurada

com rubrica simples e objetiva, contendo de 3 a 5 critérios (por exemplo, correção conceitual, completude, clareza/organização e aderência ao enunciado), com pesos e limites de pontuação.

No contexto deste estudo, o conjunto de respostas pode ser composto por **respostas sintéticas** elaboradas pelos autores, cobrindo níveis de qualidade (excelente, intermediária, fraca e fora do tema). O objetivo não é representar toda a diversidade de respostas humanas, mas viabilizar a verificação objetiva do funcionamento do sistema em casos típicos e casos-limite.

Esse delineamento, por ser deliberadamente restrito (prova pequena, rubrica simplificada e respostas sintéticas), **limita o alcance das inferências**. Assim, os resultados obtidos devem ser interpretados como evidência de **viabilidade técnica e operacional** e de consistência interna do fluxo proposto, não como base suficiente para conclusões amplas sobre eficácia educacional, impacto pedagógico ou desempenho comparativo geral em contextos reais e diversos. Para sustentar generalizações mais robustas, seriam necessários estudos com maior variedade de provas, materiais, perfis de estudantes e validação sistemática com docentes em cenários de uso.

4.4.4 Parâmetros experimentais

Para fortalecer a reprodutibilidade e reduzir ambiguidades de interpretação, define-se explicitamente um conjunto de **parâmetros experimentais** e **controles** aplicados às duas condições (com RAG e sem RAG).

Em termos de **quantidade de casos**, recomenda-se adotar uma configuração mínima que permita observar variação de qualidade e casos-limite. Assim, utiliza-se uma prova com $Q = 3$ questões (dentro do intervalo de 2 a 4), e para cada questão um conjunto de $A = 4$ respostas sintéticas (excelente, intermediária, fraca e fora do tema), totalizando $Q \times A = 12$ respostas a serem corrigidas em cada condição.

Para avaliar estabilidade (QA4), seleciona-se um subconjunto de $A_{rep} = 4$ respostas (uma por nível de qualidade) e repete-se sua correção $R = 3$ vezes em cada condição, mantendo constantes os demais parâmetros.

Quadro 3 – Parâmetros experimentais utilizados no estudo

Parâmetro	Valor/control
Modelo do LLM	Google Gemini / <code>gemini-2.5-flash</code>
Temperatura do LLM	0,0 (baixa estocasticidade; <code>LLM_TEMPERATURE=0.0</code>)
Top- k do RAG (Condição A)	$k = 4$ trechos recuperados por consulta (<code>RAG_TOP_K=4</code>)
Top- k do RAG (Condição B)	$k = 0$ (RAG desativado; controle equivalente)
Limiar de divergência	2,0 pontos na escala da questão (<code>DIVERGENCE_THRESHOLD=2.0</code>)
Quantidade de questões	$Q = 3$ (prova pequena, dentro do intervalo 2–4)
Quantidade de respostas	$Q \times A = 12$ respostas ($A = 4$ níveis de qualidade por questão)
Repetições (estabilidade)	$R = 3$ repetições para $A_{rep} = 4$ respostas selecionadas

Fonte: Elaborado pelos autores.

A escolha dos parâmetros segue critérios de defensibilidade técnica. O modelo `gemini-2.5-flash` foi adotado pelo balanço entre custo, latência e qualidade adequado ao escopo experimental. A temperatura 0,0 corresponde a um regime de *decoding* determinístico, requisito metodológico para a análise de estabilidade (QA4): variações entre rodadas devem refletir comportamento intrínseco do modelo, não amostragem estocástica. O parâmetro $k = 4$ na recuperação RAG situa-se na faixa intermediária recomendada em revisões da técnica (Finardi et al., 2024), equilibrando cobertura semântica e ruído de recuperação. O limiar de divergência 2,0 pontos segue a lógica estrutural do protocolo oficial de correção do ENEM (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024), detalhada no Capítulo 5, em que um terceiro avaliador é convocado quando a discrepância entre corretores excede um limiar predefinido. As quantidades $Q = 3$, $A = 4$ e $R = 3$ representam o mínimo necessário para observar, simultaneamente, variação entre níveis de qualidade (A), comportamento sob diferentes questões (Q) e estabilidade entre execuções repetidas (R), sem inviabilizar o orçamento de chamadas ao modelo no escopo do trabalho.

4.4.5 Procedimento experimental

O procedimento é dividido em duas condições para observar o efeito do RAG, mantendo as demais variáveis constantes.

1. **Configuração:** cadastrar prova, questões, rubrica e anexar PDFs.
2. **Publicação:** publicar a prova e aguardar o processamento em *background* (indexação do material e início da correção).

3. **Condição A (com RAG):** executar a correção com recuperação de contexto ativada.
4. **Condição B (sem RAG):** executar a correção com recuperação de contexto desativada (ou equivalente, como $top_k=0$), mantendo rubrica e dados idênticos.
5. **Coleta de evidências:** extrair os artefatos gerados para cada resposta (nota final, notas por critério, justificativas, indicação de divergência e eventual atuação do árbitro), além do status de indexação dos anexos.

Quando aplicável, repete-se a execução de um subconjunto de casos (por exemplo, 3 repetições) para observar estabilidade.

4.4.6 Evidências coletadas

As evidências são baseadas em artefatos do próprio sistema:

- nota final por resposta;
- pontuação por critério;
- justificativa textual associada;
- indicação de divergência entre corretores e acionamento do árbitro;
- status de indexação dos anexos (sucesso/falha), quando existir;
- (opcional) relatório exportado (planilha) com consolidação das notas.

4.4.7 Métricas simples

As métricas são propositalmente simples, priorizando reprodutibilidade e evidência operacional dentro do escopo e dos recursos do trabalho

- **Compleitude estrutural:** porcentagem de respostas com todos os campos esperados (nota total, notas por critério e justificativa).
- **Aderência à rubrica (checklist):** verificação de que cada critério foi efetivamente pontuado e possui justificativa coerente.
- **Efeito do RAG (checklist):** comparação das justificativas em A vs. B, registrando se, com RAG, há maior especificidade e **ancoragem ao material anexado**. Para fins operacionais, considera-se uma justificativa *ancorada* quando menciona explicitamente ao menos um conceito, definição ou evidência presente no material recuperado.

- **Taxa de arbitragem:** porcentagem de respostas em que o limiar de divergência aciona o árbitro.
- **Estabilidade:** variação absoluta da nota final entre execuções repetidas do mesmo caso.

4.4.8 Critérios de sucesso

Considera-se que a avaliação cumpre seu papel quando os resultados satisfazem critérios objetivos compatíveis com as QAs e com as métricas definidas:

- **QA1 (end-to-end):** 100% das respostas previstas são processadas e persistidas, e a prova é disponibilizada para revisão docente (sem falhas que impeçam a revisão).
- **Compleitude estrutural:** pelo menos 95% das respostas apresentam todos os campos esperados (nota final, notas por critério e justificativa).
- **QA2 (RAG):** na condição A (com RAG), a proporção de justificativas classificadas como *ancoradas* (conforme checklist) é maior do que na condição B (sem RAG), mantendo o mesmo conjunto de respostas.
- **QA3 (arbitragem):** o árbitro é acionado quando $|nota_{C1} - nota_{C2}| > 2,0$ (limiar) e não é acionado quando $|nota_{C1} - nota_{C2}| \leq 2,0$, no conjunto de casos analisado.
- **QA4 (estabilidade):** nas repetições ($R = 3$) do subconjunto definido, a variação absoluta da nota final por caso permanece $\leq 1,0$ ponto na escala da questão.

4.4.9 Ameaças à validade

- **Respostas sintéticas:** as respostas utilizadas não representam toda a diversidade de respostas humanas. Para mitigar essa limitação, o estudo inclui níveis de qualidade distintos e casos-limite que permitem verificar comportamentos esperados do sistema.
- **Validade externa (generalização):** o desenho com número reduzido de questões e casos limita a extrapolação dos resultados para outras disciplinas, turmas, níveis de ensino e estilos de rubrica; estudos adicionais com amostras maiores são necessários para ampliar a validade externa.
- **Validade ecológica (uso em contexto real):** a avaliação foi conduzida em ambiente controlado e pode não reproduzir integralmente condicionantes da rotina docente (volume de respostas, variações de enunciado, ajustes de rubrica, pressão institucional). Testes em cenários reais são recomendados como trabalho futuro.

- **Não-determinismo de LLMs:** modelos de linguagem apresentam variabilidade nas saídas. Neste estudo, a estocasticidade foi reduzida por configuração de temperatura igual a 0,0 e por meio da repetição de casos selecionados para avaliar consistência.
- **Dependência do material:** os resultados dependem do conteúdo e da qualidade dos materiais anexados (PDFs). Por este motivo, o conjunto de materiais foi descrito explicitamente e recomenda-se avaliar robustez com diferentes fontes em estudos subsequentes.

4.4.10 Reprodutibilidade

Para permitir repetição do estudo:

- registrar configurações relevantes (provedor/modelo, LLM_TEMPERATURE=0.0, RAG_TOP_K=4 na condição A, DIVERGENCE_THRESHOLD=2.0);
- manter a mesma prova, rubrica e conjunto de respostas nas duas condições;
- explicitar Q , A , A_{rep} e R utilizados (quantidade de questões, respostas, subconjunto repetido e número de repetições);
- documentar o procedimento de extração dos resultados (relatório/consulta).

5 DESENVOLVIMENTO


Este capítulo descreve o desenvolvimento do sistema de correção automática de provas, enfatizando a organização arquitetural, a implementação do *backend*, o pipeline de inteligência artificial e as principais integrações empregadas. A intenção é apresentar detalhes suficientes para que um leitor compreenda como o sistema foi construído e como suas partes se articulam, sem depender da leitura direta do código-fonte.

5.1 ARQUITETURA DO SISTEMA

O sistema foi concebido como uma aplicação de *backend* exposta por uma API REST, integrada a mecanismos de persistência relacional e vetorial, e a provedores de modelos de linguagem e de *embeddings*. Além do fluxo síncrono de requisições HTTP, há etapas assíncronas executadas em *background*, necessárias para preparar materiais anexados e processar correções.

De forma resumida, a arquitetura organiza-se em: (i) camada de apresentação/consumo (clientes e ferramentas de inspeção), (ii) camada de API (rotas e controladores), (iii) camada de serviços (regras de negócio, orquestração e pipeline), e (iv) camada de dados (banco relacional e base vetorial). A [Figura 4](#) apresenta a visão geral.

Figura 4 – Visão geral da arquitetura do sistema



Fonte: Elaborado pelos autores.

Na arquitetura adotada, o banco relacional centraliza os dados estruturados do domínio (provas, questões, respostas, rubricas e resultados), enquanto a base vetorial

armazena representações vetoriais de trechos de materiais didáticos para recuperação semântica. A correção em si depende de chamadas a modelos de linguagem; para reduzir acoplamento a um único provedor e permitir experimentação, o sistema utiliza uma camada de compatibilidade para parametrizar modelo, provedor e configurações de execução.

Na prática, essa arquitetura se materializa em um fluxo ponta-a-ponta que pode ser observado por meio da própria API. Um cenário típico de uso (professor configurando e revisando uma prova) pode ser descrito, de forma simplificada, como:

- **Configuração (síncrona via API):** criação da prova (POST `/exams`), associação de critérios (POST `/exam-criteria`), cadastro de questões (POST `/exam-questions`), cadastro de respostas (POST `/student-answers`) e upload de materiais PDF (POST `/attachments/upload?exam_uuid=...`).
- **Publicação (gatilho do processamento):** publicação da prova (POST `/exams/{exam_uuid}/publish`), que atualiza o *status* e agenda o processamento em *background*.
- **Revisão docente (inspeção e ajustes):** consulta dos dados consolidados para revisão (GET `/reviews/exams/{exam_uuid}`);
ajuste manual de nota (PUT `/reviews/grades/adjust`);
aprovação de respostas (POST `/reviews/approve-answer/{answer_uuid}`);
finalização da revisão (POST `/reviews/finalize`).

Esse encadeamento ajuda a tornar explícito que o protótipo foi implementado como um sistema operacional, com etapas observáveis, persistência de estado e pontos de intervenção docente.

5.2 BACKEND

A organização do código segue uma separação em camadas, visando isolar responsabilidades e facilitar evolução e testes. Em termos funcionais, o fluxo de uma operação típica consiste em:

- **Rotas:** definem os endpoints por domínio (por exemplo, provas, questões, anexos, respostas e revisões) e validam aspectos básicos da requisição;
- **Controladores:** traduzem a requisição para uma intenção de caso de uso, organizando entradas e saídas;

- **Serviços:** concentram regras de negócio e orquestram operações, inclusive chamadas ao pipeline de IA;
- **Persistência:** executa acesso ao banco relacional e garante consistência transacional;
- **Resposta:** devolve ao cliente dados estruturados para inspeção e revisão docente.

Para tornar essa organização mais concreta, o [Quadro 4](#) resume alguns endpoints diretamente associados ao fluxo principal de configuração, publicação e revisão.


Quadro 4 – Exemplos de endpoints do fluxo principal do sistema

Domínio	Exemplos (rota)
Provas	POST /exams, GET /exams/{exam_uuid}, POST /exams/{exam_uuid}/publish
Anexos (PDF)	POST /attachments/upload?exam_uuid=...
Questões e respostas	POST /exam-questions, POST /student-answers, GET /student-answers/question/{question_uuid}
Revisão docente	GET /reviews/exams/{exam_uuid}, PUT /reviews/grades/adjust, POST /reviews/approve-answer/{answer_uuid}, POST /reviews/finalize

Fonte: Elaborado pelos autores.

A [Figura 5](#) representa esse encadeamento de camadas, evidenciando o caminho de ida (requisição) e volta (resposta) no *backend*.

Figura 5 – Fluxo de requisição e resposta entre camadas do backend



Fonte: Elaborado pelos autores.

Essa estrutura favorece a rastreabilidade das operações e torna mais claras as fronteiras entre a lógica de aplicação (por exemplo, publicação de prova e mudanças de *status*) e a lógica de avaliação automática (por exemplo, recuperação de contexto, correção por agentes e arbitragem por divergência).

5.2.1 Processamento assíncrono e *status* de rastreabilidade

Determinadas etapas do sistema são executadas de forma assíncrona, especialmente as relacionadas à preparação de anexos e à correção de respostas, que podem envolver operações de maior custo computacional (por exemplo, segmentação de PDF, geração de *embeddings* e chamadas a LLMs). Para permitir controle operacional e revisão, o modelo de dados utiliza campos de *status* e sinalizações que indicam se uma etapa foi concluída com sucesso ou se exige atenção.

De forma concreta, a publicação de uma prova, via endpoint `POST /exams/{exam_uuid}/publish`, segue o padrão: (i) valida a existência da prova e que ela está em `DRAFT`, (ii) atualiza seu *status* para `PUBLISHED` de forma síncrona, e (iii) agenda uma tarefa em *background* para indexar anexos e executar a correção automática. Ao final do processamento, o *status* da prova é atualizado para um estado final de sucesso (`GRADED`) ou atenção (`WARNING`), permitindo distinguir casos que exigem intervenção.

Nos anexos, um campo como `vector_status` permite sinalizar se o PDF foi efetivamente preparado para busca vetorial. Isso torna observáveis falhas de indexação que podem comprometer a etapa de RAG, sem impedir a continuidade da revisão docente.

Além disso, campos como `is_graded` limitam alterações em entidades após a execução da correção, preservando consistência entre rubrica, respostas e resultados persistidos.

5.3 PIPELINE DE IA (RAG, CORREÇÃO E ARBITRAGEM)

O pipeline de correção foi estruturado como um *workflow* com estado explícito utilizando o *framework* LangGraph, composto por nós que representam etapas do processo e por regras de encaminhamento condicional. Os agentes corretores utilizam LangChain para integração com o provedor de LLM e para produção de saídas estruturadas via `with_structured_output`. A abordagem permite documentar e reproduzir a sequência de execução, o que é relevante tanto para depuração quanto para a revisão docente.

O desenho multiagente adotado — dois corretores independentes com acionamento condicional de um terceiro (árbitro) — foi inspirado no processo oficial de correção de redações do ENEM. No ENEM, cada redação é avaliada por dois corretores de forma


independente, e um terceiro avaliador é convocado quando a discrepância entre as notas excede um limiar predefinido (diferença superior a 100 pontos no total ou superior a 80 pontos em qualquer uma das cinco competências individuais). A nota final, quando há três avaliações, é calculada como a média das duas notas totais mais próximas, descartando a mais discrepante (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024). O sistema desenvolvido neste trabalho adota a mesma lógica estrutural — dupla correção, limiar de divergência e consenso por proximidade — adaptada ao contexto de avaliação automatizada com agentes de IA.

No sistema desenvolvido, o pipeline segue as seguintes macroetapas:

- **Recuperação de contexto (RAG):** busca de trechos relevantes dos materiais anexados, a partir do enunciado da questão;
- **Correção independente:** avaliação por dois agentes corretores, sem comunicação entre si;
- **Checagem de divergência:** cálculo de divergência entre as notas e decisão de acionar ou não um *árbitro*;
- **Arbitragem condicional:** avaliação adicional quando a divergência supera um limiar;
- **Consolidação e persistência:** definição de nota final, armazenamento de justificativas e pontuações por critério.

A Figura 6 apresenta um diagrama simplificado desse *workflow*.

Figura 6 – Pipeline de correção com RAG e arbitragem por divergência



Fonte: Elaborado pelos autores.

O [Codigo 1](#) apresenta uma versão simplificada da definição do grafo, ilustrando a composição dos nós e as regras de encaminhamento.

Codigo 1 – Definição do grafo de correção com LangGraph

```

1 # Definicao do grafo de correcao (LangGraph)
2 workflow = StateGraph(GradingState)
3
4 workflow.add_node("retrieve_context", retrieve_context_node)
5 workflow.add_node("examiner_1", examiner_1_node)
6 workflow.add_node("examiner_2", examiner_2_node)
7 workflow.add_node("divergence_check", divergence_check_node)
8 workflow.add_node("arbiter", arbiter_node)
9 workflow.add_node("finalize", finalize_node)
10
11 # Corretores em PARALELO (independencia logica e temporal)
12 workflow.set_entry_point("retrieve_context")
13 workflow.add_edge("retrieve_context", "examiner_1")
14 workflow.add_edge("retrieve_context", "examiner_2")
15 workflow.add_edge("examiner_1", "divergence_check")
16 workflow.add_edge("examiner_2", "divergence_check")
17
18 # Roteamento condicional: arbitro so se divergencia > threshold
19 workflow.add_conditional_edges("divergence_check",
20     should_call_arbiter,
21     {"arbiter": "arbiter", "finalize": "finalize"})
22
23 workflow.add_edge("arbiter", "finalize")
24 workflow.add_edge("finalize", END)

```

Fonte: Elaborado pelos autores.

5.3.1 Recuperação de contexto

Para viabilizar RAG, os materiais didáticos anexados são processados em duas fases: (i) segmentação em trechos e geração de *embeddings* para indexação, e (ii) recuperação por similaridade durante a correção. No protótipo, a segmentação utiliza trechos com sobreposição para preservar contexto local, enquanto a consulta recupera um conjunto pequeno de trechos mais relevantes (*top-k*) para compor o contexto fornecido aos agentes.

Um aspecto de projeto relevante é o isolamento por prova: as consultas de recuperação utilizam um filtro primário por `exam_uuid`, priorizando trechos associados à prova em questão. Caso nenhum resultado seja encontrado com esse filtro (por exemplo, quando os materiais foram indexados sem associação explícita a uma prova), o sistema realiza uma busca global sem filtro como mecanismo de *fallback*, evitando que a correção prossiga sem contexto quando há material disponível no banco vetorial. Operacionalmente, o sistema utiliza *top-k* pequeno (por padrão, `RAG_TOP_K=4`), de modo a produzir contexto suficiente sem exceder o orçamento de tokens e sem inundar os corretores com material pouco relevante.

5.3.2 Vantagens do desenho multiagente frente a uma correção monolítica

Embora seja possível corrigir uma resposta com uma única chamada a LLM (um *prompt* único e uma nota final), o protótipo adotou um desenho em etapas e com redundância controlada porque esse formato aumenta a robustez e melhora a qualidade operacional do sistema como artefato de apoio à decisão docente.

Em uma correção monolítica, os principais riscos se concentram em um único ponto: uma saída potencialmente instável, pouco diagnosticável e difícil de auditar, na qual erros de entendimento do enunciado, recuperação de contexto inadequada ou interpretações subjetivas do critério se tornam indistinguíveis. Já no *workflow* multiagente, cada etapa produz artefatos verificáveis (contexto recuperado, notas e justificativas por critério, medida de divergência e decisão de arbitragem), permitindo que a revisão docente se apoie em evidências intermediárias e não apenas no resultado final.

De forma mais concreta, os benefícios técnicos desse desenho podem ser sintetizados em:

- **Robustez por redundância e detecção de inconsistência:** dois corretores independentes reduzem a dependência de uma única amostra de resposta do modelo; a divergência explicita quando há instabilidade entre avaliações, em vez de ocultá-la no resultado final.
- **Arbitragem condicional como controle de custo e de incerteza:** o terceiro agente não é acionado sempre; ele é reservado para casos em que a divergência supera um limiar (por padrão, `DIVERGENCE_THRESHOLD=2.0`), equilibrando consistência e custo computacional.
- **Separação de responsabilidades e depuração:** a recuperação (RAG), a correção e a consolidação são módulos distintos; assim, falhas de indexação ou de recuperação podem ser tratadas e observadas (por exemplo, via `vector_status`) sem confundir o diagnóstico com a etapa de correção.
- **Auditabilidade e revisabilidade:** saídas estruturadas (nota total, pontuação por critério e justificativas) tornam explícito como a nota foi composta, permitindo ao professor localizar rapidamente o ponto de discordância e ajustar o que for necessário.
- **Reprodutibilidade operacional:** a execução como *workflow* com estado explícito facilita repetir o processamento sob o mesmo conjunto de parâmetros (por exemplo, `LLM_TEMPERATURE`, `RAG_TOP_K` e `DIVERGENCE_THRESHOLD`) e comparar resultados entre rodadas de avaliação.

5.3.3 Correção por agentes e saídas estruturadas

Cada resposta discursiva é avaliada por dois corretores logicamente independentes, isto é, sem estado compartilhado entre si, de modo que a avaliação de um não influencia a do outro. Na implementação, os corretores são executados em **paralelo** pelo LangGraph, garantindo independência tanto lógica quanto temporal entre as avaliações e reduzindo o tempo total de correção. Os agentes produzem uma saída estruturada que inclui: nota total, pontuação por critério e justificativas textuais. Essa estrutura atende ao objetivo de tornar o resultado revisável pelo professor, pois permite inspecionar como cada critério contribuiu para a nota final.

Quando a divergência entre as notas dos corretores ultrapassa um limiar configurável (por padrão, `DIVERGENCE_THRESHOLD=2.0` pontos), um terceiro agente (*árbitro*) é acionado para produzir uma avaliação adicional. Na consolidação, o sistema utiliza a avaliação adicional como mecanismo de estabilização da nota final em casos de incerteza ou inconsistência entre corretores.

Esse mecanismo também fortalece a coerência do sistema sob a ótica de governança: em vez de “forçar” uma nota única, o pipeline sinaliza quando a própria IA está em desacordo consigo mesma e, portanto, quando há maior probabilidade de que o professor precise inspecionar a resposta com mais atenção. Em termos de apoio à decisão, esse comportamento é preferível porque direciona esforço humano para os casos mais ambíguos.

A definição da nota final é realizada pelo módulo `ConsensusBuilder`, que emprega uma regra de consenso baseada em proximidade: quando há duas avaliações (sem divergência), a nota final é a média aritmética simples das notas dos Corretores 1 e 2; quando há três avaliações (com acionamento do árbitro), o sistema ordena as três notas, identifica o par com menor distância absoluta (*closest-pair*) e calcula a média desse par, descartando o valor mais discrepante. Essa estratégia reduz o impacto de avaliações *outlier* e produz notas finais mais estáveis.

Após a execução do *workflow*, o resultado é persistido no banco relacional, marcando a resposta como avaliada (`is_graded`) e registrando pontuações por critério em uma estrutura normalizada (uma linha por critério). Dessa forma, a API de revisão pode recuperar tanto a nota final quanto o detalhamento necessário para inspeção e ajuste docente.

5.3.4 Engenharia de *prompts* dos agentes corretores

Os *prompts* que instruem os agentes corretores constituem um elemento central do sistema, pois determinam como o modelo de linguagem interpreta a resposta do aluno, aplica a rubrica e produz justificativas. O sistema utiliza três técnicas complementares de

engenharia de *prompts*, centralizadas no módulo `prompts.py`:

1. **Role Prompting:** cada agente recebe uma identidade especializada. Os Corretores 1 e 2 são instruídos como “Especialista em Avaliação Educacional com foco em correção de provas discursivas”, enquanto o Árbitro recebe o papel de “Revisor Sênior e Árbitro Acadêmico”. Essa atribuição de papel direciona o comportamento do modelo para um tom profissional e critérios de avaliação acadêmicos.
2. **Chain-of-Thought (CoT):** os agentes são instruídos a desenvolver um raciocínio passo a passo antes de atribuir qualquer nota. O *prompt* exige que cada critério da rubrica seja analisado individualmente, com a nota parcial registrada entre colchetes ao final de cada análise (por exemplo, “[Nota: 2.5/3.0]”). Esse raciocínio é armazenado no campo `reasoning_chain` da saída estruturada, permitindo rastreabilidade completa da decisão avaliativa.
3. **Groundedness (fidelidade ao contexto RAG):** o *prompt* instrui o corretor a utilizar o material didático recuperado como referência principal para validar terminologia e escopo, mas com flexibilidade pedagógica: respostas tecnicamente corretas que utilizem exemplos ou terminologia diferentes do material são consideradas válidas. Essa diretriz equilibra fidelidade ao conteúdo da disciplina com reconhecimento de compreensão conceitual genuína.

Adicionalmente, o *prompt* dos corretores inclui uma diretriz destinada à identificação de estratégias discursivas evasivas. Os agentes são orientados a reconhecer e penalizar, de forma criteriosa e baseada em sinais linguísticos objetivos, ocorrências de linguagem vaga, uso reiterado de clichês, afirmações não fundamentadas ou generalizações excessivas que aparentem mascarar a ausência de conhecimento específico. Esta diretriz é operacionalizada por meio de exemplos anotados e regras heurísticas no *prompt*, com o objetivo de aumentar a sensibilidade do sistema a indícios de baixa substância conceitual sem comprometer a avaliação de respostas concisas e legítimas.

O *prompt* do Árbitro (C3) é estruturalmente diferente: além de receber os mesmos dados de entrada (enunciado, rubrica, contexto RAG e resposta do aluno), ele também recebe o `reasoning_chain` e as notas de ambos os corretores. Suas instruções incluem: (i) identificar se algum corretor foi excessivamente rígido ou cometeu “alucinação” de regras inexistentes; (ii) apoiar o corretor que melhor avaliou a precisão conceitual; e (iii) atribuir notas de forma independente, funcionando como mediação técnica do conflito.

Todas as saídas são exigidas em formato JSON estruturado (*AgentCorrection*), incluindo os campos `total_score`, `criteria_scores`, `reasoning_chain` e `feedback_text`. As notas são exigidas na escala absoluta (0 até o peso máximo de cada critério), e o *prompt*


inclui exemplos explícitos para evitar normalização indevida pelo modelo (por exemplo, atribuir 0,75 em vez de 3,0 em um critério de 4,0 pontos).

Os prompts completos utilizados na implementação — versões integrais dos prompts dos Corretores, do Árbitro e dos helpers — encontram-se nos Apêndices (ver Apêndice [B](#)).

5.4 MODELAGEM DO BANCO DE DADOS

O banco de dados relacional foi modelado para suportar as etapas de configuração, publicação, correção, revisão e consolidação. As entidades centrais do domínio incluem provas, questões, alunos, respostas, critérios de correção e pontuações por critério. A [Figura 7](#) apresenta uma visão simplificada dessas relações.

Figura 7 – Modelo entidade-relacionamento simplificado do domínio



Fonte: Elaborado pelos autores.

O esquema completo do banco de dados, com todas as tabelas e relacionamentos, é apresentado no [Apêndice A](#).

Mais do que armazenar entidades do domínio, a modelagem foi projetada para sustentar três requisitos do protótipo: (i) **rastreabilidade do processo** (o que foi feito, quando e em que estado), (ii) **revisão docente baseada em evidências** (inspecionar a composição da nota e ajustar com segurança) e (iii) **persistência e governança do pipeline** (registrar o resultado e reduzir ambiguidades em reprocessamentos).

5.4.1 Justificativa das entidades e relações

No centro do domínio, a prova (**exams**) funciona como agregador dos demais objetos: questões (**exam_questions**), anexos de referência (**attachments**), critérios associados e pesos, e respostas submetidas. Essa organização é intencional porque permite isolar o ciclo de vida de uma prova (por exemplo, DRAFT → PUBLISHED → GRADED/WARNING → FINALIZED) e, ao mesmo tempo, associar de forma inequívoca todo artefato produzido pelo pipeline ao contexto correto.

Para critérios de correção, a modelagem separa (i) um catálogo reutilizável de critérios (**grading_criteria**) e (ii) a parametrização específica por prova (**exam_criteria**). Essa tabela de associação permite que o mesmo critério seja reaproveitado em diferentes provas, mantendo, por prova, campos como **weight** e **max_points**. Tecnicamente, isso reduz duplicação e melhora consistência: ajustes de pesos e máximos tornam-se mudanças de configuração da prova, sem “replicar” o critério.

Para respostas, a entidade **student_answers** vincula explicitamente aluno, prova e questão, com restrição de unicidade (por exemplo, um aluno não responde duas vezes a mesma questão na mesma prova, salvo alteração deliberada da regra). Essa escolha reduz ambiguidade de rastreabilidade e evita que o pipeline produza múltiplos resultados concorrentes para o mesmo alvo.

Por fim, o detalhamento de nota foi normalizado na tabela **student_answer_criteria_scores**, com **uma linha por critério por resposta** e restrição de unicidade (resposta, critério). Esse desenho é superior a armazenar apenas uma nota total porque materializa a decomposição da avaliação e viabiliza inspeção e auditoria: o professor pode verificar onde a pontuação foi atribuída, comparar justificativas por critério e corrigir pontualmente sem perder o histórico de como a nota foi composta. Adicionalmente, armazenar **raw_score** e (opcionalmente) **weighted_score** dá suporte a cenários em que o peso do critério é tratado como configuração da prova, mantendo rastreabilidade do que foi pontuado e do que foi efetivamente computado.

Alguns campos merecem destaque por seu papel na rastreabilidade do processo:

- **status de prova e resposta**: permitem distinguir prova em rascunho, publicada,

em correção, corrigida e finalizada, assim como respostas submetidas e avaliadas;

- ***vector_status* de anexo**: indica se o material anexado foi indexado com sucesso na base vetorial, sinalizando situações de falha que podem afetar o RAG;
- **Indicadores de correção**: campos como *is_graded* e informações de divergência (por exemplo, detecção e valor) ajudam a controlar reprocessamentos e a direcionar revisão docente.

Em conjunto, essas escolhas permitem que a revisão docente opere sobre dados consistentes e contextualizados: o estado da prova e das respostas indica em que fase do fluxo o item se encontra; o detalhamento por critério torna a avaliação explicável e ajustável; e os indicadores de divergência e de correção ajudam a priorizar inspeção humana nos casos em que a própria IA sinaliza maior incerteza.

5.5 INTEGRAÇÕES E DECISÕES TÉCNICAS

O desenvolvimento priorizou integrações que mantivessem o sistema reproduzível em ambiente local e coerente com as necessidades do domínio educacional.

5.5.1 Integrações principais

- **PostgreSQL**: adotado para persistência relacional das entidades do domínio, com suporte a transações e integridade;
- **Migrações (Alembic)**: versionamento do esquema do banco via Alembic, permitindo evolução controlada e reprodutibilidade entre ambientes;
- **ChromaDB**: utilizado como *vector store* persistente para a estratégia de recuperação por similaridade;
- **Provedores de LLM e *embeddings***: integração por uma camada de compatibilidade para alternar provedores e parâmetros de execução;
- **Docker e Docker Compose**: padronização do ambiente de execução, reduzindo divergências de configuração entre máquinas.

Além dessas integrações, a execução do protótipo foi desenhada para ser parametrizável por ambiente. Em particular, a seleção do provedor/modelo de LLM e de *embeddings*, assim como parâmetros operacionais do pipeline (por exemplo, `LLM_TEMPERATURE`, `RAG_TOP_K` e `DIVERGENCE_THRESHOLD`) pode ser controlada via variáveis de ambiente, favorecendo reprodutibilidade e ajustes sem alteração do código.

5.5.2 Infraestrutura de experimentação

Para viabilizar a execução e a documentação dos experimentos descritos no [Capítulo 6](#), foi desenvolvido um *notebook* Jupyter (`experimento_tcc.ipynb`) que orquestra o experimento completo via API REST do *backend*. O *notebook* está organizado nas seguintes etapas:

1. **Setup**: registro do professor, autenticação, criação de turma e cadastro dos alunos sintéticos via API.
2. **Condição A (com RAG)**: criação da prova, *upload* do PDF de referência, cadastro de questões, critérios e respostas, publicação e *polling* até o status **GRADED**.
3. **Condição B (sem RAG)**: mesmo fluxo da Condição A, mas sem *upload* de PDF.
4. **Comparação A vs. B**: geração de tabelas pareadas com notas de C1, C2 e nota final por questão e por nível de qualidade.
5. **QA4 — Estabilidade**: execução de $R = 3$ repetições com $A_{rep} = 4$ respostas (uma por nível), mantendo RAG ativo.
6. **Exportação**: salvamento dos resultados em CSV e JSON na pasta `notebooks/results/`.

Toda a comunicação ocorre via *endpoints* da API REST, de modo que o *notebook* não acessa diretamente o banco de dados nem o pipeline de IA, garantindo que o experimento reflita o comportamento real do sistema em produção.

5.5.3 Disponibilização do código-fonte

Com o objetivo de apoiar reprodutibilidade, inspeção técnica e evolução incremental do protótipo, o código-fonte do sistema foi disponibilizado publicamente em um repositório GitHub. O repositório contém a implementação do *backend*, scripts de infraestrutura (por exemplo, Docker Compose) e instruções de execução e configuração. O acesso público está disponível em: [<https://github.com/savino0/ai-grading-system>](https://github.com/savino0/ai-grading-system) (Savino; Fernandes, 2026).

5.5.4 Decisões e *trade-offs*

- **Dois corretores e árbitro condicional**: reduz sensibilidade a uma única saída de LLM e prioriza consistência, ao custo de maior consumo computacional em casos divergentes;

- **Workflow com estado explícito:** favorece rastreabilidade e controle de execução, ao custo de maior complexidade estrutural em comparação a uma sequência linear;
- **RAG por prova:** melhora a aderência ao material didático e reduz alucinações, mas depende da qualidade e da indexação bem-sucedida dos anexos;
- **Não-determinismo de LLMs:** mitigado por configuração de baixa estocasticidade (temperatura = 0,0) e por revisão docente, mas não eliminado completamente.

Em conjunto, as decisões de arquitetura e implementação buscam equilibrar viabilidade técnica, rastreabilidade e utilidade prática no contexto de correção de respostas discursivas com apoio à revisão do professor. O próximo capítulo apresenta os resultados obtidos a partir da execução do procedimento experimental sobre o sistema aqui descrito.

6 RESULTADOS E DISCUSSÕES

Este capítulo apresenta os resultados obtidos a partir da execução do procedimento experimental descrito no [Capítulo 4](#). A avaliação seguiu o desenho de estudo de caso controlado, com duas condições — Condição A (com RAG) e Condição B (sem RAG) — aplicadas sobre o **mesmo conjunto pareado** de respostas: uma prova com $Q = 3$ questões discursivas e $A = 4$ respostas sintéticas por questão, totalizando 12 respostas avaliadas em ambas as condições. Os corretores C1 e C2 foram executados em **paralelo** via LangGraph, com verificação de divergência e arbitragem condicional. Os resultados são organizados de acordo com as questões avaliativas (QA1 a QA4), seguidos de uma análise de desempenho temporal e de uma discussão integrada.

6.1 CONFIGURAÇÃO DO EXPERIMENTO

O [Quadro 5](#) resume os parâmetros efetivamente utilizados na execução do experimento, conforme definido na metodologia.

Quadro 5 – Parâmetros efetivos do experimento

Parâmetro	Valor utilizado
Provedor/Modelo do LLM	Google Gemini / <code>gemini-2.5-flash</code>
Temperatura do LLM	0,0 (baixa estocasticidade)
Top- k do RAG (Condição A)	$k = 4$ (<code>RAG_TOP_K=4</code>)
Top- k do RAG (Condição B)	$k = 0$ (RAG desativado)
Limiar de divergência	2,0 pontos (<code>DIVERGENCE_THRESHOLD=2.0</code>)
Questões (Q)	3
Respostas por questão (A)	4 (excelente, intermediária, fraca, fora do tema)
Total de respostas por condição	12
Repetições para estabilidade (R)	3
Respostas repetidas (A_{rep})	4 (uma por nível de qualidade)
Execução dos corretores	Paralela (C1 e C2 simultâneos via LangGraph)
Dados entre condições	Pareados (mesmas respostas em A e B)
Versão dos <i>prompts</i>	v3 (pareados, paralelos, otimizados)
Critérios de avaliação	5 critérios: Correção técnica (35%), Completude (25%), Precisão terminológica (20%), Uso de exemplos (10%), Análise crítica (10%)

Fonte: Elaborado pelos autores.

A prova versou sobre o tema *Algoritmos e Estrutura de Dados*, com três questões discursivas que exigiam raciocínio comparativo e análise de complexidade algorítmica. As questões formuladas foram:

- **Q1:** Diferenciação entre *Array* (vetor estático) e *Lista Encadeada*, abrangendo alocação de memória, acesso a elementos, operações de inserção e remoção, e análise de complexidade $O(n)$.
- **Q2:** Comparação entre os algoritmos de ordenação *Merge Sort* e *Quick Sort*, abordando estabilidade, comportamento no pior caso e consumo de espaço auxiliar.
- **Q3:** Propriedades que definem uma *Árvore Binária de Busca* (BST) balanceada versus não balanceada, incluindo propriedades estruturais e complexidade das operações de busca, inserção e remoção.

Os materiais de referência consistiram em documentos em formato PDF contendo o conteúdo programático da disciplina, indexados vetorialmente no ChromaDB para recuperação na Condição A.

6.1.1 Respostas sintéticas

Conforme descrito na metodologia, as respostas foram elaboradas pelos autores em quatro níveis de qualidade, visando cobrir cenários típicos e casos-limite. O **mesmo conjunto** de 12 respostas foi utilizado em ambas as condições (A e B), garantindo o pareamento dos dados e permitindo isolar o efeito do RAG. O [Quadro 6](#) apresenta a caracterização de cada nível.

Quadro 6 – Caracterização dos níveis de qualidade das respostas sintéticas

Nível	Descrição
Excelente	Resposta completa, conceitualmente correta, com análise de complexidade e exemplos.
Intermediária	Resposta parcialmente correta, com cobertura razoável dos conceitos, mas superficial e sem exemplos.
Fraca	Resposta incompleta, com erros conceituais, complexidades incorretas ou terminologia equivocada.
Fora do tema	Resposta que não aborda o assunto solicitado ou apresenta conteúdo completamente irrelevante.

Fonte: Elaborado pelos autores.

6.2 QA1 — EXECUÇÃO END-TO-END

A primeira questão avaliativa verifica se o sistema completa o fluxo de configuração, publicação, processamento em *background*, correção, persistência e disponibilização para revisão docente.

6.2.1 Resultados

O [Quadro 7](#) apresenta o resultado de cada etapa do fluxo de execução *end-to-end*. Todas as 13 etapas foram concluídas com sucesso.

Quadro 7 – Verificação de execução *end-to-end* do sistema

Etapa	Status	Observações
Cadastro da prova e questões	Sim	3 questões cadastradas com sucesso
Anexação de materiais (PDF)	Sim	Material didático anexado corretamente
Definição de critérios e rubrica	Sim	5 critérios definidos com pesos configuráveis
Inserção das respostas dos alunos	Sim	12 respostas inseridas (4 por questão)
Publicação da prova	Sim	Prova publicada e disponível para correção
Indexação vetorial dos anexos	Sim	<i>Chunks</i> indexados no ChromaDB
Correção C1 (Corretor 1)	Sim	12 correções geradas em paralelo com C2
Correção C2 (Corretor 2)	Sim	12 correções geradas em paralelo com C1
Verificação de divergência	Sim	Verificada para todas as 12 respostas
Arbitragem (quando acionada)	Sim	Árbitro disponível; acionado condicionalmente
Persistência dos resultados	Sim	Dados persistidos no PostgreSQL
Disponibilização para revisão	Sim	Resultados acessíveis via API REST

Fonte: Elaborado pelos autores.

As [Tabela 1](#) e [Tabela 2](#) apresentam a completude estrutural dos artefatos gerados em cada condição, verificando se cada resposta corrigida produziu os campos esperados (notas individuais de C1 e C2, nota final consensuada e indicação de divergência).

Tabela 1 – Completude estrutural dos artefatos gerados — Condição A (com RAG)

Questão	Nível	Nota C1	Nota C2	Nota final	Divergência	Completo?
Q1	Excelente	10,00	10,00	10,00	Não	Sim
Q1	Intermediária	7,59	8,65	8,65	Não	Sim
Q1	Fraca	0,92	0,00	0,00	Não	Sim
Q1	Fora tema	0,00	0,00	0,00	Não	Sim
Q2	Excelente	10,00	10,00	10,00	Não	Sim
Q2	Intermediária	8,29	9,47	9,47	Não	Sim
Q2	Fraca	1,89	2,55	2,55	Não	Sim
Q2	Fora tema	0,00	0,00	0,00	Não	Sim
Q3	Excelente	10,00	10,00	10,00	Não	Sim
Q3	Intermediária	10,00	9,80	9,80	Não	Sim
Q3	Fraca	0,00	0,67	0,67	Não	Sim
Q3	Fora tema	0,00	0,00	0,00	Não	Sim
Completude total:						12/12 (100%)

Fonte: Elaborado pelos autores.

Tabela 2 – Completude estrutural dos artefatos gerados — Condição B (sem RAG)

Questão	Nível	Nota C1	Nota C2	Nota final	Divergência	Completo?
Q1	Excelente	10,00	10,00	10,00	Não	Sim
Q1	Intermediária	6,24	6,73	6,73	Não	Sim
Q1	Fraca	0,51	0,00	0,00	Não	Sim
Q1	Fora tema	0,00	0,00	0,00	Não	Sim
Q2	Excelente	10,00	10,00	10,00	Não	Sim
Q2	Intermediária	8,88	8,88	8,88	Não	Sim
Q2	Fraca	2,55	1,63	1,63	Não	Sim
Q2	Fora tema	0,00	0,00	0,00	Não	Sim
Q3	Excelente	10,00	10,00	10,00	Não	Sim
Q3	Intermediária	9,80	9,80	9,80	Não	Sim
Q3	Fraca	0,00	1,22	1,22	Não	Sim
Q3	Fora tema	0,00	0,00	0,00	Não	Sim
Completude total:						12/12 (100%)

Fonte: Elaborado pelos autores.

6.2.2 Análise

O sistema executou o fluxo completo sem interrupções ou falhas em nenhuma das 12 etapas verificadas. As 12 respostas de cada condição foram processadas e persistidas com sucesso no PostgreSQL, e os resultados ficaram imediatamente disponíveis para revisão docente por meio dos *endpoints* da API REST. Os corretores C1 e C2 foram executados em paralelo via LangGraph, reduzindo o tempo total de correção em comparação com a execução sequencial.

A completude estrutural atingiu 100% em ambas as condições (24/24 correções), superando amplamente o critério mínimo de 95% definido na metodologia. Cada correção produziu todos os campos esperados: notas individuais de C1 e C2, nota final consensuada, valor de divergência e método de consenso aplicado (`mean_2` em todos os casos). Em nenhuma das 24 respostas foi detectada divergência acima do limiar, confirmando a consistência interna dos corretores para este conjunto de respostas.

O fluxo *end-to-end* demonstra que a arquitetura proposta — envolvendo cadastro, indexação vetorial, dupla correção automatizada em paralelo, verificação de divergência, arbitragem condicional, persistência e revisão — é tecnicamente funcional e operacionalmente viável nas duas configurações testadas.

6.3 QA2 — UTILIDADE DO RAG

A segunda questão avaliativa investiga se, ao ativar o RAG (Condição A), as pontuações se alteram em relação à Condição B (sem RAG), e de que forma o material de referência influencia o rigor da correção. As duas condições foram avaliadas sobre o **mesmo conjunto pareado** de respostas, permitindo isolar o efeito do RAG.

6.3.1 Comparação de notas

A [Tabela 3](#) apresenta a comparação das notas finais (após consenso) entre as duas condições, para cada resposta.

Tabela 3 – Comparação de notas finais — Condição A (com RAG) vs. Condição B (sem RAG)

Questão	Nível	Nota A (RAG)	Nota B (sem RAG)	Δ (A–B)
Q1	Excelente	10,00	10,00	0,00
Q1	Intermediária	8,65	6,73	+1,92
Q1	Fraca	0,00	0,00	0,00
Q1	Fora tema	0,00	0,00	0,00
Q2	Excelente	10,00	10,00	0,00
Q2	Intermediária	9,47	8,88	+0,59
Q2	Fraca	2,55	1,63	+0,92
Q2	Fora tema	0,00	0,00	0,00
Q3	Excelente	10,00	10,00	0,00
Q3	Intermediária	9,80	9,80	0,00
Q3	Fraca	0,67	1,22	–0,55
Q3	Fora tema	0,00	0,00	0,00

Fonte: Elaborado pelos autores.

A [Tabela 4](#) consolida os resultados por nível de qualidade, permitindo identificar em quais faixas o RAG exerce maior influência.

Tabela 4 – Comparação de notas médias por nível de qualidade

Nível	Média A (RAG)	Média B (sem RAG)	Δ (A–B)
Excelente	10,00	10,00	0,00
Intermediária	9,31	8,47	+0,84
Fraca	1,07	0,95	+0,12
Fora tema	0,00	0,00	0,00

Fonte: Elaborado pelos autores.

Os resultados revelam um efeito positivo do RAG concentrado no nível intermediário. O impacto mais expressivo ocorreu no nível “Intermediária” ($\Delta = +0,84$ na média), com

destaque para Q1 ($\Delta = +1,92$) e Q2 ($\Delta = +0,59$). No nível “Frac”, o RAG produziu um efeito positivo modesto ($\Delta = +0,12$ na média), com Q2 apresentando a maior diferença ($\Delta = +0,92$), enquanto Q3 registrou leve redução ($\Delta = -0,55$). Os extremos — “Excelente” e “Fora do tema” — apresentaram notas idênticas em ambas as condições.

6.3.2 Efeito do RAG sobre a precisão avaliativa

O resultado mais relevante desta comparação é que o RAG auxilia os corretores a identificar com maior precisão o conhecimento parcial presente em respostas intermediárias. Ao dispor do material didático recuperado, o corretor pode comparar a resposta do aluno com o conteúdo de referência, reconhecendo acertos que, sem a referência, poderiam ser subestimados.

A explicação reside na natureza do mecanismo de RAG como “gabarito contextual”: com acesso ao material de referência, o corretor distingue com maior acurácia entre conceitos corretos, parcialmente corretos e ausentes. Sem o RAG, o corretor baseia-se exclusivamente no conhecimento paramétrico do modelo de linguagem, que captura o domínio de forma genérica e pode não reproduzir com fidelidade o recorte conceitual específico adotado na disciplina. A presença do material recuperado funciona, portanto, como um referencial explícito que restringe o espaço de interpretação do corretor, tornando a avaliação mais aderente ao conteúdo programático.

Para os níveis “Excelente” e “Fora do tema”, as notas foram idênticas em ambas as condições. Esses extremos são esperados: o material didático não altera a avaliação de respostas claramente corretas ou completamente irrelevantes, pois o LLM identifica esses casos com igual precisão com ou sem contexto adicional.

A leve redução observada em Q3/Frac ($\Delta = -0,55$) ilustra que o RAG não opera de forma uniforme: ao dispor do material de referência para a questão sobre BSTs, o corretor pode ter exigido maior rigor terminológico, penalizando mais a resposta fraca do que na ausência de contexto. Este resultado reforça que o RAG aumenta a especificidade avaliativa, podendo resultar tanto em notas maiores (quando o aluno demonstra conhecimento parcial compatível com o material) quanto em notas menores (quando o material expõe com mais clareza as lacunas da resposta).

6.3.3 Análise

A comparação pareada entre as condições A e B revela que o RAG agrega valor ao processo de correção de forma coerente com o esperado. O efeito concentra-se no nível intermediário ($\Delta = +0,84$), onde o material recuperado fornece ao corretor a referência necessária para identificar com maior precisão o conhecimento parcial demonstrado. As

notas finais da Condição A apresentaram coerência com os níveis de qualidade: excelente (10,00), intermediária (9,31), fraca (1,07) e fora do tema (0,00), demonstrando a capacidade discriminativa do sistema em ambas as condições.

Em cenários com turmas reais, onde respostas com qualidade intermediária são mais frequentes e mais variadas do que as respostas sintéticas deste experimento, espera-se que o impacto positivo do RAG seja proporcionalmente mais consistente.

6.4 QA3 — ARBITRAGEM POR DIVERGÊNCIA

A terceira questão avaliativa verifica se o mecanismo de divergência e acionamento condicional do terceiro corretor (árbitro) funciona conforme especificado. O critério de sucesso é que o árbitro deve ser acionado se e somente se $|C1 - C2| > 2,0$ pontos.

6.4.1 Resultados

A [Tabela 5](#) apresenta a verificação de divergência para todas as 12 respostas da Condição A, detalhando as notas individuais de C1 e C2 e o valor absoluto de divergência.

Tabela 5 – Verificação de divergência — Condição A (com RAG)

Q	Nível	C1	C2	$ C1 - C2 $	Árbitro?	Final
Q1	Excelente	10,00	10,00	0,00	Não	10,00
Q1	Intermediária	7,59	8,65	1,06	Não	8,65
Q1	Fraca	0,92	0,00	0,92	Não	0,00
Q1	Fora tema	0,00	0,00	0,00	Não	0,00
Q2	Excelente	10,00	10,00	0,00	Não	10,00
Q2	Intermediária	8,29	9,47	1,18	Não	9,47
Q2	Fraca	1,89	2,55	0,66	Não	2,55
Q2	Fora tema	0,00	0,00	0,00	Não	0,00
Q3	Excelente	10,00	10,00	0,00	Não	10,00
Q3	Intermediária	10,00	9,80	0,20	Não	9,80
Q3	Fraca	0,00	0,67	0,67	Não	0,67
Q3	Fora tema	0,00	0,00	0,00	Não	0,00

Fonte: Elaborado pelos autores.

A [Tabela 6](#) apresenta os resultados equivalentes para a Condição B (sem RAG).

Tabela 6 – Verificação de divergência — Condição B (sem RAG)

Q	Nível	C1	C2	C1–C2	Árbitro?	Final
Q1	Excelente	10,00	10,00	0,00	Não	10,00
Q1	Intermediária	6,24	6,73	0,49	Não	6,73
Q1	Fraca	0,51	0,00	0,51	Não	0,00
Q1	Fora tema	0,00	0,00	0,00	Não	0,00
Q2	Excelente	10,00	10,00	0,00	Não	10,00
Q2	Intermediária	8,88	8,88	0,00	Não	8,88
Q2	Fraca	2,55	1,63	0,92	Não	1,63
Q2	Fora tema	0,00	0,00	0,00	Não	0,00
Q3	Excelente	10,00	10,00	0,00	Não	10,00
Q3	Intermediária	9,80	9,80	0,00	Não	9,80
Q3	Fraca	0,00	1,22	1,22	Não	1,22
Q3	Fora tema	0,00	0,00	0,00	Não	0,00

Fonte: Elaborado pelos autores.

6.4.2 Padrões de divergência

Em nenhum dos 24 casos avaliados (12 por condição) a divergência entre C1 e C2 ultrapassou o limiar de 2,0 pontos. O valor máximo de divergência observado foi de 1,22 pontos (Q3, Fraca, Condição B) e 1,18 pontos (Q2, Intermediária, Condição A). Consequentemente, o árbitro não foi acionado em nenhum caso, e o método de consenso aplicado em todas as correções foi `mean_2` (média entre C1 e C2).

As divergências concentraram-se nos níveis “Intermediária” e “Fraca”, conforme esperado: respostas nos extremos da escala (“Excelente” e “Fora do tema”) geraram convergência perfeita entre os corretores ($|C1-C2| = 0,00$) em todos os casos. Nos níveis “Excelente” e “Fora do tema”, as avaliações foram idênticas nas duas condições, confirmando que o RAG não altera a avaliação de respostas inequívocas.

A maior variabilidade nas respostas de qualidade intermediária e fraca é coerente com a natureza desses casos: respostas parcialmente corretas envolvem julgamentos de valor sobre quais conceitos foram abordados e com que profundidade, o que introduz divergência natural entre avaliadores independentes.

6.4.3 Análise

O critério de sucesso da QA3 — o árbitro deve ser acionado se e somente se $|C1-C2| > 2,0$ — foi atendido integralmente. O mecanismo de verificação de divergência funcionou corretamente: calculou a diferença absoluta entre C1 e C2 para todos os 24 casos e não acionou o árbitro em nenhuma situação em que o limiar não foi ultrapassado.

A convergência entre os corretores em todas as respostas (com divergência máxima

de 1,22 pontos) pode ser atribuída à combinação de fatores: (i) temperatura 0,0 do modelo, que minimiza a variabilidade estocástica; (ii) critérios de avaliação com pesos explícitos; e (iii) *prompts* otimizados para especificidade graduada. A baixa divergência reforça a consistência interna do sistema de dupla correção, indicando que os dois corretores independentes chegam a avaliações próximas mesmo sem coordenação entre si.

Embora o árbitro não tenha sido acionado neste experimento, o mecanismo está implementado e disponível: em cenários reais com maior volume de respostas e maior heterogeneidade nas redações dos alunos, espera-se que divergências superiores ao limiar ocorram com maior frequência, tornando a arbitragem relevante para garantir a qualidade do consenso.

6.5 QA4 — ESTABILIDADE OPERACIONAL

A quarta questão avaliativa verifica se, com configurações de baixa estocasticidade (temperatura = 0,0), o sistema produz saídas com baixa variabilidade em execuções repetidas do mesmo caso. Conforme definido na metodologia, selecionou-se um subconjunto de $A_{rep} = 4$ respostas (uma por nível de qualidade) referentes à questão Q2, e repetiu-se a correção $R = 3$ vezes.

6.5.1 Resultados

A [Tabela 7](#) apresenta as notas finais obtidas em cada repetição e as estatísticas de variabilidade por nível de qualidade.

Tabela 7 – Estabilidade das notas em execuções repetidas ($R = 3$) — Questão Q2

Nível	R_1	R_2	R_3	Média	DP	Var. máx.
Excelente	10,00	10,00	10,00	10,00	0,00	0,00
Intermediária	9,88	9,04	9,08	9,33	0,47	0,84
Fraca	0,51	1,71	1,88	1,37	0,75	1,37
Fora tema	0,00	0,00	0,00	0,00	0,00	0,00

Fonte: Elaborado pelos autores.

6.5.2 Análise

Os resultados revelam dois padrões distintos de estabilidade. Os níveis “Excelente” e “Fora do tema” apresentaram variação nula (0,00 ponto), demonstrando reprodutibilidade perfeita para respostas nos extremos da escala de qualidade. Os níveis “Intermediária” e “Fracamente” apresentaram variação máxima de 0,84 e 1,37 pontos, respectivamente.

O nível “Intermediária” atendeu ao critério de sucesso ($\leq 1,0$ ponto de variação máxima), com desvio-padrão de 0,47 e média de 9,33. O nível “Fracas” ultrapassou o limiar, com variação máxima de 1,37 pontos e desvio-padrão de 0,75.

Essa diferença de estabilidade é coerente com os achados da QA3: respostas fracas são as mais ambíguas e as que apresentam maior variação nas notas individuais de C1 e C2. Enquanto respostas excelentes e fora do tema permitem avaliação inequívoca (nota máxima ou zero), respostas parcialmente corretas — especialmente as fracas, onde erros conceituais coexistem com alguma terminologia adequada — envolvem julgamentos de valor que introduzem variabilidade natural mesmo com temperatura 0,0.

As médias por nível ($10,00 > 9,33 > 1,37 > 0,00$) confirmam a hierarquia de discriminação do sistema. O critério QA4 foi plenamente atendido para os níveis extremos e para o nível intermediário, e parcialmente atendido para o nível fraco. Em cenários de uso real, a variabilidade residual nos níveis ambíguos seria mitigada pela etapa de revisão docente, que permite ao professor inspecionar e ajustar as notas antes da consolidação final.

6.6 DESEMPENHO TEMPORAL

Para avaliar a viabilidade operacional do sistema em termos de tempo de execução, foram registrados os tempos de processamento de cada condição experimental. A [Tabela 8](#) apresenta os resultados.

Tabela 8 – Tempos de execução do *pipeline* de correção

Etapa	Tempo (s)	Observações
Condição A (com RAG) — 12 respostas	155	$\approx 12,9$ s/resposta
Condição B (sem RAG) — 12 respostas	140	$\approx 11,7$ s/resposta
QA4 — Run 1/3 (4 respostas, RAG ativo)	55	$\approx 13,8$ s/resposta
QA4 — Run 2/3 (4 respostas, RAG ativo)	55	$\approx 13,8$ s/resposta
QA4 — Run 3/3 (4 respostas, RAG ativo)	55	$\approx 13,8$ s/resposta

Fonte: Elaborado pelos autores.

6.6.1 Análise

O tempo total de correção para 12 respostas discursivas na Condição A foi de 155 segundos ($\approx 12,9$ s/resposta), e na Condição B foi de 140 segundos ($\approx 11,7$ s/resposta). A Condição A foi ligeiramente mais lenta, o que é esperado em razão da etapa adicional de recuperação vetorial no ChromaDB antes da geração das correções.

A correção de questões discursivas é reconhecida na literatura como uma tarefa intensiva em trabalho docente (Schneider; Schenk; Niklaus, 2024), compondo parcela relevante da carga extraclasse dos professores (Barbosa et al., 2021). O sistema automatizado processou as 12 respostas em aproximadamente 2 minutos e meio (Condição A), o que representa uma compressão expressiva do tempo dedicado à correção inicial em relação à avaliação manual.

Cabe ressaltar que a comparação direta com correção humana não implica equivalência qualitativa: o sistema automatizado produz avaliações que devem ser revisadas pelo docente. No entanto, o ganho de tempo é substancial mesmo considerando a etapa de revisão, pois o professor dispõe de notas pré-atribuídas e pode concentrar-se na validação e ajuste pontual em vez de avaliar cada resposta *ab initio*.

Os tempos dos três *runs* do QA4 foram consistentes (55 s cada), confirmando a estabilidade operacional do *pipeline* para execuções repetidas.

6.7 DISCUSSÃO INTEGRADA

6.7.1 Síntese dos critérios de sucesso

O Quadro 8 resume o atendimento aos critérios de sucesso definidos na metodologia.

Quadro 8 – Síntese do atendimento aos critérios de sucesso

QA	Critério	Resultado obtido	Atendido?
QA1	100% das respostas processadas	12/12 (100%)	Sim
QA1	Completeness $\geq 95\%$	100%	Sim
QA2	Efeito do RAG observável	Δ Intermediária=+0,84; Δ Fraca=+0,12	Sim
QA3	Árbitro acionado somente se $ \text{diff} > 2,0$	Nenhum caso ultrapassou o limiar; árbitro não acionado	Sim
QA4	Variação $\leq 1,0$ ponto	Extremos: 0,00; Intermediária: 0,84; Fraca: 1,37	Parcial

Fonte: Elaborado pelos autores.

6.7.2 Viabilidade técnica

Os resultados demonstram que o sistema é tecnicamente viável para a tarefa proposta. O fluxo *end-to-end* foi executado integralmente sem falhas, desde o cadastro da prova até a exportação dos relatórios finais, comprovando que a arquitetura baseada em LLM com dupla correção independente em paralelo, verificação de divergência e arbitragem condicional é funcional.

Os artefatos gerados pelo sistema são estruturados e rastreáveis: cada correção contém a nota final, as notas individuais de cada corretor, o valor de divergência e o método de consenso aplicado. Essa estrutura permite ao docente não apenas verificar a nota atribuída, mas compreender como ela foi obtida, facilitando a revisão e o ajuste quando necessário.

A integração com o ChromaDB para indexação vetorial dos materiais didáticos funcionou conforme especificado, permitindo que o mecanismo de RAG recuperasse trechos relevantes para contextualizar as correções. A persistência no PostgreSQL garantiu a durabilidade e a rastreabilidade dos dados ao longo de todo o fluxo de execução.

6.7.3 Viabilidade operacional

Do ponto de vista operacional, o sistema preserva a autoridade docente ao posicionar a correção automatizada como etapa de apoio, não de decisão final. O professor tem acesso aos resultados por meio da API REST, que permite integração com outros sistemas institucionais.

O sistema demonstrou operação autônoma durante o fluxo de correção, sem necessidade de intervenção manual entre as etapas. O tempo de execução de aproximadamente 155 segundos para 12 respostas (Condição A) indica que a etapa de correção automatizada é concluída em tempo substancialmente inferior ao que seria demandado pela correção manual, ainda que uma comparação rigorosa exigiria mensuração controlada do tempo docente real para o mesmo conjunto de respostas.

6.7.4 Contribuição do RAG

Os dados pareados da comparação entre Condições A e B revelam que o mecanismo de RAG aumenta a especificidade avaliativa: ao dispor do material didático, o corretor passa a avaliar com maior aderência ao conteúdo programático da disciplina, em vez de se apoiar apenas no conhecimento paramétrico genérico do modelo. Esse aumento de especificidade não implica necessariamente notas mais altas, podendo resultar tanto em notas maiores, quando o material confirma acertos parciais que poderiam ser subestimados, quanto em notas menores, quando o material expõe lacunas que passariam despercebidas sem a referência.

No experimento, o efeito predominante foi positivo no nível intermediário ($\Delta = +0,84$), onde o material recuperado forneceu ao corretor a referência necessária para reconhecer o conhecimento parcial demonstrado. Já no nível fraco, o efeito foi modesto na média ($\Delta = +0,12$), com Q3 registrando leve redução ($\Delta = -0,55$), evidência de que o RAG também pode tornar o corretor mais rigoroso quando o material deixa mais clara a

distância entre a resposta e o conteúdo esperado.

Os níveis “Excelente” e “Fora do tema” não foram afetados pelo RAG, resultado esperado: o LLM identifica esses casos com igual precisão independentemente do contexto adicional, pois a distinção entre uma resposta completa e uma resposta irrelevante não requer referência ao material didático.

6.7.5 Limitações observadas

Diversas limitações foram identificadas durante a execução do experimento e devem ser consideradas na interpretação dos resultados:

1. **Respostas sintéticas:** O conjunto de 12 respostas foi elaborado pelos autores em quatro níveis bem definidos de qualidade, o que facilita a discriminação pelo sistema. Respostas reais de alunos apresentam maior variabilidade, ambiguidade e gradações intermediárias de qualidade que não foram contempladas neste experimento.
2. **Escala reduzida:** A prova utilizada contém apenas 3 questões de uma única disciplina (Algoritmos e Estrutura de Dados), limitando a generalização dos resultados para provas com maior número de questões, outras disciplinas ou enunciados de natureza diferente.
3. **Modelo único:** Todos os experimentos foram realizados com o modelo `gemini-2.5-flash`. Os resultados podem variar com outros modelos de linguagem, tanto em termos de qualidade das avaliações quanto de estabilidade operacional.
4. **Ausência de comparação com correção humana:** O experimento não incluiu correção humana como referência (*ground truth*), impossibilitando a mensuração da acurácia absoluta do sistema em relação ao julgamento docente.
5. **Árbitro não exercitado:** Neste experimento, nenhuma divergência ultrapassou o limiar de 2,0 pontos, de modo que o mecanismo de arbitragem não foi exercitado em condições reais. A validação empírica do árbitro fica, portanto, condicionada a experimentos futuros com maior volume e heterogeneidade de respostas.

7 CONCLUSÃO

Este trabalho apresentou o desenvolvimento e a avaliação de um sistema de correção automatizada de provas discursivas baseado em múltiplos agentes de IA, com suporte ao RAG e mecanismo de arbitragem condicional por divergência. O objetivo principal foi implementar um protótipo funcional capaz de executar o fluxo completo, desde a configuração da prova até a disponibilização dos resultados para revisão docente, produzindo artefatos estruturados e revisáveis: nota final, notas por critério e indicação de divergência entre corretores.

Os resultados obtidos no estudo de caso controlado, com dados pareados entre as condições experimentais, indicam que:

1. **QA1 — Execução *end-to-end*:** o sistema completou todas as etapas do fluxo sem falhas nas duas condições testadas, processando e persistindo 100% das respostas previstas (24/24), com completude estrutural de 100%. Cada correção produziu nota final, notas individuais de C1 e C2, valor de divergência e método de consenso, atendendo plenamente ao critério de sucesso definido na metodologia.
2. **QA2 — Utilidade do RAG:** a comparação pareada entre Condição A (com RAG) e Condição B (sem RAG), utilizando o mesmo conjunto de respostas em ambas as condições, revelou que o RAG aumenta a especificidade avaliativa, com efeito mais expressivo no nível intermediário ($\Delta = +0,84$ na média), especialmente em Q1 ($\Delta = +1,92$). No nível fraco, o efeito foi modesto na média ($\Delta = +0,12$), com casos de leve aumento de rigor (Q3: $\Delta = -0,55$), evidenciando que o material recuperado funciona como referencial que restringe o espaço de interpretação do corretor. Os extremos (“Excelente” e “Fora do tema”) não foram afetados ($\Delta = 0,00$).
3. **QA3 — Arbitragem por divergência:** em nenhum dos 24 casos avaliados (12 por condição) a divergência entre C1 e C2 ultrapassou o limiar de 2,0 pontos. O valor máximo observado foi 1,22 pontos. O árbitro não foi acionado, e o método de consenso `mean_2` foi aplicado em todas as correções. O critério de sucesso (árbitro acionado somente quando $|C1 - C2| > 2,0$) foi atendido integralmente: o mecanismo calculou divergências corretamente e não realizou acionamento indevido.
4. **QA4 — Estabilidade operacional:** nas três repetições ($R = 3$) sobre a questão Q2, os níveis “Excelente” e “Fora do tema” apresentaram variação nula (0,00 ponto), demonstrando reprodutibilidade perfeita nos extremos da escala. O nível “Intermediária” (variação máxima de 0,84) atendeu ao critério de $\leq 1,0$ ponto. O

nível “Frac” (variação máxima de 1,37, $DP = 0,75$) ultrapassou o limiar, refletindo a ambiguidade inerente a respostas com erros conceituais parciais. A hierarquia de médias ($10,00 > 9,33 > 1,37 > 0,00$) confirma a capacidade discriminativa do sistema.

Do ponto de vista arquitetural, a combinação de FastAPI para o *backend*, LangGraph para orquestração do pipeline com corretores paralelos, LangChain para integração com LLMs, ChromaDB para armazenamento vetorial e PostgreSQL para persistência relacional mostrou-se viável e funcionalmente coerente. A comunicação entre o *notebook* de experimentação e o sistema ocorreu integralmente via API REST, o que garantiu que os resultados refletissem o comportamento real do sistema em produção.

Do ponto de vista operacional, o sistema preserva a autoridade docente ao posicionar a correção automatizada como etapa de apoio: o professor tem acesso às notas individuais de cada corretor, ao valor de divergência e à nota final consensuada, podendo validar ou ajustar cada resultado antes da consolidação. O tempo de execução para as 12 respostas da Condição A foi de 155 segundos ($\approx 12,9$ s/resposta), e os três *runs* do QA4 foram consistentes (55 s cada), indicando estabilidade operacional do pipeline.

É importante reconhecer as limitações do estudo. O escopo restrito (uma disciplina, três questões, respostas sintéticas em quatro níveis bem definidos) não permite generalizações amplas sobre eficácia educacional ou desempenho em contextos reais. A ausência de gabarito humano como referência impede afirmar que as notas atribuídas pelo sistema são “corretas”, apenas que são internamente consistentes e estruturalmente completas. Adicionalmente, o mecanismo de arbitragem não foi exercitado empiricamente neste experimento, pois nenhuma divergência ultrapassou o limiar configurado; sua validação em condições reais fica condicionada a estudos com maior volume e heterogeneidade de respostas. Os resultados devem ser interpretados como evidência de viabilidade técnica e operacional do protótipo, não como validação pedagógica conclusiva.

7.1 TRABALHOS FUTUROS

Com base nos resultados e limitações identificados, sugere-se as seguintes direções para trabalhos futuros:

- **Validação com respostas humanas reais:** aplicar o sistema em turmas reais para avaliar a concordância entre notas atribuídas pela IA e notas atribuídas por docentes, utilizando métricas como coeficiente Kappa e correlação de Pearson.
- **Exercitação empírica do árbitro:** ampliar o conjunto de respostas e diversificar os perfis de qualidade de modo a provocar divergências acima do limiar, permitindo

validar o mecanismo de arbitragem em condições reais e avaliar o impacto da regra de consenso *closest-pair* sobre a nota final.

- **Estudo comparativo multi-modelo:** avaliar o desempenho do pipeline com diferentes provedores de LLM (OpenAI, Anthropic, modelos locais via Ollama), comparando qualidade das correções, estabilidade operacional e custo por resposta.
- **Análise aprofundada do impacto do RAG:** expandir a comparação A vs. B com maior diversidade de questões, disciplinas e materiais didáticos, investigando em quais contextos o efeito de especificidade avaliativa proporcionado pelo RAG é mais significativo e consistente.
- **Interface de revisão docente completa:** expandir a interface para incluir ajuste de nota por critério, anotações do professor e relatórios pedagógicos que identifiquem lacunas de aprendizado e tendências da turma.
- **Escalabilidade e implantação:** avaliar o sistema em cenários com dezenas de alunos e múltiplas provas simultâneas, otimizando gerenciamento de *rate limits* e custos de API.
- **Deteção de plágio e integridade acadêmica:** integrar mecanismos de detecção de similaridade entre respostas e de conteúdo gerado por IA, contribuindo para a integridade dos processos avaliativos.

REFERÊNCIAS

AVCU, A. Employing a Hierarchical Rater Models for Automated Scoring: Scope Review on the Application in Educational Assessment. *Malaysian Online Journal of Educational Technology*, v. 13, n. 2, p. 37–47, abr. 2025. ISSN 2289-2990. Disponível em: <https://mojet.net/index.php/mojet/article/view/569>. Acesso em: 12 maio 2025. Citado 4 vezes nas páginas 28, 30, 32 e 35.

BARBOSA, A. et al. Tempo de trabalho e de ensino: composição da jornada de trabalho dos professores paulistas. *Educação e Pesquisa*, v. 47, p. e235807, 2021. ISSN 1678-4634, 1517-9702. Disponível em: http://www.scielo.br/scielo.php?script=sci_arttext&pid=S1517-97022021000100770&tlng=pt. Acesso em: 29 abr. 2025. Citado 3 vezes nas páginas 3, 9 e 78.

BARROSO, I. d. N.; REIS, J. F. d.; AMORIM, V. P. R. Subjetividade na avaliação da aprendizagem. *Research, Society and Development*, v. 10, n. 3, p. e18410313234–e18410313234, mar. 2021. ISSN 2525-3409. Disponível em: <https://rsdjournal.org/index.php/rsd/article/view/13234>. Acesso em: 1 abr. 2025. Citado 2 vezes nas páginas 7 e 10.

BECKFORD, W. *Revisit from 2024: The current Status and Future of Pretrained Large Language Models (LLMs) for Education Revolution*. 2024. Disponível em: <https://osf.io/7ds4a>. Acesso em: 27 abr. 2025. Citado na página 16.

BORGES, B. G.; SILVA, S. P. D. Avaliação, exames e poderes: a “docimologia” a partir de algumas contribuições de Foucault e Nietzsche. *EDUCAÇÃO E FILOSOFIA*, v. 31, n. 62, p. 669–694, ago. 2017. ISSN 01026801, 1982596X. Disponível em: <http://www.seer.ufu.br/index.php/EducacaoFilosofia/article/view/31385>. Acesso em: 30 abr. 2025. Citado 3 vezes nas páginas 2, 4 e 7.

BRAY, T. *The JavaScript Object Notation (JSON) Data Interchange Format*. 2017. RFC 8259. Disponível em: <https://www.rfc-editor.org/rfc/rfc8259>. Acesso em: 22 mar. 2026. Citado na página 45.

CARNAVAL, M. M. A desigualdade da infraestrutura escolar das escolas estaduais no município de São Paulo. *Jornal de Políticas Educacionais*, v. 15, maio 2021. ISSN 1981-1969, 1981-1969. Disponível em: <https://revistas.ufpr.br/jpe/article/view/79216>. Acesso em: 30 abr. 2025. Citado na página 1.

CARREGARI, F. A. D. S.; ROMÃO, J. E. LUCKESI, Cipriano Carlos. Avaliação em educação: questões epistemológicas e práticas. São Paulo: Cortez, 2018. *Dialogia*, n. 48, p. e25572, abr. 2024. ISSN 1983-9294, 1677-1303. Disponível em: <https://periodicos.uninove.br/dialogia/article/view/25572>. Acesso em: 29 abr. 2025. Citado na página 5.

CHEN, M. et al. *Evaluating Large Language Models Trained on Code*. arXiv, 2021. ArXiv:2107.03374. Disponível em: <http://arxiv.org/abs/2107.03374>. Acesso em: 29 abr. 2025. Citado 2 vezes nas páginas 1 e 15.

- CHEN, S. et al. *A Survey on LLM-based Multi-Agent System: Recent Advances and New Frontiers in Application*. arXiv, 2025. ArXiv:2412.17481. Disponível em: <<http://arxiv.org/abs/2412.17481>>. Acesso em: 6 maio 2025. Citado 2 vezes nas páginas 18 e 19.
- Chroma Contributors. *Chroma Documentation*. 2026. Disponível em: <<https://docs.trychroma.com/>>. Acesso em: 22 mar. 2026. Citado na página 45.
- DIAS, A. N. d. L. et al. CORREÇÃO AUTOMATIZADA DE QUESTÕES DISSERTATIVAS UTILIZANDO MEDIDAS DE SIMILARIDADE E PROCESSAMENTO DE LINGUAGEM NATURAL. *Colloquium Exactarum*. ISSN: 2178-8332, v. 15, n. 1, p. e234595–e234595, ago. 2023. ISSN 2178-8332. Disponível em: <<https://journal.unoeste.br/index.php/ce/article/view/4595>>. Acesso em: 1 abr. 2025. Citado na página 2.
- Docker, Inc. *Docker Compose Documentation*. 2026. Disponível em: <<https://docs.docker.com/compose/>>. Acesso em: 22 mar. 2026. Citado na página 45.
- Docker, Inc. *Docker Documentation*. 2026. Disponível em: <<https://docs.docker.com/>>. Acesso em: 22 mar. 2026. Citado na página 45.
- DSPy Contributors. *DSPy Documentation*. 2026. Disponível em: <<https://dspy.ai/>>. Acesso em: 22 mar. 2026. Citado 2 vezes nas páginas 20 e 44.
- FastAPI. *FastAPI Documentation*. 2026. Disponível em: <<https://fastapi.tiangolo.com/>>. Acesso em: 22 mar. 2026. Citado na página 44.
- Fiki Setiawan; Annas Alkhowarizmi. Exploring an Artificial Intelligence as Automated Feedback Program in EFL Writing. *ETERNAL (English Teaching Journal)*, v. 16, n. 1, p. 202–224, fev. 2025. ISSN 2614-1639, 2086-5473. Disponível em: <<https://journal2.upgris.ac.id/index.php/eternal/article/view/1206>>. Acesso em: 12 maio 2025. Citado 5 vezes nas páginas 28, 31, 32, 34 e 35.
- FINARDI, P. et al. *The Chronicles of RAG: The Retriever, the Chunk and the Generator*. arXiv, 2024. ArXiv:2401.07883. Disponível em: <<http://arxiv.org/abs/2401.07883>>. Acesso em: 26 fev. 2025. Citado na página 48.
- GAO, L. et al. *Precise Zero-Shot Dense Retrieval without Relevance Labels*. arXiv, 2022. ArXiv:2212.10496. Disponível em: <<http://arxiv.org/abs/2212.10496>>. Acesso em: 6 maio 2025. Citado na página 22.
- GAO, Y. et al. *Retrieval-Augmented Generation for Large Language Models: A Survey*. arXiv, 2024. ArXiv:2312.10997. Disponível em: <<http://arxiv.org/abs/2312.10997>>. Acesso em: 6 maio 2025. Citado 2 vezes nas páginas 21 e 22.
- GATTI, B. A. FORMAÇÃO DE PROFESSORES, COMPLEXIDADE E TRABALHO DOCENTE. *Revista Diálogo Educacional*, v. 17, n. 53, p. 721–737, ago. 2017. ISSN 1981-416X. Disponível em: <<https://periodicos.pucpr.br/dialogoeducacional/article/view/8429>>. Acesso em: 29 abr. 2025. Citado na página 1.
- Gunicorn Contributors. *Gunicorn Documentation*. 2026. Disponível em: <<https://docs.gunicorn.org/>>. Acesso em: 22 mar. 2026. Citado na página 44.

HEGGLER, J. M.; SZMOSKI, R. M.; MIQUELIN, A. F. AS DUALIDADES ENTRE O USO DA INTELIGÊNCIA ARTIFICIAL NA EDUCAÇÃO E OS RISCOS DE VIESES ALGORÍTMICOS. *Educação & Sociedade*, v. 46, jan. 2025. ISSN 1678-4626. Disponível em: <<https://www.scielo.br/j/es/a/qrTryFvZR9Y9WsRpG5fWGHb/>>. Acesso em: 27 abr. 2025. Citado 3 vezes nas páginas 2, 10 e 17.

HUTT, S. et al. Feedback on Feedback: Comparing Classic Natural Language Processing and Generative AI to Evaluate Peer Feedback. In: *Proceedings of the 14th Learning Analytics and Knowledge Conference*. Kyoto Japan: ACM, 2024. p. 55–65. ISBN 9798400716188. Disponível em: <<https://dl.acm.org/doi/10.1145/3636555.3636850>>. Acesso em: 12 maio 2025. Citado 5 vezes nas páginas 28, 31, 33, 34 e 35.

Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. *A Redação no ENEM 2024: Cartilha do Participante*. 2024. Diretoria de Avaliação da Educação Básica (DAEB). Ministério da Educação. Disponível em: <https://download.inep.gov.br/publicacoes/institucionais/avaliacoes_e_exames_da_educacao_basica/a_redacao_no_enem_2024_cartilha_do_participante.pdf>. Acesso em: 27 mar. 2026. Citado 2 vezes nas páginas 48 e 56.

JANUMPALLY, R. K. The Role of Natural Language Processing in Graduate Medical Education: A Scoping Review. *Cureus*, mar. 2025. ISSN 2168-8184. Disponível em: <<https://www.cureus.com/articles/334867-the-role-of-natural-language-processing-in-graduate-medical-education-a-scoping-review>>. Acesso em: 12 maio 2025. Citado 3 vezes nas páginas 28, 30 e 32.

KHATTAB, O.; ZAHARIA, M. *ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT*. arXiv, 2020. ArXiv:2004.12832. Disponível em: <<http://arxiv.org/abs/2004.12832>>. Acesso em: 6 maio 2025. Citado na página 21.

KITCHENHAM, B.; CHARTERS, S. *Guidelines for performing systematic literature reviews in software engineering*. [S.l.], 2007. Citado 3 vezes nas páginas 24, 25 e 26.

KITZIE, V. et al. The AI-empowered Researcher: Using AI-based Tools for Success in Ph.D. Programs. *Proceedings of the ALISE Annual Conference*, out. 2024. ISSN 2573-2269. Disponível em: <<https://iopn.library.illinois.edu/journals/aliseacp/article/view/1710>>. Acesso em: 12 maio 2025. Citado 3 vezes nas páginas 29, 32 e 33.

LAI, J. et al. Large language models in law: A survey. *AI Open*, v. 5, p. 181–196, jan. 2024. ISSN 2666-6510. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2666651024000172>>. Acesso em: 30 abr. 2025. Citado na página 1.

LangChain, Inc. *LangChain Documentation*. 2026. Disponível em: <<https://python.langchain.com/>>. Acesso em: 22 mar. 2026. Citado na página 44.

LangChain, Inc. *LangGraph Documentation*. 2026. Disponível em: <<https://langchain-ai.github.io/langgraph/>>. Acesso em: 22 mar. 2026. Citado na página 44.

LEWIS, P. et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. arXiv, 2021. ArXiv:2005.11401. Disponível em: <<http://arxiv.org/abs/2005.11401>>. Acesso em: 6 maio 2025. Citado na página 21.

- LI, W.; LIU, H. Applying large language models for automated essay scoring for non-native Japanese. *Humanities and Social Sciences Communications*, v. 11, n. 1, p. 723, jun. 2024. ISSN 2662-9992. Disponível em: <<https://www.nature.com/articles/s41599-024-03209-9>>. Acesso em: 12 maio 2025. Citado 3 vezes nas páginas 28, 29 e 34.
- LIMA, T. B. d.; FREITAS, E.; MACARIO, V. AESVoting: Automatic Essay Scoring with Bert and Voting Classifiers. In: GAMALLO, P. et al. (Ed.). *Proceedings of the 16th International Conference on Computational Processing of Portuguese - Vol. 2*. Santiago de Compostela, Galicia/Spain: Association for Computational Linguistics, 2024. p. 6–9. Disponível em: <<https://aclanthology.org/2024.propor-2.2/>>. Acesso em: 28 abr. 2025. Citado na página 2.
- LIMA, T. B. d. et al. Avaliação Automática de Redação: Uma revisão sistemática. *Revista Brasileira de Informática na Educação*, v. 31, p. 205–221, maio 2023. ISSN 2317-6121. Disponível em: <<https://journals-sol.sbc.org.br/index.php/rbie/article/view/2869>>. Acesso em: 27 abr. 2025. Citado 6 vezes nas páginas 6, 8, 9, 10, 11 e 14.
- LIU, P. et al. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *ACM Comput. Surv.*, Association for Computing Machinery, New York, NY, USA, v. 55, n. 9, jan. 2023. ISSN 0360-0300. Disponível em: <<https://doi.org/10.1145/3560815>>. Acesso em: 5 maio 2025. Citado na página 20.
- Ollama. *Ollama Documentation*. 2026. Disponível em: <<https://ollama.com/>>. Acesso em: 22 mar. 2026. Citado na página 45.
- OTTER, D. W.; MEDINA, J. R.; KALITA, J. K. A Survey of the Usages of Deep Learning for Natural Language Processing. *IEEE transactions on neural networks and learning systems*, v. 32, n. 2, p. 604–624, fev. 2021. ISSN 2162-2388. Citado 2 vezes nas páginas 1 e 13.
- PAIXÃO, G. M. d. M. et al. Machine Learning na Medicina: Revisão e Aplicabilidade. *Arquivos Brasileiros de Cardiologia*, v. 118, n. 1, p. 95–102, jan. 2022. ISSN 0066-782X. Disponível em: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8959062/>>. Acesso em: 30 abr. 2025. Citado na página 1.
- PESSANHA, G. R. G.; VIEIRA, A. G.; BRANDÃO, W. C. Large Language Models (LLMs): A systematic study in Administration and Business. *RAM. Revista de Administração Mackenzie*, v. 25, p. eRAMD240059, dez. 2024. ISSN 1678-6971. Disponível em: <<https://www.scielo.br/j/ram/a/GCJHtgxWBNVv7kB73pKbm5m/?lang=en>>. Acesso em: 30 abr. 2025. Citado na página 1.
- PINHO, C. M. D. A.; GASPAR, M. A.; SASSI, R. J. APLICAÇÃO DE TÉCNICAS DE INTELIGÊNCIA ARTIFICIAL PARA CLASSIFICAÇÃO DE FUGA AO TEMA EM REDAÇÕES. *Educação em Revista*, v. 40, p. e39773, 2024. ISSN 1982-6621, 0102-4698. Disponível em: <http://www.scielo.br/scielo.php?script=sci_arttext&pid=S0102-46982024000100209&tlng=pt>. Acesso em: 1 abr. 2025. Citado 4 vezes nas páginas 2, 4, 6 e 9.
- PostgreSQL Global Development Group. *PostgreSQL Documentation*. 2026. Disponível em: <<https://www.postgresql.org/docs/>>. Acesso em: 22 mar. 2026. Citado na página 45.
- Python Software Foundation. *Python 3 Documentation*. 2026. Disponível em: <<https://docs.python.org/3/>>. Acesso em: 22 mar. 2026. Citado na página 43.

- QIAN, C. et al. *ChatDev: Communicative Agents for Software Development*. arXiv, 2024. ArXiv:2307.07924. Disponível em: <<http://arxiv.org/abs/2307.07924>>. Acesso em: 6 maio 2025. Citado na página 19.
- QIU, H. et al. *SteLLA: A Structured Grading System Using LLMs with RAG*. arXiv, 2025. Disponível em: <<https://arxiv.org/abs/2501.09092>>. Acesso em: 12 maio 2025. Citado na página 35.
- RAM, O. et al. *In-Context Retrieval-Augmented Language Models*. arXiv, 2023. ArXiv:2302.00083. Disponível em: <<http://arxiv.org/abs/2302.00083>>. Acesso em: 6 maio 2025. Citado na página 22.
- RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. [S.l.]: Pearson, 2021. ISBN 978-0134610993. Citado na página 12.
- SAHOO, P. et al. *A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications*. arXiv, 2025. ArXiv:2402.07927. Disponível em: <<http://arxiv.org/abs/2402.07927>>. Acesso em: 6 maio 2025. Citado 2 vezes nas páginas 19 e 20.
- SANTOS, L. A articulação entre a avaliação somativa e a formativa, na prática pedagógica: uma impossibilidade ou um desafio? *Ensaio: Avaliação e Políticas Públicas em Educação*, v. 24, n. 92, p. 637–669, set. 2016. ISSN 0104-4036. Disponível em: <http://www.scielo.br/scielo.php?script=sci_arttext&pid=S0104-40362016000300637&lng=pt&tlng=pt>. Acesso em: 29 abr. 2025. Citado 2 vezes nas páginas 2 e 4.
- SAVINO, L. L.; FERNANDES, M. M. *ai-grading-system: código-fonte do protótipo de correção automática de provas discursivas*. 2026. Disponível em: <<https://github.com/savinoo/ai-grading-system>>. Acesso em: 23 mar. 2026. Citado na página 66.
- SCHNEIDER, J.; SCHENK, B.; NIKLAUS, C. *Towards LLM-based Autograding for Short Textual Answers*. arXiv, 2024. ArXiv:2309.11508. Disponível em: <<http://arxiv.org/abs/2309.11508>>. Acesso em: 26 fev. 2025. Citado na página 78.
- SEO, H. et al. Large Language Models as Evaluators in Education: Verification of Feedback Consistency and Accuracy. *Applied Sciences*, v. 15, n. 2, p. 671, jan. 2025. ISSN 2076-3417. Disponível em: <<https://www.mdpi.com/2076-3417/15/2/671>>. Acesso em: 27 abr. 2025. Citado 2 vezes nas páginas 2 e 16.
- SHAHZAD, T. et al. A comprehensive review of large language models: issues and solutions in learning environments. *Discover Sustainability*, v. 6, n. 1, p. 27, jan. 2025. ISSN 2662-9984. Disponível em: <<https://doi.org/10.1007/s43621-025-00815-8>>. Acesso em: 30 abr. 2025. Citado 2 vezes nas páginas 1 e 2.
- SILVA, R. R. d. O. d. *Políticas e gestão da educação brasileira em tempos de retrocessos*. [S.l.]: Anpae, 2020. ISBN 9786587561004. Citado na página 1.
- SQLAlchemy Authors. *Alembic Documentation*. 2026. Disponível em: <<https://alembic.sqlalchemy.org/>>. Acesso em: 22 mar. 2026. Citado na página 45.
- SQLAlchemy Authors. *SQLAlchemy Documentation*. 2026. Disponível em: <<https://docs.sqlalchemy.org/>>. Acesso em: 22 mar. 2026. Citado na página 45.


- Streamlit Inc. *Streamlit Documentation*. 2026. Disponível em: <<https://docs.streamlit.io/>>. Acesso em: 22 mar. 2026. Citado na página 45.
- TORFI, A. et al. *Natural Language Processing Advancements By Deep Learning: A Survey*. arXiv, 2021. ArXiv:2003.01200. Disponível em: <<http://arxiv.org/abs/2003.01200>>. Acesso em: 29 abr. 2025. Citado 3 vezes nas páginas 1, 12 e 13.
- Uvicorn Contributors. *Uvicorn Documentation*. 2026. Disponível em: <<https://www.uvicorn.org/>>. Acesso em: 22 mar. 2026. Citado na página 44.
- VASWANI, A. et al. Attention Is All You Need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Curran Associates, 2017. Publicado em NeurIPS 2017. arXiv:1706.03762. Disponível em: <<http://arxiv.org/abs/1706.03762>>. Acesso em: 29 abr. 2025. Citado 2 vezes nas páginas 1 e 14.
- WANG, L. et al. *A Survey on Large Language Model based Autonomous Agents*. arXiv, 2025. ArXiv:2308.11432. Disponível em: <<http://arxiv.org/abs/2308.11432>>. Acesso em: 6 maio 2025. Citado 2 vezes nas páginas 17 e 19.
- WANG, S. et al. *Large Language Models for Education: A Survey and Outlook*. arXiv, 2024. ArXiv:2403.18105. Disponível em: <<http://arxiv.org/abs/2403.18105>>. Acesso em: 29 abr. 2025. Citado 3 vezes nas páginas 13, 15 e 16.
- WEI, J. et al. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. arXiv, 2023. ArXiv:2201.11903. Disponível em: <<http://arxiv.org/abs/2201.11903>>. Acesso em: 6 maio 2025. Citado na página 20.
- WOOLDRIDGE, M. J. *An introduction to multiagent systems*. 2. ed., repr. ed. Chichester: Wiley, 2012. ISBN 9780470519462. Citado na página 17.
- XI, Z. et al. *The Rise and Potential of Large Language Model Based Agents: A Survey*. arXiv, 2023. ArXiv:2309.07864. Disponível em: <<http://arxiv.org/abs/2309.07864>>. Acesso em: 5 maio 2025. Citado na página 17.
- XIAO, C. et al. Human-AI Collaborative Essay Scoring: A Dual-Process Framework with LLMs. In: *Proceedings of the 15th International Learning Analytics and Knowledge Conference*. Dublin Ireland: ACM, 2025. p. 293–305. ISBN 9798400707018. Disponível em: <<https://dl.acm.org/doi/10.1145/3706468.3706507>>. Acesso em: 12 maio 2025. Citado 4 vezes nas páginas 28, 30, 34 e 35.
- YAN, B. et al. *Beyond Self-Talk: A Communication-Centric Survey of LLM-Based Multi-Agent Systems*. arXiv, 2025. ArXiv:2502.14321. Disponível em: <<http://arxiv.org/abs/2502.14321>>. Acesso em: 6 maio 2025. Citado 2 vezes nas páginas 18 e 19.
- YOUNG, T. et al. *Recent Trends in Deep Learning Based Natural Language Processing*. arXiv, 2018. ArXiv:1708.02709. Disponível em: <<http://arxiv.org/abs/1708.02709>>. Acesso em: 29 abr. 2025. Citado 2 vezes nas páginas 1 e 13.

Apêndices

APÊNDICE A – ESQUEMA COMPLETO DO BANCO DE DADOS

Este apêndice apresenta uma visão completa do esquema relacional do sistema. A figura foi gerada automaticamente a partir das tabelas e relacionamentos definidos no banco de dados e é fornecida como material de consulta.

Figura 8 – Esquema completo do banco de dados relacional



Fonte: Elaborado pelos autores.

APÊNDICE B – PROMPTS COMPLETOS

Este apêndice apresenta os prompts completos utilizados na implementação dos agentes corretores e do árbitro, bem como helpers de formatação usados para montar entradas. Os trechos abaixo correspondem ao conteúdo do arquivo de código-fonte ‘src/domain/ai/prompts.py’.

```
"""
```

```
Centralização dos Prompts do Sistema de Correção Automática.
```

```
Aplica técnicas de Engenharia de Prompt:
```

1. Role Prompting (Atuar como especialista)
2. Chain-of-Thought (Raciocínio passo-a-passo)
3. Groundedness (Fidelidade ao Contexto RAG)
4. Cobertura de Edge Cases (respostas em branco, fora do tema, cópia)

```
"""
```

```
from __future__ import annotations
```

```
from typing import List
```

```
from src.domain.ai.schemas import EvaluationCriterion
```

```
from src.domain.ai.rag_schemas import RetrievedContext
```

```
# -----
# PROMPT PARA CORRETORES INDEPENDENTES (C1 e C2)
# -----
```

```
CORRECTOR_SYSTEM_PROMPT = """
```

```
Você é um Especialista em Avaliação Educacional com foco em correção de provas disc
Sua tarefa é avaliar a resposta de um aluno para uma questão técnica, baseando-se n
```

```
### INSTRUÇÕES FUNDAMENTAIS:
```

1. ****Uso do Contexto (RAG):**** O material didático fornecido abaixo é sua REFERÊNCIA
 - Se a resposta do aluno estiver ****tecnicamente correta**** e atender ao enunciado
 - Sua prioridade é verificar se o aluno ****compreendeu o conceito**** solicitado na
 - Apenas rejeite informações externas válidas se elas ****contradisserem**** o mater

2. ****Avaliação de Especificidade:**** Avalie o nível de especificidade da resposta:
 - (a) Resposta específica e correta → nota integral no critério
 - (b) Resposta correta mas genérica (usa conceitos certos sem detalhe) → nota parcial
 - (c) Resposta vaga que poderia se aplicar a qualquer contexto → nota mínima (0-25)
 - (d) Embromação deliberada (frases vazias, clichês, nenhum conceito técnico) → zero
3. ****Chain-of-Thought (CoT):**** Antes de atribuir qualquer nota, você deve desenvolver uma cadeia de raciocínio.
4. ****Feedback Pedagógico:**** Seu feedback deve ser PROFISSIONAL e OBJETIVO. Aponte pontos fortes e áreas de melhoria.
5. ****Formato de Saída:**** Sua resposta deve ser estritamente um objeto JSON válido que siga o formato especificado.

CASOS ESPECIAIS:

- ****Resposta em branco ou trivial**** (ex: "não sei", ".", frases sem conteúdo técnico) → atribua nota zero.
- ****Resposta completamente fora do tema**** (responde sobre assunto diferente do enunciado) → atribua nota zero.
- ****Cópia literal do material sem elaboração própria****: Atribua nota parcial (50%).

DADOS DE ENTRADA:

--- ENUNCIADO DA QUESTÃO ---

{question_statement}

--- RUBRICA DE AVALIAÇÃO ---

{rubric_formatted}

--- CONTEXTO RECUPERADO (MATERIAL DIDÁTICO) ---

{rag_context_formatted}

--- RESPOSTA DO ALUNO ---

{student_answer}

SEU OBJETIVO:

Primeiro, verifique se a resposta aborda o tema da questão. Se não abordar, atribua nota zero.

Se abordar, gere um JSON com os seguintes campos:

- 'agent_id': "{agent_id}"
- 'criteria_scores': Lista com a nota de CADA critério, ****na mesma ordem em que aparecem na rubrica****.
- 'total_score': A soma simples e EXATA de todos os valores em 'criteria_scores'.
- 'reasoning_chain': Seu processo de pensamento detalhado. Analise CADA critério separadamente.
- 'feedback_text': Feedback direto e profissional para o aluno, em no máximo 3 frases.

"""

```
# -----
# PROMPT PARA O ÁRBITRO (C3 - Desempate)
# -----

ARBITER_SYSTEM_PROMPT = """
Você é um Revisor Sênior e Árbitro Acadêmico.
Foi detectada uma DIVERGÊNCIA significativa entre dois avaliadores (Corretor 1 e Co

Sua tarefa é analisar a resposta do aluno, o contexto, e as avaliações conflitantes

### ANÁLISE DE DIVERGÊNCIA:
- O Corretor 1 deu a nota: {score_c1}
- O Corretor 2 deu a nota: {score_c2}
- A diferença é de: {divergence_value} pontos.

### INSTRUÇÕES DO ÁRBITRO:
1. **Avaliação Independente PRIMEIRO:** Antes de considerar as avaliações dos corre
2. **Reconciliação:** SOMENTE APÓS formar sua avaliação independente, compare com o
    - Onde você concorda com C1 ou C2 (e por quê)
    - Onde ambos erraram (se aplicável)
    - Se algum corretor aluciou regras inexistentes ou ignorou erros graves
3. **Veredito Final:** Sua nota final pode coincidir com C1, com C2, ou ser complet

### DADOS DE ENTRADA:

--- ENUNCIADO E RUBRICA ---
{question_statement}
{rubric_formatted}

--- CONTEXTO RAG ---
{rag_context_formatted}

--- RESPOSTA DO ALUNO ---
{student_answer}

--- AVALIAÇÃO DO CORRETOR 1 ---
Raciocínio: {reasoning_c1}
Nota: {score_c1}
```

--- AVALIAÇÃO DO CORRETOR 2 ---

Raciocínio: {reasoning_c2}

Nota: {score_c2}

SEU OBJETIVO:

Gere um JSON final (formato 'AgentCorrection') com sua avaliação de desempate. O campo 'criteria_scores' deve seguir a mesma ordem da rubrica, com o campo 'reasoning_chain', primeiro apresente sua avaliação independente, depois c

"""

HELPER FUNCTIONS (Para formatar os inputs dentro dos prompts)

def format_rubric_text(rubric_list: List[EvaluationCriterion]) -> str:

"""

Transforma a lista de objetos EvaluationCriterion em texto formatado para o prompt

Args:

rubric_list: Lista de critérios de avaliação

Returns:

String formatada com os critérios

"""

total = sum(c.max_score for c in rubric_list)

text = f"[Escala total: {total:.1f} pontos distribuídos entre {len(rubric_list)}

for criterion in rubric_list:

text += f"- Critério: {criterion.name} (Valendo até: {criterion.max_score})

text += f" Descrição: {criterion.description}\n"

return text

def format_rag_context(context_list: List[RetrievedContext]) -> str:

"""

Formata os chunks recuperados para leitura clara do LLM.

Args:

context_list: Lista de contextos recuperados via RAG

Returns:

String formatada com os trechos relevantes

"""

```
if not context_list:
```

```
    return "[Nenhum contexto específico foi recuperado. Avalie com base no conh
```

```
text = ""
```

```
for idx, ctx in enumerate(context_list, 1):
```

```
    text += f"[TRECHO {idx}] (Fonte: {ctx.source_document}, Pág: {ctx.page_num
```

```
    text += f"Relevância: {ctx.relevance_score:.2f}\n"
```

```
    text += f"{ctx.content}\n\n"
```

```
return text
```